



UNIVERSITAT POLITÈCNICA
DE CATALUNYA
BARCELONATECH



telecos
BCN



GENERACIÓ AUTOMATITZADA DE DATASETS RASTER AMBIENTALS ALS PIRINEUS PER A APLICACIONS D'ANÀLISI ESPACIAL I MODELITZACIÓ ECOLÒGICA

ANIOL GARRIGA TORRA

Director/a

CARLOS LOPEZ MARTINEZ (Departament de Teoria del Senyal i Comunicacions)

Codirector/a

ALBERTO ALONSO GONZÁLEZ (Departament de Teoria del Senyal i Comunicacions)

Titulació

Grau en Ciència i Enginyeria de Dades

Memòria del treball de fi de grau

Facultat d'Informàtica de Barcelona (FIB)

Escola Tècnica Superior d'Enginyeria de Telecomunicació de Barcelona (ETSETB)

Facultat de Matemàtiques i Estadística (FME)

Universitat Politècnica de Catalunya (UPC) - BarcelonaTech

25/06/2026

Resums

Resum

Els Pirineus concentren una diversitat ambiental excepcional, però les fonts de dades geoespacial que la descriuen presenten una heterogeneïtat molt alta. Elevació, coberta del sòl, clima, neu, vegetació i pressió humana arriben cadascuna amb sistemes de coordenades, resolucions, estructures temporals, mecanismes de descàrrega i formats finals propis i incompatibles entre si. A aquesta dificultat tècnica s’hi afegeix la fragmentació política de la serralada entre tres estats, que fa que poques fonts precises cobreixin el domini pirinenc de manera uniforme. El resultat és que qualsevol investigador que necessiti construir un *dataset* geoespacial integrat als Pirineus ha d’assumir un cost d’harmonització manual enorme, repetitiu i difícil de reproduir, abans d’arribar a la pregunta científica que realment vol respondre.

Aquest treball presenta **pirineus-raster**, una eina que resol aquest problema de manera sistemàtica. Mitjançant fitxers de configuració **YAML**, l’investigador declara l’àrea d’interès, la resolució i les variables ambientals que necessita, i **pirineus-raster** s’encarrega de la resta: descarregar les fonts, harmonitzar-les sobre una graella de referència comuna i generar un *dataset raster* directament apte per a l’anàlisi. Una interfície visual integrada facilita la creació i validació d’aquestes configuracions sense necessitat d’escriure codi, mentre que el sistema garanteix la reproductibilitat i la traçabilitat de cada capa generada. El resultat és una infraestructura reutilitzable que permet generar *datasets* de qualitat per a qualsevol cas d’ús pirinenc amb un cost molt inferior al que requeriria la harmonització manual.

Per demostrar la capacitat de l’eina per produir *datasets* aptes per a estudis d’idoneïtat d’hàbitat de fauna, s’ha aprofitat l’oportunitat de modelitzar l’ós bru (*Ursus arctos*) als Pirineus, una espècie en perill d’extinció per a la qual el coneixement espacial del seu hàbitat és clau per a la conservació. A partir d’un *dataset* de 41 variables generat amb **pirineus-raster** a 100 m de resolució, s’han entrenat models d’aprenentatge automàtic basats en arbres per a femelles amb cries. Per a la classe de cries de menys de sis mesos s’obté un model amb bona capacitat de discriminació espacial que permet cartografiar la idoneïtat d’hàbitat a escala de tot el Pirineu i complementar la cartografia de referència existent.

Paraules clau: *datasets raster*, dades *analysis-ready*, Pirineus, harmonització geoespacial, modelització ecològica, idoneïtat d’hàbitat, ós bru, XGBoost

Abstract

The Pyrenees concentrate exceptional environmental diversity, yet the geospatial data sources that describe it present very high heterogeneity. Elevation, land cover, climate, snow, vegetation, and human pressure each arrive with their own coordinate reference systems, resolutions, temporal structures, download mechanisms, and file formats, all mutually incompatible. This technical challenge is compounded by the political fragmentation of the mountain range across three states, which means that few precise sources cover the Pyrenean domain uniformly. The result is that any researcher needing to build an integrated geospatial *dataset* for the Pyrenees must absorb a huge, repetitive, and poorly reproducible harmonisation effort before reaching the scientific question they actually want to answer.

This work presents **pirineus-raster**, a tool that solves this problem systematically. Through YAML configuration files, the researcher declares the area of interest, the resolution, and the environmental variables needed, and **pirineus-raster** takes care of the rest: downloading the sources, harmonising them onto a shared reference grid, and delivering a raster *dataset* that is directly ready for analysis. An integrated visual interface makes it easy to create and validate these configurations without writing code, while the system ensures the reproducibility and traceability of every generated layer. The outcome is a reusable infrastructure that enables high-quality *datasets* to be produced for any Pyrenean use case at a fraction of the cost of manual harmonisation.

To demonstrate the tool's ability to produce *datasets* suitable for wildlife habitat suitability studies, the opportunity arose to model the brown bear (*Ursus arctos*) across the Pyrenees, an endangered species for which detailed spatial knowledge of its habitat is critical to conservation. From a 41-variable *dataset* generated with **pirineus-raster** at 100 m resolution, tree-based machine learning models were trained for females with cubs. For the class of cubs younger than six months, the resulting model shows strong spatial discrimination and enables habitat suitability to be mapped across the entire Pyrenean range, providing a complementary perspective to existing reference cartography.

Keywords: raster *datasets*, analysis-ready data, Pyrenees, geospatial harmonisation, ecological modelling, habitat suitability, brown bear, XGBoost

Resumen

Los Pirineos concentran una diversidad ambiental excepcional, pero las fuentes de datos geoespaciales que la describen presentan una heterogeneidad muy alta. Elevación, cobertura del suelo, clima, nieve, vegetación y presión humana llegan cada una con sistemas de coordenadas, resoluciones, estructuras temporales, mecanismos de descarga y formatos finales propios e incompatibles entre sí. A esta dificultad técnica se suma la fragmentación política de la cordillera entre tres estados, que hace que pocas fuentes precisas cubran el dominio pirenaico de manera uniforme. El resultado es que cualquier investigador que necesite construir un *dataset* geoespacial integrado en los Pirineos debe asumir un coste de armonización manual enorme, repetitivo y difícil de reproducir, antes de llegar a la pregunta científica que realmente quiere responder.

Este trabajo presenta **pirineus-raster**, una herramienta que resuelve este problema de manera sistemática. Mediante archivos de configuración YAML, el investigador declara el área de interés, la resolución y las variables ambientales que necesita, y **pirineus-raster** se encarga del resto: descargar las fuentes, armonizarlas sobre una cuadrícula de referencia común y generar un *dataset raster* directamente apto para el análisis. Una interfaz visual integrada facilita la creación y validación de estas configuraciones sin necesidad de escribir código, mientras que el sistema garantiza la reproducibilidad y la trazabilidad de cada capa generada. El resultado es una infraestructura reutilizable que permite generar *datasets* de calidad para cualquier caso de uso pirenaico con un coste muy inferior al que requeriría la armonización manual.

Para demostrar la capacidad de la herramienta para producir *datasets* aptos para estudios de idoneidad de hábitat de fauna, se ha aprovechado la oportunidad de modelizar el oso pardo (*Ursus arctos*) en los Pirineos, una especie en peligro de extinción para la cual el conocimiento espacial de su hábitat es clave para la conservación. A partir de un *dataset* de 41 variables generado con **pirineus-raster** a 100 m de resolución, se han entrenado modelos de aprendizaje automático basados en árboles para hembras con crías. Para la clase de crías de menos de seis meses se obtiene un modelo con buena capacidad de discriminación espacial que permite cartografiar la idoneidad de hábitat a escala de todo el Pirineo y complementar la cartografía de referencia existente.

Palabras clave: *datasets raster*, datos *analysis-ready*, Pirineos, armonización geoespacial, modelización ecológica, idoneidad de hábitat, oso pardo, XGBoost

Agraïments

Primer de tot, vull agrair als meus dos tutors del projecte, Carlos López Martínez i Alberto Alonso González, l'ajuda, el suport, la comprensió i la tutela d'aquest projecte, que ha estat molt personal des del primer moment. Gràcies per entendre les meves idees, ajudar-me a desenvolupar-les millor i transmetre'm els consells de veterania que tant m'han ajudat.

També m'agradaria agrair a qui dec gran part d'aquesta idea, en Juan Fernández Gil, la seva visió experta, els seus consells, les seves propostes i la cessió de dades tan valuoses sobre l'ós bru als Pirineus. Tot plegat m'ha ajudat a encarrilar una part fonamental del projecte.

Vull agrair igualment al meu pare, en Marc Garriga i Lujan, que, a més d'haver estat el precursor de la idea original, m'ha ajudat a aconseguir els contactes adients per al bon desenvolupament del projecte i, evidentment, ha estat un gran suport emocional per a mi, tant en aquest projecte com al llarg de tota la meva vida.

A la meva mare, Gemma Torra i Vilajosana, que, tot i que potser encara no sàpiga ben bé de què va el meu projecte, m'ha donat suport incondicional, ara i sempre.

A la meva parella, la Paula Mimoso i Gómez, que és qui m'ha vist suar hores i hores, dies i dies, per aquest projecte; i que, des del moment en què la vaig conèixer, no ha deixat d'ajudar-me, fer-me costat i estimar-me. L'estimo molt.

A tots aquells experts, com l'Oriol Grau o en Lluís Comas, que potser creuen que només m'han donat el seu granet de sorra, però que en realitat m'han donat una muntanya. A partir dels seus consells vaig acabar decidint que havia de construir una eina automatitzada d'harmonització completa.

Finalment, vull agrair-me a mi mateix la perseverança, la resiliència i la voluntat de fer cada canvi, cada procés i cada secció de la millor manera possible. Ara fa un mes no les tenia totes que acabaria, i encara menys que ho faria així de bé, aquest gran projecte que tenia al damunt.

Gràcies, Aniol.

Índex

Resums	i
Resum	i
Abstract	ii
Resumen	iii
Agraïments	iv
Índex de figures	ix
Índex de taules	x
Acrònims i notació	xi
1 Introducció	1
1.1 Context i motivació	1
1.2 Plantejament del problema	3
1.2.1 Heterogeneïtat de les fonts geoespacial	3
1.2.2 Necessitat de dades preparades per a l'anàlisi	4
1.3 Objectius del treball	4
1.3.1 Objectiu general	4
1.3.2 Objectius específics	4
1.4 Abast i delimitació del treball	5
1.5 Treball previ i fonaments conceptuals	5
1.5.1 Dades raster ambientals	6
1.5.2 Processament geoespacial reproducible	6
1.5.3 Modelització ecològica d'idoneïtat d'hàbitat	7
1.6 Contribucions principals	7
1.7 Estructura de la memòria	8
2 Disseny del sistema i arquitectura de pirineus-raster	9
2.1 Requisits del sistema	9
2.1.1 Requisits funcionals	10
2.1.2 Requisits no funcionals	12
2.2 Visió general de l'arquitectura	14
2.3 Organització del repositori	17
2.3.1 Estructura de directoris	17
2.3.2 Separació entre codi, configuració i productes generats	19
2.3.3 Interfície de configuració i <i>workbench</i> visual	19

2.4	Parametrització del flux de treball	22
2.4.1	Configuració territorial	23
2.4.2	Configuració de variables ambientals	23
2.4.3	Configuració de sortides	23
2.4.4	Model de <i>features</i> i compilador de configuracions	23
2.5	Flux de processament	24
2.6	Traçabilitat, metadades i control de versions	24
2.7	Publicació, reutilització i modes d'ús	25
2.8	Adequació de l'eina al problema plantejat	25
3	Construcció automatitzada de <i>datasets</i> raster preparats per a l'anàlisi	27
3.1	Criteris de construcció del <i>dataset</i>	27
3.2	Àrea d'estudi i graella de referència	28
3.2.1	Definició de l'AOI i límits de treball	28
3.2.2	Sistema de coordenades, resolució i alineació de píxels	29
3.3	Ingesta i preparació de fonts ambientals	30
3.3.1	Descàrrega o localització de dades originals	30
3.3.2	Validació inicial de fonts i metadades	31
3.3.3	Catàleg de fonts ambientals integrades	31
3.3.4	Tractament de variables temporals	33
3.4	Harmonització geoespacial de les capes	33
3.4.1	Retall espacial i adaptació a l'AOI	34
3.4.2	Reprojecció al sistema de referència comú	34
3.4.3	Remostreig segons la semàntica de variable	35
3.4.4	Gestió de valors absents i màscares	37
3.5	Construcció de variables derivades	37
3.6	Organització del <i>dataset</i> final	40
3.6.1	Estructura de sortida i productes generats	40
3.6.2	Metadades, <i>manifest</i> i nomenclatura	40
3.7	Control de qualitat	41
3.7.1	Comprovacions geomètriques	41
3.7.2	Comprovacions estadístiques	41
3.7.3	Inspecció visual i coherència espacial	42
3.8	Síntesi tècnica del procés de generació	42
4	Cas d'ús: modelització ecològica de l'ós bru als Pirineus	44
4.1	Objectiu del cas d'ús	44
4.2	Context ecològic i referència metodològica	45
4.3	Dades d'entrada per al model	46
4.3.1	Dades biològiques: GPS, observacions i classes de cria	47
4.3.2	Variables ambientals explicatives	49
4.3.3	Construcció de la matriu de modelització	52
4.4	Estratègia metodològica	54
4.4.1	Relació amb l'enfocament CARTOBIO/MaxEnt	54
4.4.2	Models d'aprenentatge automàtic i candidats comparats	55

4.4.3	Validació leave-one-individual-out	56
4.4.4	Calibratge, bootstrap i validació externa	57
4.4.5	Mètriques d'avaluació	57
4.5	Resultats del model	59
4.5.1	Rendiment predictiu i selecció de models	59
4.5.2	Interpretació de les variables importants	61
4.5.3	Mapes d'idoneïtat i classificació de zones	63
4.5.4	Validació externa amb observacions independents	64
4.5.5	Comparació amb CARTOBIO/MaxEnt	65
4.6	Síntesi del cas d'ús	66
5	Conclusions i treball futur	67
5.1	Síntesi del treball desenvolupat	67
5.2	Grau d'assoliment dels objectius	67
5.3	Aportacions de pirineus-raster	69
5.4	Conclusions sobre el cas de l'ós bru	69
5.5	Impacte potencial en recerca i conservació	70
5.6	Limitacions del treball	71
5.7	Línies futures	72
5.7.1	Ampliació de fonts i variables ambientals	72
5.7.2	Nous casos d'ús ecològics	72
5.7.3	Millores tècniques i operatives	73
5.8	Valoració final	74
	Bibliografia	75
A	Planificació i metodologia de treball	78
A.1	Fases del projecte	78
A.2	Seguiment i iteracions	79
A.3	Riscos identificats	79
B	Viabilitat, manteniment i escalabilitat	81
B.1	Recursos utilitzats	81
B.2	Cost aproximat del projecte	81
B.3	Manteniment de fonts i connectors	82
B.4	Viabilitat de continuïtat	82
B.5	Escalabilitat territorial i computacional	83
C	Aspectes ètics, socials i ambientals	84
C.1	Impacte científic i social	84
C.2	Contribució a la conservació de la biodiversitat	84
C.3	Sostenibilitat i Objectius de Desenvolupament Sostenible	85
C.4	Riscos, biaixos i ús responsable de les dades	85
D	Ús d'eines d'intel·ligència artificial	87
D.1	Tasques assistides per IA	87
D.2	Criteris de supervisió i validació humana	87

D.3 Limitacions de l'assistència amb IA	88
E Mapes finals del cas d'ús de l'ós bru	89
F Instruccions de reproductibilitat	92
F.1 Requisits de l'entorn	92
F.2 Estructura de configuracions	93
F.3 Validació i renderització de configuracions	93
F.4 Creació de la graella de referència	94
F.5 Execució del <i>pipeline</i>	94
F.6 Validació de resultats	95
F.7 Interfície visual de configuració	95
F.8 Execució en HPC/SLURM	96

Índex de figures

2.1	Arquitectura general de pirineus-raster	16
2.2	Flux de validació, compilació i execució d'un <i>run config</i>	17
2.3	Pantalla inicial del <i>workbench</i> de pirineus-raster	21
2.4	Creació assistida d'una àrea d'interès i de la graella de referència.	21
2.5	Construcció assistida d'una variable del <i>feature builder</i> de la UI.	22
2.6	Revisió d'una configuració de <i>run</i> des de la UI.	22
3.1	Extensió de l'AOI aplicada al cas d'ús de l'ós bru (en verd).	29
3.2	Flux general d'harmonització geoespacial d'una font fins a obtenir una capa final preparada per a l'anàlisi.	34
4.1	Distribució estacional dels registres GPS retinguts per classe de cria.	49
4.2	Cel·les de 100 m ocupades per les femelles monitoritzades, separades per classe de cria.	49
4.3	Correlació de predictors en les presències de les dues classes de cria.	52
4.4	AOI completa, domini local accessible, presències GPS i punts de <i>background</i>	54
4.5	Importància per permutació fora de mostra per a les dues classes de cria.	62
4.6	Mapes finals d'idoneïtat, zones categòriques i incertesa relativa per a 1t6 i 6to12	63
E.1	Mapa d'idoneïtat relativa per a la classe 1t6 en EPSG:3035.	89
E.2	Mapa d'idoneïtat relativa per a la classe 6to12 en EPSG:3035.	89
E.3	Mapa de zones categòriques per a la classe 1t6 en EPSG:3035.	90
E.4	Mapa de zones categòriques per a la classe 6to12 en EPSG:3035.	90
E.5	Mapa d'incertesa relativa per a la classe 1t6 en EPSG:3035.	91
E.6	Mapa d'incertesa relativa per a la classe 6to12 en EPSG:3035.	91

Índex de taules

2.1	Requisits funcionals i no funcionals de pirineus-raster	10
3.1	Fonts ambientals integrades al catàleg de pirineus-raster	32
3.2	Modes temporals principals usats en la construcció de variables.	33
3.3	Tipus de value_semantics i criteris de remostreig.	36
3.4	Famílies principals de variables derivades suportades per pirineus-raster	38
3.5	Resum tècnic de la <i>run</i> principal del <i>dataset</i> de l'ós bru.	41
4.1	Dades biològiques utilitzades en el cas d'ús després del tractament inicial.	48
4.2	Variables explicatives finals utilitzades en la modelització.	51
4.3	Àmbits espacials utilitzats per generar els punts de <i>background</i>	53
4.4	Mida de les taules finals de modelització per classe de cria.	54
4.5	Rendiment dels models finals sota validació <i>leave-one-individual-out</i>	59
4.6	Principals predictors segons importància per permutació fora de mostra.	62
4.7	Auditoria externa amb observacions independents OBS	64
4.8	Comparació sintètica entre el plantejament CARTOBIO i el cas d'ús d'aquest treball.	65

Acrònims i notació

Aquest apartat recull els acrònims, abreviatures i termes tècnics que apareixen de manera recurrent al llarg de la memòria. En alguns casos s’hi manté el terme anglès perquè és la forma habitual en la documentació tècnica o científica. En altres casos s'utilitza també l'equivalent català quan ajuda a fer el text més natural. Així, expressions com *dataset* i col·lecció de dades, *pipeline* i flux de processament, *run* i execució, o *background* i disponibilitat ambiental s'empren com a formes equivalents segons el context.

Per coherència tipogràfica, els acrònims, noms de fitxers, variables, classes, comandes i claus de configuració es mostren habitualment amb **monoespai**; els anglicismes conceptuals que es mantenen com a termes tècnics es presenten en cursiva.

Acrònim	Significat
AGB	<i>Above-Ground Biomass</i> ; biomassa aèria.
AOI	<i>Area of Interest</i> ; àrea d'interès o domini espacial sobre el qual s'executa una configuració.
API	<i>Application Programming Interface</i> ; interfície de programació usada per accedir a serveis o catàlegs de dades.
ARD	<i>Analysis-Ready Data</i> ; dades preparades per ser utilitzades directament en anàlisi espacial o modelització.
AUC-PR	<i>Area Under the Precision-Recall Curve</i> ; mètrica basada en precisió i <i>recall</i> , útil en problemes de presència/ <i>background</i> .
AUC-ROC	<i>Area Under the Receiver Operating Characteristic Curve</i> ; mètrica de discriminació que avalua la capacitat d'ordenar presències per sobre del <i>background</i> .
BRGM	<i>Bureau de Recherches Géologiques et Minières</i> ; organisme geològic francès.
CARTOBIO	Cartografia o modelització de referència utilitzada com a marc comparatiu en el cas d'ús de l'ós bru.
CCI	<i>Climate Change Initiative</i> ; iniciativa de l'Agència Espacial Europea, emprada en productes com ESA CCI Biomass.
CLC	<i>Corine Land Cover</i> ; cartografia europea de coberta del sòl.
CLI	<i>Command-Line Interface</i> ; interfície de línia de comandes de pirineus-raster .
CLMS	<i>Copernicus Land Monitoring Service</i> ; servei de monitoratge terrestre de Copernicus.
CPU	<i>Central Processing Unit</i> ; processador principal d'un equip de càlcul.
CRS	<i>Coordinate Reference System</i> ; sistema de referència de coordenades.
CRU TS	<i>Climatic Research Unit Time-Series</i> ; sèrie climàtica històrica utilitzada en productes WorldClim/CRU.
CSL	Clúster de càlcul de la UPC utilitzat durant part del desenvolupament i execució del projecte.
DEM	<i>Digital Elevation Model</i> ; model digital d'elevacions.
EPSG	Catàleg d'identificadors de sistemes de referència de coordenades, com EPSG:3035.
ESA	<i>European Space Agency</i> ; Agència Espacial Europea.
FSC	<i>Fractional Snow Cover</i> ; fracció o percentatge de cobertura de neu.
GCM	<i>Global Climate Model</i> ; model climàtic global utilitzat en escenaris climàtics.
GDAL	<i>Geospatial Data Abstraction Library</i> ; biblioteca fonamental per llegir, escriure i transformar dades geoespaciales.
GDD	<i>Growing Degree Days</i> ; graus-dia de creixement.
GeoTIFF	Format raster geoespacial basat en TIFF amb informació de georeferenciació.

Acrònim	Significat (continuació)
GHSL	<i>Global Human Settlement Layer</i> ; capes globals de població, assentaments i urbanització.
GIS / SIG	<i>Geographic Information System</i> ; sistema d'informació geogràfica.
GPS	<i>Global Positioning System</i> ; sistema de posicionament global utilitzat en les localitzacions de telemetria.
HDA	<i>Harmonised Data Access</i> ; servei d'accés a dades emprat en alguns productes Copernicus via WEkEO.
HPC	<i>High-Performance Computing</i> ; computació d'altres prestacions.
HR-VPP	<i>High Resolution Vegetation Phenology and Productivity</i> ; productes Copernicus de fenologia i productivitat de la vegetació.
HRSI	<i>High Resolution Snow and Ice</i> ; productes Copernicus de neu i gel.
HTML	<i>HyperText Markup Language</i> ; format de document web.
IA	Intel·ligència artificial.
IGME	Instituto Geológico y Minero de España.
JSON	<i>JavaScript Object Notation</i> ; format lleuger d'intercanvi de dades, usat per metadades i manifests.
LOIO	<i>Leave-One-Individual-Out</i> ; estratègia de validació que deixa fora un individu complet en cada partició.
MaxEnt	<i>Maximum Entropy</i> ; aproximació clàssica per modelitzar idoneïtat d'hàbitat amb dades de presència i <i>background</i> .
NoData	Valor o màscara que identifica píxels sense dada vàlida en un raster.
OBS	Observacions independents reservades per a l'auditoria externa del cas d'ús.
ODS	Objectius de Desenvolupament Sostenible.
OSM	OpenStreetMap; font oberta de dades geoespacionals vectorials.
PDCA	Productes o dades de topoclima emprats com a font ambiental pirinenca.
PDF	<i>Portable Document Format</i> ; format de document final o de report.
PET	<i>Potential Evapotranspiration</i> ; evapotranspiració potencial.
PROJ	Biblioteca de transformació de coordenades geoespacionals.
PyPI	<i>Python Package Index</i> ; repositori de paquets Python.
QGIS	Programari SIG lliure utilitzat per inspecció visual i elaboració de mapes.
RAM	<i>Random Access Memory</i> ; memòria principal de l'equip.
RF	<i>Random Forest</i> ; algorisme d'aprenentatge automàtic basat en conjunts d'arbres de decisió.
SDM	<i>Species Distribution Modelling</i> ; modelització de distribució d'espècies o d'idoneïtat d'hàbitat.
SLURM	Gestor de cues i recursos habitual en entorns HPC.
SSD	<i>Solid-State Drive</i> ; unitat d'emmagatzematge d'estat sòlid.
SSP	<i>Shared Socioeconomic Pathway</i> ; escenari socioeconòmic utilitzat en projeccions climàtiques.
TP, FP, TN, FN	Veritables positius, falsos positius, veritables negatius i falsos negatius, emprats en mètriques de classificació.
TPI	<i>Topographic Position Index</i> ; índex de posició topogràfica.
TSS	<i>True Skill Statistic</i> ; mètrica basada en sensibilitat i especificitat.
UI	<i>User Interface</i> ; interfície visual d'usuari.
UPC	Universitat Politècnica de Catalunya.
URL	<i>Uniform Resource Locator</i> ; adreça web d'un recurs.
WEkEO	Plataforma d'accés a dades Copernicus.
XGBoost / XGB	<i>Extreme Gradient Boosting</i> ; algorisme d'aprenentatge automàtic basat en arbres de decisió potencials.
YAML	<i>YAML Ain't Markup Language</i> ; format de configuració llegible per humans.

Terme	Ús en aquesta memòria
<i>background</i>	Conjunt de punts que representen la disponibilitat ambiental del domini d'estudi en models de presència/ <i>background</i> . No equival a absències verificades.
<i>build</i>	Etapla de la <i>pipeline</i> que construeix les capes finals harmonitzades a partir de fonts preparades.
<i>clip</i>	Etapla de retall espacial de les fonts al domini requerit per l'execució.
<i>dataset</i> / col · lecció de dades	Conjunt organitzat de capes raster i fitxers auxiliars. S'utilitza també l'expressió col · lecció de dades quan el context demana una formulació més natural en català.
<i>download</i>	Etapla que descarrega o localitza les dades originals necessàries.
<i>feature</i>	Variable final o derivada que l'usuari vol obtenir en una <i>run</i> .
<i>log</i>	Registre textual d'execució. En plural, <i>logs</i> .
<i>manifest</i>	Fitxer estructurat que resumeix els productes generats i les seves metadades principals.
<i>notebook</i>	Document executable utilitzat per anàlisi, inspecció o modelització, habitualment en entorns Python/Jupyter.
<i>pipeline</i> / flux de processament	Cadena ordenada d'etapes que converteix fonts originals en productes finals. Es manté <i>pipeline</i> quan es fa referència al component tècnic de l'eina.
<i>raster</i>	Format de dades espacials basat en una matriu regular de cel · les o píxels.
<i>run</i> / execució	Configuració concreta que defineix una AOI, resolució, fonts, variables i sortides. També pot designar l'execució efectiva d'aquesta configuració.
<i>workbench</i>	Interfície visual de suport per crear, revisar i validar configuracions de pirineus-raster .

Capítol 1

Introducció

1.1 Context i motivació

La motivació d'aquest treball té una arrel personal. Soc del Pallars i he crescut en un territori on la muntanya no és només un paisatge de fons, sinó una manera concreta d'entendre el món, les distàncies, les estacions i la relació entre les persones i el medi. Des de petit he viscut de prop els espais naturals protegits, en part pel vincle professional del meu pare amb aquest àmbit, i també per una experiència quotidiana feta d'excursions, camins, boscos, rius, fauna i cims. Aquesta proximitat amb l'Alt Pirineu m'ha fet entendre que la conservació de la natura no és una idea abstracta, sinó una responsabilitat situada en llocs concrets, amb espècies concretes, hàbitats fràgils i decisions de gestió que tenen conseqüències reals sobre el territori.

Aquest vincle amb la muntanya també ha anat lligat a una manera determinada de mirar el territori. Quan un ha crescut envoltat de relleus abruptes, de valls amb identitats pròpies i de paisatges que canvien de forma radical amb l'altitud i amb l'estació, és difícil entendre el medi com una simple suma de capes o com un espai neutre sobre el qual aplicar mètodes. El Pirineu és, alhora, un sistema ecològic complex i un espai viscut, on la presència d'espècies amenaçades, la continuïtat dels hàbitats, la pressió humana, l'abandonament d'alguns usos tradicionals i la necessitat de conservar sense desvincular-se del territori formen part d'una mateixa realitat. Aquesta experiència personal no substitueix el rigor tècnic, però sí que explica la voluntat que aquest TFG tingués sentit més enllà de l'exercici acadèmic.

Des d'aquest punt de partida, la intenció inicial era desenvolupar un projecte arrelat al Pirineu i amb una utilitat pràctica clara. No es tractava només d'aplicar tècniques de ciència de dades a un conjunt d'informació qualsevol, sinó de treballar sobre un problema proper, territorialment rellevant i potencialment útil per a la recerca i la conservació. En aquest context va aparèixer la possibilitat de treballar amb dades de l'ós bru (*Ursus arctos*) als Pirineus, una espècie protegida i en estat crític de conservació a la serralada, per a la qual el coneixement espacial dels hàbitats utilitzats per les femelles amb cries és especialment rellevant. La idea inicial s'orientava, per tant, cap a la modelització d'idoneïtat d'hàbitat i cap a la producció de mapes que poguessin ajudar a entendre millor quines zones presenten condicions ambientals favorables per a aquest segment tan sensible de la població.

Tanmateix, a mesura que el projecte avançava, es va fer evident que abans d'arribar al model ecològic hi havia un problema previ molt més ampli. Les dades ambientals necessàries per estudiar una espècie com l'ós bru existeixen, però arriben disperses, en formats diferents, amb resolucions diferents, amb sistemes de referència diferents i amb lògiques de descàrrega i documentació sovint incompatibles. Aquesta constatació no va sorgir només de la literatura o del treball tècnic, sinó

també de les converses amb persones vinculades a la gestió i a l'anàlisi ambiental, que coincidien en una mateixa dificultat recurrent. Abans de poder respondre una pregunta ecològica, cal invertir una gran quantitat d'hores a localitzar fonts, entendre'n les limitacions, descarregar-les, retallar-les, reprojectar-les, remostrejar-les i comprovar que realment es poden combinar.

Aquesta dificultat resulta encara més evident quan el domini d'estudi és el conjunt dels Pirineus. La serralada és una unitat ecològica contínua, però administrativament fragmentada entre França, Andorra i Espanya, i fins i tot dins de cada estat les dades disponibles responen sovint a divisions territorials pròpies, amb productes específics per a Catalunya, Aragó, Navarra o diferents àmbits francesos. Les dinàmiques naturals no segueixen aquestes fronteres, però les dades, les competències i els sistemes d'informació sí que ho fan. En conseqüència, qualsevol estudi ecològic o territorial que vulgui treballar a escala pirinenca es veu obligat a superar una primera barrera d'harmonització que no aporta coneixement científic per si mateixa, però que condiciona de manera decisiva la qualitat de tota l'anàlisi posterior.

Aquesta paradoxa és una de les idees centrals del treball. En un moment en què mai no hi havia hagut tantes dades ambientals disponibles, el problema ja no és només l'escassetat d'informació, sinó la dificultat de convertir aquesta abundància en una base coherent i utilitzable. Fonts públiques d'abast europeu o global generen periòdicament capes d'elevació, coberta del sòl, fenologia vegetal, neu, pressió demogràfica i condicions climàtiques, amb resolucions que poden arribar als deu metres i amb cobertures temporals de dècades. Aquest volum de dades ha obert la porta a estudis que fins fa poc eren difícils d'abordar, com la modelització de la distribució potencial d'espècies amenaçades, la identificació de corredors ecològics, l'avaluació de vulnerabilitat territorial o l'anàlisi dels efectes del canvi climàtic sobre la biodiversitat. Amb tot, disposar de moltes dades no equival a disposar d'un *dataset* ambiental realment utilitzable.

És precisament aquí on el projecte canvia d'escala. Allò que al principi podia semblar una feina prèvia al cas de l'ós bru es converteix en el nucli del TFG, ja que la necessitat d'harmonitzar dades no és exclusiva d'aquest cas d'ús, sinó una dificultat compartida per molts projectes ambientals. Si cada estudi ha de tornar a resoldre manualment la mateixa cadena de problemes, una part molt significativa del temps de recerca es perd abans d'arribar a la pregunta científica que realment es vol respondre. Per això, en lloc de construir només un *dataset* puntual per a un model concret, el treball deriva cap al desenvolupament d'una infraestructura capaç de transformar fonts ambientals heterogènies en col·leccions de dades raster harmonitzades, documentades i preparades per a l'anàlisi.

Aquesta infraestructura és **pirineus-raster**, una eina configurable i reproduïble que permet declarar una àrea d'interès, una resolució i un conjunt de variables ambientals, i que s'encarrega de construir les capes finals sobre una graella comuna. El valor de l'eina no rau únicament en les capes que produeix per a aquest cas d'ús, sinó en la capacitat de regenerar-les, adaptar-les i ampliar-les per a altres preguntes ecològiques o territorials dins del domini pirinenc. D'aquesta manera, les hores que en un projecte convencional quedarien absorbides per operacions manuals i repetitives es converteixen en una arquitectura reutilitzable, traçable i extensible.

El cas de l'ós bru es manté, per tant, com a validació aplicada del sistema. Modelitzar la idoneïtat d'hàbitat de femelles amb cries continua sent una motivació central, ja que exigeix variables de naturalesa molt diversa i obliga a comprovar si les dades generades són prou coherents per

alimentar un flux complet de modelització ecològica. Alhora, aquest cas d'ús dona sentit pràctic a l'eina, perquè connecta la infraestructura tècnica amb una pregunta de conservació real. Així, el treball parteix d'una inquietud personal i territorial, travessa una dificultat metodològica general i acaba proposant una eina que vol facilitar que altres anàlisis ambientals al Pirineu puguin començar més a prop de la pregunta científica i menys atrapades en la preparació prèvia de les dades.

1.2 Plantejament del problema

El problema central del treball és que les fonts d'informació ambiental i geoespacial disponibles avui dia, malgrat ser nombroses i sovint d'accés obert, no estan preparades per ser combinades directament. Cada font reflecteix les decisions de disseny del seu proveïdor, com ara el sistema de coordenades natiu, la resolució espacial, l'estructura de fitxers, la convenció de **NoData**, el mecanisme de distribució i els estàndards de metadades. Quan un investigador vol construir un conjunt de predictors ambientals per alimentar un model o una anàlisi, és ell qui ha d'assumir la tasca de fer compatibles totes aquestes peces.

1.2.1 Heterogeneïtat de les fonts geoespacials

L'heterogeneïtat de les fonts geoespacials es manifesta en múltiples dimensions alhora. El sistema de referència de coordenades pot ser geogràfic o projectat, i les projeccions disponibles s'expressen en unitats i orígens incompatibles. La resolució espacial pot variar de deu metres a diverses desenes de quilòmetres. L'extensió pot anar de productes globals a productes d'abast continental, regional o local. L'estructura temporal pot ser estàtica, mensual, estacional, anual o organitzada com una sèrie contínua. El format del fitxer pot correspondre a estàndards raster, vectorials o multidimensionals com **GeoTIFF**, **NetCDF**, **Shapefile** o **GeoJSON**. També les convencions per codificar valors absents poden variar de manera substancial, ja sigui mitjançant valors numèrics específics, màscares internes o absència de píxel.

A aquestes diferències formals s'hi afegeix la diversitat semàntica. Una capa categòrica de coberta del sòl no es pot tractar igual que una variable de temperatura, i una variable extensiva com la població no s'ha de remostrear de la mateixa manera que una fracció de cobertura. L'orientació topogràfica, per exemple, és una variable circular en què 359 graus i 1 grau són valors veïns, de manera que una interpolació lineal ingènua pot introduir artefactes sense cap advertència visible. Aquestes diferències no es poden resoldre amb un únic algorisme genèric, ja que exigeixen tractar cada variable amb consciència del que representa.

Els mecanismes de descàrrega i actualització també dificulten l'automatització. Algunes fonts estan disponibles mitjançant **URL** directa o **API** estandarditzada, mentre que d'altres requereixen credencials, portals específics, serveis externs o descàrrega manual prèvia. Algunes publiquen noves versions periòdicament i poden modificar l'estructura de fitxers o els noms de variables, mentre que d'altres mantenen versions estàtiques de referència. Sense una capa d'abstracció que encapsuli aquestes particularitats, qualsevol flux d'integració esdevé fràgil i difícil de mantenir.

1.2.2 Necessitat de dades preparades per a l'anàlisi

El concepte de dades preparades per a l'anàlisi, sovint designat amb l'acrònim **ARD** (*analysis-ready data*), descriu productes que poden ser consumits directament per una anàlisi o un model sense requerir preprocessament addicional. En el context d'aquest projecte, una capa es considera preparada per a l'anàlisi quan comparteix amb la resta del *dataset* un mateix sistema de referència de coordenades, una mateixa extensió, una mateixa resolució, un mateix *transform affine*, unes mateixes dimensions de matriu i una gestió coherent i documentada del valor **NoData**.

La preparació, però, no és només geomètrica. Una capa **ARD**, en el sentit d'aquest treball, ha de tenir un nom que permeti identificar-ne la naturalesa sense obrir el fitxer, metadades que n'expliquin l'origen i el tractament aplicat, i valors que reflecteixin correctament la semàntica de la variable. Això implica evitar factors d'escala pendents d'aplicar, categories mal codificades, valors fora de rang o artefactes de remostreig que alterin el significat de les dades. Tot plegat ha d'estar documentat de manera suficient per poder auditar-ne la generació i reproduir-la.

Quan es disposa de capes que compleixen aquests criteris, el treball posterior es simplifica de manera substancial. Els predictors es poden apilar, filtrar i consultar directament des d'un *notebook* o un flux de modelització sense operacions manuals intermèdies. Les comparacions entre variables són vàlides perquè les capes estan referenciades al mateix marc espacial. Els resultats, a més, es poden reproduir, revisar i estendre de manera independent. Sense aquesta base, cada nova anàlisi es converteix en una nova ronda d'harmonització, amb els riscos d'error i el cost de temps que això comporta.

1.3 Objectius del treball

1.3.1 Objectiu general

L'objectiu general del treball és desenvolupar i analitzar **pirineus-raster**, una eina configurable, reproduïble i extensible per generar *datasets* raster ambientals harmonitzats als Pirineus i facilitar-ne l'ús en aplicacions d'anàlisi espacial i modelització ecològica.

1.3.2 Objectius específics

1. Dissenyar i implementar una arquitectura reproduïble i configurable per al processament de capes raster ambientals.
2. Integrar fonts geoespacialment heterogènies en una graella comuna, harmonitzant **CRS**, extensió, resolució, **NoData**, format i nomenclatura.
3. Permetre la definició de *datasets* mitjançant configuracions d'alt nivell basades en *features*, fonts, variables, temporalitat i operacions derivades.
4. Generar productes raster *analysis-ready*, traçables i adequats per a anàlisi espacial i modelització ecològica.
5. Validar la utilitat de l'eina mitjançant un cas d'ús de modelització d'idoneïtat d'hàbitat de

femelles d'ós bru amb cries als Pirineus.

6. Comparar els resultats del cas d'ús amb models o cartografies de referència existents, especialment CARTOBIO/MaxEnt, per valorar-ne la coherència espacial.
7. Documentar les decisions tècniques, les limitacions, les instruccions de reproductibilitat i les possibilitats d'extensió.

1.4 Abast i delimitació del treball

El nucli d'aquest treball és el desenvolupament de **pirineus-raster** com a infraestructura per a la generació de *datasets* raster ambientals harmonitzats. Això inclou el disseny de l'arquitectura i del model de configuració, la integració de les fonts ambientals del catàleg, el motor de variables derivades, la interfície visual de configuració, el sistema de validació i metadades, i la *pipeline* d'execució reproduïble per CLI. Tot plegat es documenta, es valida i s'acompanya d'instruccions de reproductibilitat.

El cas d'ús de modelització ecològica de femelles d'ós bru amb cries als Pirineus forma part del treball com a validació aplicada, no com a objectiu principal en si mateix. Aquest cas demostra que l'eina **pirineus-raster** pot sostenir un flux complet de *Species Distribution Modelling*, des de la generació dels predictors fins a la producció de mapes d'idoneïtat, classificació de zones i auditoria externa amb observacions independents. No pretén, en canvi, substituir la cartografia experta d'hàbitat de l'espècie ni les decisions de gestió o conservació que se'n puguin derivar. Els resultats s'han d'interpretar en clau de validació de la infraestructura i d'exploració metodològica complementària a treballs de referència com CARTOBIO/MaxEnt.

Pel que fa als límits territorials, **pirineus-raster** ha estat dissenyat i validat per treballar dins del domini pirinenc. Les fonts integrades al catàleg cobreixen aquest àmbit, i l'ús de l'eina fora dels Pirineus pot comportar buits de cobertura o comportaments no verificats. Aquesta restricció és un límit assumit de la versió actual, no un impediment estructural, ja que l'arquitectura admet en principi dominis territorials diferents, però les fonts s'han seleccionat i configurat per al Pirineu.

Queden fora de l'abast d'aquest treball la integració de fonts que requereixen llicències comercials, el desenvolupament d'una interfície de visualització de resultats, la publicació automàtica de *datasets* a repositoris externs i l'extensió del cas d'ús a altres espècies o grups taxonòmics. Totes aquestes possibilitats s'identifiquen com a línies futures en el capítol de conclusions.

1.5 Treball previ i fonaments conceptuals

pirineus-raster és una proposta independent de l'autor. No continua directament cap projecte previ del director, del grup ni del departament, tot i que s'emmarca en una línia d'interès per la modelització ambiental i ecològica del Pirineu. El cas d'ús de l'ós bru es basa en dades biològiques i cartografies de referència prèvies, en particular el treball CARTOBIO [1] i treballs relacionats sobre períodes crítics de supervivència de les cries [2], que s'utilitzen com a marc conceptual i comparatiu però no com a punt de partida de codi ni de configuració.

1.5.1 Dades raster ambientals

Una capa raster és una representació espacial del territori basada en una matriu regular de cel·les o píxels, cadascun dels quals emmagatzema el valor d'una variable en una porció del terreny. A diferència de les representacions vectorials, que descriuen elements geomètrics discrets com punts, línies o polígons, el format raster és especialment adequat per representar fenòmens continus en l'espai, com temperatures, altures, fraccions de cobertura, distàncies o índexs de vegetació.

Les propietats que defineixen una capa raster van més enllà del seu contingut. El sistema de referència de coordenades (CRS) estableix en quin espai geogràfic o projectat se situen els píxels. L'extensió i les dimensions de la matriu determinen quina porció del territori cobreix la capa i amb quants píxels. La resolució espacial indica la mida real de cada píxel al terreny, habitualment en metres quan s'utilitza una projecció mètrica. El *transform affine* és la funció matemàtica que relaciona les coordenades de fila i columna amb les coordenades reals del terreny, de manera que dues capes amb la mateixa resolució nominal però amb *transforms* lleugerament desalineats no es poden combinar cel·la a cel·la sense un remostreig previ. Finalment, el valor *NoData* identifica els píxels sense informació vàlida i cal que sigui coherent entre totes les capes del *dataset*.

A aquestes propietats formals s'hi afegeix la semàntica de la variable. Una capa pot representar una temperatura (variable intensiva), un recompte de població (variable extensiva), una classe de coberta del sòl (variable categòrica), una fracció de cobertura (percentatge), una orientació topogràfica (variable circular) o una presència binària (variable dicotòmica). Aquesta semàntica no és decorativa, ja que condiciona directament com s'ha d'aplicar el remostreig quan la capa es reprojecta o s'adapta a una resolució diferent. Ignorar-la pot produir resultats formalment vàlids però ecològicament incorrectes.

1.5.2 Processament geoespacial reproducible

La reproductibilitat és un requisit fonamental en la recerca científica basada en dades. En el context geoespacial, un flux de treball és reproducible si, a partir del mateix codi, les mateixes configuracions i les mateixes dades d'entrada, genera els mateixos productes finals. Assolir aquest objectiu és més difícil del que sembla quan intervenen fonts diverses, processos multi-etapa, decisions de parametrització i entorns computacionals variables.

La clau per a la reproductibilitat geoespacial és la separació entre el codi que implementa la lògica de processament, les configuracions que descriuen l'experiment concret (AOI, resolució, fonts, variables i opcions temporals), i les dades d'entrada i els productes resultants. Quan aquesta separació és explícita, modificar un experiment equival a canviar una configuració i no a reescriure codi. De la mateixa manera, repetir un experiment equival a tornar a executar el flux amb la mateixa configuració, de manera que el resultat esdevé verificable i comparable.

A la reproductibilitat s'hi associa la traçabilitat, entesa com la capacitat de relacionar cada producte final amb la font original, el tractament aplicat i els paràmetres de l'execució. En un *dataset* ambiental, la traçabilitat és especialment important perquè la interpretació d'un predictor depèn de com ha estat generat. Si una variable apareix com a rellevant en un model ecològic, cal

poder saber si prové d'una temperatura mitjana mensual o anual, si s'ha remostrejat per veí més proper o per interpolació bilineal, i si s'ha aplicat un factor d'escala o una transformació logarítmica.

1.5.3 Modelització ecològica d'idoneïtat d'hàbitat

La modelització de distribució d'espècies (SDM, de l'anglès *Species Distribution Modelling*) és un conjunt de tècniques que busquen descriure la relació entre les condicions ambientals d'un territori i la presència o l'ús que en fa una espècie determinada [3]. El producte típic és un mapa d'idoneïtat que ordena el territori segons la seva semblança ambiental amb les localitzacions on l'espècie ha estat observada.

Quan les dades disponibles són únicament localitzacions de presència, sense absències verificades, el problema es formula habitualment com una comparació entre les condicions ambientals en punts de presència i les condicions en punts de *background*, que representen la disponibilitat ambiental del domini d'estudi. En aquest marc, la sortida del model no s'interpreta com una probabilitat absoluta d'ocurrència, sinó com un índex d'idoneïtat relativa, és a dir, un valor que ordena el territori però que depèn de les decisions adoptades sobre el domini de *background*, els predictors i l'algorisme.

El disseny de la validació és especialment crític en SDM. Quan les dades de presència presenten autocorrelació espacial o provenen d'un nombre reduït d'individus monitoritzats, una partició aleatòria entre entrenament i test pot produir mètriques optimistes que no reflecteixen la capacitat real de generalització del model. Estratègies com la validació per individu (*leave-one-individual-out*) o la validació espacial bloquejada resulten més prudents, perquè eviten que el model es validi sobre punts estructuralment similars als que ha vist durant l'entrenament [3].

El paper dels *datasets* raster en SDM és central, ja que les capes ambientals actuen com a predictors que descriuen les condicions de cada cel·la del territori. La qualitat d'aquestes capes, la seva coherència geomètrica, la seva semàntica i el seu nivell de detall condicionen directament la qualitat i la interpretabilitat del model resultant. Un *dataset* harmonitzat i ben documentat no garanteix per si sol un bon model, però elimina una font important de variabilitat i error que sovint passa inadvertida.

1.6 Contribucions principals

Les contribucions d'aquest treball s'organitzen en dos plans complementaris, que són el desenvolupament de la infraestructura **pirineus-raster** i la validació aplicada d'aquesta infraestructura en un cas d'ús ecològic realista.

Pel que fa a la infraestructura, **pirineus-raster** aporta una eina de línia de comandes (CLI) que permet executar, validar i inspeccionar la *pipeline* de manera reproduïble, tant en entorns locals com en clústers HPC amb SLURM. L'arquitectura separa explícitament codi, configuració i dades, de manera que les configuracions YAML defineixen l'AQI, les fonts, les variables i les sortides de cada execució, mentre que el codi implementa una lògica estable i reutilitzable que les interpreta.

A més, un compilador de configuracions transforma definicions d'alt nivell orientades a *features* finals en plans d'execució concrets, resol dependències entre variables i ordena les operacions necessàries per construir el *dataset* final.

El sistema també integra un catàleg de 23 configuracions de productes ambientals de proveïdors diversos, encapsula les particularitats de cada font i permet reutilitzar-les en múltiples *datasets*. El motor de variables derivades suporta expressions algebraiques segures, receptes guiades, derivades topogràfiques, estadístics focals, distàncies a màscares i reclassificacions, la qual cosa permet definir predictors directament en termes ecològics. El tractament semàntic del remostreig diferencia categories, variables intensives, variables extensives, fraccions, percentatges i variables circulars, aplicant el criteri metodològicament adequat en cada cas. Finalment, el *workbench* visual desenvolupat en React assisteix en la creació d'AQIs, la revisió de fonts i la construcció de configuracions de *run*, mentre que les metadades per capa, els *manifests*, les còpies de configuració i els *logs* d'execució garanteixen la traçabilitat dels productes generats.

Pel que fa al cas d'ús, la contribució principal és haver completat un flux de modelització ecològica sobre el *dataset* generat. S'ha construït una matriu de modelització a partir de les 41 capes ambientals produïdes per **pirineus-raster**, s'han comparat Random Forest i XGBoost amb combinacions ponderades i validació *leave-one-individual-out* (LOIO), s'han generat mapes continus d'idoneïtat relativa, zones categòriques i superfícies d'incertesa, i s'ha dut a terme una auditoria externa amb observacions independents que no han participat en cap fase de l'entrenament ni de la selecció de models. La comparació amb les mètriques reportades per CARTOBIO/MaxEnt en condicions comparables permet valorar la coherència dels resultats i aporta una perspectiva complementària a la cartografia de referència existent.

1.7 Estructura de la memòria

La resta de la memòria s'organitza de manera progressiva. El capítol 2 descriu l'arquitectura de **pirineus-raster**, l'organització del repositori, el model de configuració i les decisions de disseny que permeten convertir el problema plantejat en una eina reutilitzable. El capítol 3 detalla el flux metodològic que transforma fonts geoespacials heterogènies en *datasets* raster coherents i preparats per a l'anàlisi. El capítol 4 presenta el cas d'ús de modelització ecològica de femelles d'ós bru amb cries als Pirineus, utilitzat per validar la utilitat de les dades generades. Finalment, el capítol 5 recull les conclusions, les limitacions i les línies futures del projecte.

Disseny del sistema i arquitectura de `pirineus-raster`

El desenvolupament de `pirineus-raster` sorgeix de la necessitat de tractar l'heterogeneïtat de les fonts geoespacionals ambientals per construir *datasets raster* homogenis, comparables i directament utilitzables en anàlisi espacial i modelització ecològica. Per assolir l'objectiu plantejat, aquest projecte no s'ha concebut com una mera col·lecció de capes precomputades, sinó com una eina de processament geoespacial configurable, reproduïble i extensible. Aquesta és precisament la decisió cabdal del projecte: no es tracta només de construir un *dataset* específic, com en aquest cas el de l'ós bru, sinó de disposar de la capacitat de regenerar, adaptar i ampliar aquest tipus de *datasets* per a altres àrees d'interès, resolucions, fonts de dades i aplicacions ecològiques.

L'arquitectura de `pirineus-raster` es vertebrava al voltant de tres idees cabdals. En primer lloc, la separació entre configuració, codi i dades, que permet modificar completament l'àrea d'estudi, la resolució, el processament triat o fins i tot les variables font utilitzades sense haver de modificar cap línia de codi. En segon lloc, l'ús d'una graella de referència comuna, que garanteix que totes les capes finals comparteixin sistema de coordenades, extensió, resolució i alineació de píxels. En tercer lloc, la definició dins de l'eina de fluxos de processament que transformen variables font en variables de més alt nivell, fet que permet a l'usuari treballar amb les dades originals i obtenir col·leccions de dades finals més elaborades sense haver d'especificar manualment tots els passos interns de preprocessament, derivació i harmonització.

Aquest capítol descriu el sistema des del punt de vista arquitectònic. Primer es presenten els requisits funcionals i no funcionals que han guiat el desenvolupament. A continuació es descriu la visió general de l'arquitectura, l'organització del repositori, la parametrització del flux de treball, la interfície visual de configuració, el flux de processament i els mecanismes de traçabilitat i reutilització. L'objectiu és mostrar com les decisions de disseny responen directament al problema plantejat al capítol anterior: la dificultat d'integrar fonts geoespacionals ambientals molt diverses en un marc espacial coherent i reproduïble.

2.1 Requisits del sistema

Els requisits de `pirineus-raster` deriven directament de les dificultats associades a la construcció de *datasets raster* ambientals a partir de fonts heterogènies. Les fonts d'entrada poden diferir en format, sistema de coordenades, resolució, extensió espacial, estructura temporal, semàntica de variable, presència de valors `NoData`, mecanisme de descàrrega i grau de documentació. Per tant, el sistema ha de ser capaç de convertir aquesta diversitat inicial en productes finals homogenis,

traçables i aptes per a l'anàlisi.

Els requisits es poden dividir en dos grans grups. Els requisits funcionals defineixen què ha de fer l'eina: crear graelles, processar fonts, generar variables, validar resultats i produir *datasets* finals. Els requisits no funcionals defineixen com ho ha de fer: de manera reproducible, modular, escalable, mantenible i usable per investigadors que no necessàriament coneixen el codi intern.

Aquesta distinció és cabdal atès que el projecte no només té com a objectiu obtenir un resultat final concret, sinó construir una infraestructura reutilitzable. Un script puntual podria generar un conjunt de capes per a una àrea determinada, però no resoldria el problema de fons: la necessitat de repetir el procés amb altres fonts, altres resolucions o altres casos d'ús sense haver de redissenyar tota la cadena de processament.

Taula 2.1: Requisits funcionals i no funcionals de `pirineus-raster`.

Tipus	Requisits resumits
Funcionals	Definir AOI, CRS i resolució; crear i validar graelles de referència; automatitzar fonts heterogènies; generar variables finals d'alt nivell; validar i compilar configuracions; tractar variables derivades i temporals; validar <i>datasets</i> finals; generar sortides auditables; i facilitar l'ús mitjançant CLI i UI.
No funcionals	Reproductibilitat; modularitat; traçabilitat; escalabilitat territorial, temàtica i computacional; mantenibilitat; control de memòria i paral·lelització; separació entre codi, configuració i dades; i usabilitat per a investigadors no necessàriament experts en el codi intern.

2.1.1 Requisits funcionals

El primer requisit funcional és permetre la definició explícita d'una **àrea d'interès** (AOI), un **sistema de coordenades** de treball (CRS) i una **resolució espacial**. En un projecte geoespacial, aquests tres paràmetres condicionen tota la resta del procés. L'àrea d'interès determina quina part del territori s'analitza; el sistema de coordenades determina com es mesuren distàncies i àrees; i la resolució espacial determina el nivell de detall del *dataset* final. En el cas de `pirineus-raster`, totes aquestes decisions es defineixen en els **fitxers de configuració**, de manera que es poden adaptar sense modificar el codi.

El segon requisit és **crear, carregar i validar graelles de referència**. L'ús d'aquesta graella com a referència per a la reprojecció de totes les variables és l'element que permet una col·lecció de dades final unificada, comparable i utilitzable. Sense aquesta graella, dues capes podrien constar d'una mateixa resolució nominal però no estar realment alineades. És per aquest motiu que el sistema ha de ser capaç de generar una graella de referència amb les característiques espacials definides anteriorment i comprovar que totes les capes finals s'hi ajusten correctament.

El tercer requisit és **automatitzar la descàrrega** de les dades de les fonts originals. Algunes de les fonts permeten obtenir automàticament les dades a partir d'enllaços web, catàlegs o API; d'altres, tanmateix, requereixen credencials, descàrrega manual prèvia o fitxers locals. L'eina ha de poder treballar amb aquesta diversitat sense obligar l'usuari a fer manualment tot el preprocessament. Això implica organitzar les fonts segons proveïdor, producte i variable, i

encapsular les particularitats de cada font dins de mòduls o configuracions específiques.

El quart requisit és **construir variables finals d'alt nivell** a partir de les dades font, variables prèviament construïdes i operacions de processat. Una **variable final** està preparada per ser usada en una col·lecció de dades geoespacial *raster* i les seves aplicacions posteriors (anàlisi, modelització, construcció de mapes, etc.). Pot correspondre directament a la capa d'origen reprojectada, com una temperatura mitjana o una coberta del sòl, però també pot ser una variable derivada, com el pendent calculat a partir d'un DEM, una fracció de cobertura forestal o una transformació logarítmica d'una distància. Aquesta abstracció és important perquè aproxima el sistema a la manera com pensa l'investigador: no en termes de processos intermedis, sinó en termes de variables finals requerides per al projecte que duu a terme. En definitiva, el sistema ha de ser, des d'un inici, orientat a la variable final (*feature-oriented*).

El cinquè requisit és **validar les configuracions** abans d'executar-les i, en el cas de construcció mitjançant la UI, **renderitzar la configuració**. Aquesta validació prèvia és especialment important en un projecte amb moltes fonts i variables, perquè un error de nom, una variable inexistent o una incompatibilitat temporal podrien fer fallar el procés després d'hores de computació. La possibilitat de validar i renderitzar la configuració permet detectar errors abans de processar dades pesades, i aporta transparència sobre què s'executarà realment.

El sisè requisit és **compilar configuracions** *feature-oriented* en configuracions *run-oriented*. Les configuracions d'alt nivell poden descriure què es vol obtenir, però la *pipeline* necessita instruccions concretes: quines fonts llegir, quines variables seleccionar, quines operacions aplicar, on guardar els resultats i com validar-los. El **compilador de configuracions** fa aquesta traducció entre la definició conceptual del *dataset* i el **pla d'execució concret**. Això, d'una banda, redueix la complexitat per a l'usuari i evita haver de duplicar manualment configuracions llargues i propenses a errors; de l'altra, optimitza la manera com s'executa la *run*, per no repetir tasques que ja s'han fet o que es podrien haver resolt d'una manera més eficient.

El setè requisit és **facilitar el processat de variables derivades**. El sistema no s'ha de limitar a harmonitzar capes externes, sinó que també ha de permetre **calcular noves variables** a partir de les existents. Això inclou expressions complexes, receptes predefinides, variables topogràfiques, estadístics focals i distàncies a elements territorials, entre d'altres. Aquesta capacitat és especialment rellevant en els casos d'ús de projectes reals, ja que moltes de les variables d'interès no són capes originals sinó transformacions o derivacions. Aquest requisit ha de permetre a l'usuari crear de manera eficaç, senzilla i robusta la gran majoria de les variables objectiu per al seu projecte.

El vuitè requisit és **tractar variables temporals**. Moltes fonts ambientals no són estrictament estàtiques: poden tenir valors mensuals, estacionals, anuals o associats a períodes concrets. El sistema ha de permetre seleccionar capes temporals, agrupar-les, agregar-les o generar variables representatives d'una estació o període. Això és necessari per fonts climàtiques, ambientals, demogràfiques o altres variables amb variació temporal. En molts projectes, aquest punt és especialment cabdal perquè el valor de certes variables segons la seva temporalitat (època de l'any, període, any natural, etc.) pot ser un factor determinant.

El novè requisit és **validar els datasets finals**. La generació automàtica de capes no és suficient

si no es comprova que el resultat és coherent. Per això el sistema ha de validar la geometria, el CRS, la resolució, l'alineació, els valors `NoData`, els rangs estadístics i la coherència categòrica. Aquest **control de qualitat** permet detectar errors de projecció, problemes de cobertura, valors fora de rang, desplaçaments espacials o inconsistències entre capes.

El desè requisit és **generar sortides completes i auditable**s: formats harmonitzats `GeoTIFF`, metadades, *manifests*, *logs* i còpies de configuració. Una col·lecció de dades final no ha d'estar formada només per fitxers en format *raster* (variables finals), ans també per la informació suficient per entendre com s'han generat. Aquesta informació és essencial per a la reproductibilitat, la revisió científica i la reutilització futura.

L'onzè requisit és **facilitar la creació i revisió de les configuracions** necessàries per executar el *pipeline*. Amb aquest objectiu, `pirineus-raster` incorpora una interfície visual o *workbench* que ajuda l'usuari a construir fitxers de configuració com les àrees d'interès, les definicions de *runs* o la selecció de fonts i variables. Aquesta interfície també permet consultar projectes o configuracions prèvies, editar-les, revisar informació sobre les fonts de dades disponibles i accedir a documentació interna sobre el funcionament general de l'eina. D'aquesta manera, la UI no substitueix el sistema de configuració basat en `YAML`, però en facilita l'ús i **redueix la complexitat** d'haver d'escriure manualment configuracions llargues o amb moltes dependències.

Finalment, el dotzè requisit és **mantenir un mode d'execució robust i reproduïble mitjançant línia de comandes**. L'execució efectiva de les *runs*, la validació de configuracions, la generació de graelles, el processament de fonts i la validació dels *datasets* finals es realitzen des de la CLI, fet que facilita l'automatització, la reproducció exacta dels processos i l'execució en entorns locals o HPC. Alhora, els usuaris més avançats poden editar manualment els fitxers `YAML` de configuració i ajustar paràmetres com l'AOI, les variables, les sortides o les capacitats computacionals de la *run* segons l'ordinador o clúster on s'executi. Aquesta combinació entre UI, configuració editable i execució per terminal permet equilibrar usabilitat, control tècnic i reproductibilitat.

2.1.2 Requisits no funcionals

El primer requisit no funcional és la **reproductibilitat**. En un projecte científic basat en dades, no n'hi ha prou amb obtenir un resultat, sinó que cal poder explicar de quina manera s'ha obtingut i, si s'aplica el mateix escenari, poder repetir l'experiment amb els mateixos resultats. A `pirineus-raster`, aquesta reproductibilitat es basa en el fet que la variabilitat de cada execució queda definida principalment pels **fitxers de configuració**: la configuració del projecte, la de l'àrea d'interès, la de la *run* i les configuracions de les fonts. El codi comú del sistema actua com una base estable i reutilitzable que interpreta aquestes configuracions de manera consistent.

El segon requisit és la **modularitat**. El sistema està organitzat en components amb responsabilitats ben delimitades, de manera que cada part del codi s'encarrega d'una funció concreta i només necessita conèixer la informació estrictament necessària per dur-la a terme. Les funcions de nivell més baix concentren la lògica específica de cada operació (llegir una capa, retallar-la, reprojectar-la, remostrejar-la, validar-la o escriure-la), mentre que els components de nivell superior actuen com a orquestradors que criden aquestes operacions en l'ordre adequat sense

haver de conèixer-ne tots els detalls interns. Aquesta separació fa que el codi sigui més fàcil d'entendre, provar, corregir i mantenir, ja que un error o una millora en una operació concreta es pot localitzar i modificar sense alterar tot el flux de treball. A més, el sistema separa la lògica comuna de processament geoespacial del tractament específic que requereix cada font de dades. Això permet adaptar-se a formats, estructures temporals, mecanismes de descàrrega o metadades diferents, i facilita la incorporació de noves fonts, productes o variables afegint principalment el mòdul i la configuració corresponents, sense haver de modificar de manera substancial la part comuna del sistema.

El tercer requisit és la **traçabilitat**. A **pirineus-raster**, aquesta traçabilitat s'aconsegueix fent que cada execució quedi associada als seus fitxers de configuració, a l'estructura de sortides, als *logs* del procés i a les metadades generades per a cada producte. D'aquesta manera, una capa final no queda deslligada del procés que l'ha creada, sinó que es pot relacionar amb la font original, la variable processada, l'àrea d'interès utilitzada, la resolució final, les operacions aplicades i els paràmetres de processament. Aquesta informació permet reconstruir el camí que va des de la dada original fins al *raster* final, comprovar quines decisions tècniques s'hi han aplicat i, per tant, poder validar-ne la versemblança i el rigor.

El quart requisit és l'**escalabilitat territorial, temàtica i computacional**. Aquesta escalabilitat s'assoleix en diferents nivells del disseny de **pirineus-raster**. En l'àmbit territorial, la definició separada de les àrees d'interès i de les graelles de referència permet executar el mateix *pipeline* sobre dominis espacials diferents, des d'àrees experimentals petites fins al conjunt dels Pirineus, canviant únicament la configuració corresponent. Cal remarcar, però, que moltes de les fonts incloses estan pensades per abastar només els Pirineus; per tant, estendre l'AOI fora dels límits pirinencs pot fer que l'eina no conservi totes les seves garanties ni tingui el mateix sentit. En l'àmbit temàtic, la separació entre codi comú i codi específic de cada font facilita incorporar nous proveïdors, productes o variables ambientals sense modificar ni posar en risc les fonts ja integrades. Finalment, en l'àmbit computacional, el sistema permet ajustar resolucions, volums de dades i paràmetres d'execució segons els recursos disponibles, ja sigui en un ordinador local o en un entorn HPC, mantenint el mateix flux de treball i les mateixes configuracions de base.

El cinquè requisit és la **mantenibilitat**. En **pirineus-raster**, aquest requisit s'aborda mitjançant la separació entre la informació configurable de les fonts i la lògica comuna de la *pipeline*. Les fonts geoespacials externes poden canviar amb el temps, ja sigui perquè canvien els enllaços web, les versions, els formats, les credencials, l'estructura de carpetes o les metadades disponibles. Per reduir l'impacte d'aquests canvis, bona part de la informació específica de cada font queda definida en fitxers de configuració i en mòduls concrets de font. Això permet actualitzar una font determinada sense haver de modificar el funcionament general de l'eina, i fa que el manteniment sigui més localitzat, controlable i menys propens a introduir errors en altres parts del sistema.

El sisè requisit és el **control de memòria i la possibilitat de paral·lelització**. El processament *raster* pot consumir molta memòria, especialment quan es treballa amb àrees extenses, resolucions fines o moltes capes ambientals. Per aquest motiu, **pirineus-raster** incorpora un disseny que permet adaptar l'execució als recursos disponibles, evitant carregar dades innecessàries i permetent ajustar paràmetres segons si el procés s'executa en un ordinador local o en un entorn HPC. A més, la possibilitat d'executar parts del flux mitjançant *jobs* SLURM facilita el processament de *datasets* més grans o computacionalment més exigents, mantenint el mateix

esquema de configuració i el mateix *pipeline* de base.

El setè requisit és la **separació clara entre codi, configuració, dades originals, productes intermedis i *datasets* finals**. Aquesta separació queda reflectida en l'estructura del repositori i en l'organització dels directoris de dades. El codi font conté la lògica general de l'eina; les configuracions descriuen què s'ha d'executar en cada cas; les dades originals es mantenen separades dels productes transformats; i les sortides finals s'organitzen com a *datasets* preparats per a l'anàlisi. Aquesta estructura evita confusions entre dades *raw*, capes intermèdies i productes finals, impedeix que les dades pesades hagin de formar part del codi versionat, i facilita que altres usuaris puguin replicar el projecte mantenint la mateixa organització encara que no disposin exactament dels mateixos fitxers generats.

Finalment, el vuitè requisit és la **usabilitat per a investigadors que no necessàriament coneixen el codi intern**. Aquest objectiu s'aconsegueix mitjançant el model de *features*, el compilador de configuracions i la UI/*workbench*. Aquestes capes permeten que l'usuari defineixi l'àrea d'estudi, les fonts, les variables, la resolució, les opcions temporals o les sortides esperades sense haver d'entrar en tots els detalls interns de cada operació *raster*. Això no elimina la possibilitat d'editar manualment les configuracions o executar el *pipeline* per terminal, però ofereix una **capa d'abstracció** que fa l'eina més accessible, redueix errors de configuració i facilita la reutilització del sistema en nous estudis.

2.2 Visió general de l'arquitectura

L'arquitectura de `pirineus-raster` s'organitza al voltant de tres grans blocs: una **capa de configuració**, una **capa de gestió i validació de configuracions** i una **capa funcional de processament geoespacial**. Aquesta separació permet distingir amb claredat quina part del sistema defineix la variabilitat de cada execució, quina part comprova i prepara aquesta definició, i quina part executa finalment les operacions necessàries per construir el *dataset* ambiental harmonitzat.

La **capa de configuració** és la part modificable del sistema. Està formada per fitxers YAML que descriuen el projecte, el territori de treball, les fonts disponibles i les execucions concretes que es volen dur a terme. Aquesta decisió evita que la variabilitat de l'experiment quedi dispersa dins del codi i fa que els canvis rellevants (com treballar amb una altra AOI, una altra resolució o un altre conjunt de variables) es puguin dur a terme d'una manera més senzilla i versionable.

En primer lloc, la **configuració global del projecte** defineix els paràmetres comuns a totes les execucions: el sistema de coordenades de treball, els directoris de dades originals, intermèdies i processades, els valors `NoData`, les resolucions disponibles i altres opcions generals. Aquesta configuració estableix el marc compartit sobre el qual funcionen la resta de components.

En segon lloc, les configuracions d'**àrea d'interès** o AOI defineixen el domini espacial sobre el qual es vol executar el procés. Cada AOI és independent de la resta del sistema i permet aplicar el mateix flux de processament a àmbits diferents, com el conjunt dels Pirineus, una delimitació específica per al cas de l'ós bru o una àrea experimental més petita. Aquesta separació és important perquè l'àrea d'estudi condiona la graella de referència, el retall espacial i el volum

final de dades.

En tercer lloc, el **catàleg de fonts ambientals** recull les fonts integrades al projecte. Aquest catàleg també es defineix mitjançant fitxers de configuració i descriu els proveïdors, productes, variables, metadades, resolucions, opcions temporals i mecanismes necessaris per localitzar, descarregar o processar cada font. Tot i que aquests fitxers es poden modificar, en general actuen com una base ja preparada del sistema: cada font incorpora la informació necessària perquè pugui ser usada dins d'una *run* sense haver de redefinir-ne manualment el funcionament.

En quart lloc, les configuracions de **run** constitueixen la peça central per construir un *dataset* final concret. Una *run* no descriu només quines dades existeixen, sinó l'execució que l'usuari vol dur a terme: quina AOI s'utilitza, a quina resolució es treballa, quines fonts i variables entren al procés, quines variables derivades s'han de generar, quines opcions temporals s'apliquen i com s'organitzen les sortides. És, per tant, el punt on es formalitza el *dataset* desitjat i on es defineix la recepta que acabarà alimentant el flux de processament.

La segona part de l'arquitectura és la **capa de gestió i validació de configuracions**. Aquesta capa no genera directament els productes finals, però és imprescindible per assegurar que les configuracions introduïdes per l'usuari són coherents, completes i executables. Inclou components com el catàleg consultable, els validadors, el compilador, el renderitzador i la interfície visual o *workbench*. La seva funció és fer de pont entre la definició del projecte i l'execució de la *pipeline*.

La **validació de configuracions** és el primer filtre abans d'executar processos costosos. El sistema comprova que les fonts existeixin, que les variables estiguin ben definides, que l'AOI sigui vàlida, que la resolució sigui admissible, que les opcions temporals siguin compatibles i que les sortides esperades tinguin sentit. Aquest control previ evita que errors de configuració es detectin tard, quan ja s'han iniciat descàrregues o processaments pesats.

Un cop validada la definició, el **compilador de configuracions** transforma una configuració d'alt nivell, orientada a les *features* finals, en una configuració executable pel *pipeline*. Aquesta traducció és necessària perquè una *run* pot expressar el *dataset* desitjat de manera conceptual, però el sistema necessita convertir aquesta definició en un pla d'execució concret: quines fonts s'han de consultar, quines variables cal processar, quines dependències existeixen entre capes, quines agregacions o operacions derivades s'han d'aplicar i quines sortides s'han de generar.

El **renderitzador** s'usa quan la configuració es construeix o es modifica a través de la UI. En aquest cas, l'usuari treballa amb formularis, selectors i pantalles de revisió, tanmateix el resultat final ha de continuar essent una configuració formal, explícita i executable. El renderitzador converteix aquesta configuració assistida en un fitxer YAML final, que després pot ser revisat, versionat, validat i executat igual que una configuració escrita manualment.

La tercera part és la **capa funcional de processament geoespacial**. Aquesta és la part del codi que executa les instruccions derivades de les configuracions ja validades i compilades. Inclou la *pipeline* general, els mòduls específics de cada font, les operacions *raster*, el tractament temporal, el motor de variables derivades, l'escriptura de sortides i la construcció del paquet final de dades.

El **pipeline de processament** orquestra l'execució. A partir de la configuració compilada, el

sistema localitza o descarrega les dades font, les retalla a l'àrea d'interès, les reprojeta al sistema de coordenades comú, les remostreja a la resolució definida, aplica els tractaments necessaris i escriu les capes resultants. Aquest conjunt d'operacions permet convertir fonts molt diferents entre si en capes homogènies, comparables i alineades sobre una mateixa graella de referència.

Dins d'aquesta capa funcional també hi ha els **mòduls específics de fonts**. Aquests mòduls encapsulen les particularitats de cada proveïdor o producte, com ara la manera de descarregar les dades, l'estructura dels fitxers originals, la nomenclatura, les dimensions temporals o el tractament previ necessari. Aquesta separació permet mantenir una lògica comuna de processament i, alhora, adaptar-se a fonts molt diferents sense barrejar tot el codi en un únic bloc difícil de mantenir.

Un altre component funcional és el **motor de variables derivades**. Moltes variables útils per a l'anàlisi espacial o la modelització ecològica no existeixen directament com a capes originals, sinó que s'han de calcular a partir d'altres dades. Per exemple, a partir d'un model digital d'elevacions es poden derivar variables topogràfiques com el pendent, l'orientació, la rugositat o índexs de posició topogràfica; i a partir de dades vectorials d'OpenStreetMap es poden generar distàncies a carreteres, pistes o nuclis de població. Integrar aquestes operacions dins del mateix sistema evita càlculs manuals dispersos i garanteix que les variables derivades es generin amb els mateixos criteris de traçabilitat, validació i reproductibilitat que la resta de capes.

Finalment, la capa funcional inclou la **generació i validació dels productes finals**. El resultat de l'execució no és només un conjunt de capes *raster*, sinó un *dataset* ambiental harmonitzat, acompanyat de metadades, *manifests*, *logs* i còpies de les configuracions utilitzades. A més, el sistema incorpora comprovacions sobre les graelles de referència, les capes generades i els *datasets* finals, reduint el risc que errors d'alineació, resolució, CRS, NoData o coherència estadística arribin a l'anàlisi posterior.




Figura 2.1: Arquitectura general de **pirineus-raster**.

La figura 2.1 mostra aquesta separació en tres nivells. A la part superior, les configuracions que defineixen què es vol obtenir; al centre, la capa de gestió que valida, compila i renderitza; i a la

part inferior, el processament que construeix el *dataset* final. La UI/*workbench* pot aparèixer com una capa lateral connectada a les configuracions, ja que ajuda a crear-les i revisar-les, però no substitueix l'execució final de la *pipeline*.




Figura 2.2: Flux de validació, compilació i execució d'un *run config*.

La figura 2.2 representa el pas d'una definició declarativa a una execució concreta. Aquest diagrama és útil per remarcar que `pirineus-raster` no executa una llista fixa de scripts, sinó que transforma una configuració d'alt nivell en un pla de processament reproduïble.

2.3 Organització del repositori

L'organització del repositori reflecteix la voluntat de construir una eina reutilitzable i no només un conjunt de scripts puntuals. El projecte separa de manera explícita les configuracions, el codi font, els mòduls de fonts, la validació, el *workbench*, els *notebooks*, els *jobs* d'execució i els directoris de dades. Aquesta estructura fa més clara la funció de cada element i facilita tant el manteniment del codi com la reproducció dels resultats.

2.3.1 Estructura de directoris

L'estructura principal del repositori es pot resumir de la manera següent. L'arbre mostra tant els components estrictament necessaris per al funcionament de l'eina com alguns directoris auxiliars que s'han utilitzat en aquest treball, però que no formen part imprescindible del nucli de `pirineus-raster`:

```

pirineus-raster/
+-- configs/
|   +-- project.yaml
|   +-- aoi/
|   +-- sources/
|   '-- runs/
+-- src/
|   +-- cli/
|   +-- io/
|   +-- pipeline/
|   +-- sources/

```

```

|   +-- validation/
|   +-- workbench/
|   '-- make_grid.py
+-- ui/
+-- tests/           (opcional)
+-- data_raw/        (nom per defecte)
+-- data_interim/    (nom per defecte)
'-- data_processed/ (nom per defecte)
    +-- features/
    '-- datasets/

```

La carpeta `configs/` conté la **configuració declarativa** del projecte. A dins, `project.yaml` defineix els paràmetres globals, com el CRS, el valor `NoData`, les resolucions disponibles, els directoris de treball i l'organització de les sortides.

La carpeta `configs/aoi/` recull les àrees d'interès; `configs/sources/` actua com a catàleg de fonts ambientals, agrupades per proveïdor o producte; i `configs/runs/` conté les receptes d'execució que defineixen els *datasets* finals. Aquesta part sí que forma part del nucli de l'eina, perquè és el mecanisme que permet canviar d'àrea, resolució, font o cas d'ús sense modificar el codi.

La carpeta `src/` conté el **codi font principal** i és, amb diferència, el directori amb més pes dins del repositori. `src/cli/` implementa la interfície de línia de comandes i les accions disponibles per executar, validar, inspeccionar o servir l'eina. `src/io/` agrupa funcions de lectura de configuracions i resolució de camins. `src/pipeline/` concentra la lògica comuna de la *pipeline*: execució de *runs*, construcció de *datasets*, operacions *raster*, remostreig, tractament temporal, variables derivades, optimització de memòria i seguiment del progrés. `src/sources/` conté el tractament específic de cada família de fonts. `src/validation/` incorpora les comprovacions de graella, *raster* i *dataset*. `src/workbench/` conté la lògica del catàleg, la compilació de configuracions i el suport a la UI. Finalment, `src/make_grid.py` implementa la generació de graelles de referència.

La carpeta `ui/` conté la **interfície visual** desenvolupada amb React. Aquesta part actua com un *workbench* de configuració i permet crear, consultar, editar, validar i renderitzar configuracions sense haver d'escriure sempre manualment tots els fitxers `YAML`. Tot i que no substitueix la línia de comandes, sí que forma una part cabdal del projecte perquè facilita l'ús de l'eina per part de tot tipus d'usuaris.

La carpeta `tests/` és **opcional des del punt de vista de l'usuari final**, però ha estat important durant el desenvolupament. Conté proves automatitzades per comprovar que parts concretes del sistema funcionen correctament, detectar errors, validar casos extrems i evitar regressions quan es modifica el codi. Aquests tests ajuden a incrementar la robustesa de l'eina, però no intervenen directament en l'execució normal d'una *run* ni en la generació dels *datasets* finals.

Finalment, els directoris `data_raw/`, `data_interim/` i `data_processed/` representen l'organització de dades utilitzada per defecte en aquest projecte, definida a `configs/project.yaml`.

Aquests noms no són obligatoris, de manera que un altre usuari podria redefinir-los segons la seva infraestructura o preferències. `data_raw/` guarda les dades originals descarregades o localitzades, sense assumir que ja estiguin harmonitzades. `data_interim/` recull productes intermedis, com dades extretes, retallades o preparades abans de la construcció final. `data_processed/` conté els resultats generats; dins seu, `data_processed/features/` organitza les capes finals per font o variable, mentre que `data_processed/datasets/` agrupa les sortides empaquetades d'una *run*, incloent rasters, metadades, *manifests*, còpies de configuració i *logs*.

2.3.2 Separació entre codi, configuració i productes generats

La separació entre **codi**, **configuració** i **productes generats** és una de les decisions que més contribueix a la robustesa del projecte. El codi implementa la lògica general de processament; les configuracions descriuen què s'ha d'executar en cada cas; i els productes generats recullen els resultats del procés. Aquesta divisió evita que un canvi en l'experiment obligui a modificar el codi intern de l'eina.

Aquesta organització també facilita la **reproductibilitat**. Si una execució concreta queda definida per un conjunt de configuracions, el mateix escenari es pot repetir sempre que es mantinguin el codi i les dades d'entrada. A més, conservar còpies de les configuracions executades dins de les sortides permet reconstruir posteriorment com s'ha generat cada capa.

Des del punt de vista de la gestió de dades, la separació entre **dades originals**, **productes intermedis** i **datasets finals** evita confusions. Les dades originals no s'haurien de modificar; els productes intermedis poden regenerar-se; i els *datasets* finals representen el resultat d'una *run* concreta. Aquesta estructura també evita versionar dades pesades dins del repositori i facilita que altres usuaris reproduïxin el projecte mantenint la mateixa organització.

2.3.3 Interfície de configuració i *workbench* visual

El repositori incorpora una **interfície visual de configuració**, desenvolupada amb React i situada a `ui/`. Aquesta interfície actua com un *workbench* de suport per crear, revisar i editar configuracions. No substitueix la línia de comandes ni els fitxers `YAML`, però redueix la complexitat d'haver de construir manualment configuracions llargues, especialment quan intervenen moltes fonts, variables, opcions temporals o *features* derivades.

La pantalla inicial de la UI separa quatre usos principals. **Start new project** obre el flux per construir una nova configuració de *run*; **New AOI** permet crear una configuració d'àrea d'interès i generar-ne la graella; **My projects** mostra les *runs* guardades a `configs/runs/` i permet inspeccionar-les, editar-les o eliminar-les; i **Workbench guide** dona accés a una guia interna de conceptes, exemples, referència tècnica i informació sobre les fonts disponibles.

El mòdul **New AOI** permet definir el nom, la descripció, el `CRS`, la resolució i els límits de l'àrea d'interès. Inclou una previsualització cartogràfica amb mapa base i mode satèl·lit, eines de zoom, rectangle de selecció i comprovacions sobre l'encaix dins d'un embolcall general dels Pirineus. També incorpora comprovacions de divisibilitat dels límits segons les resolucions del projecte i una opció per ajustar mínimament els límits de l'AOI quan cal crear una graella sense cel·les

parcials. Des de la mateixa interfície es pot crear el fitxer d'AOI i, posteriorment, generar la graella de referència.

El mòdul **My projects** serveix per recuperar configuracions de *run* ja existents. La UI llista els projectes guardats, en mostra el nom, la descripció, les *features* finals, els avisos de validació i el resum de fonts compilades. Des d'aquesta vista es pot obrir una configuració per editar-la, eliminar-la o revisar-ne els resultats de validació. Aquesta funcionalitat és útil perquè molts *datasets* futurs poden partir d'una configuració anterior i modificar-ne només alguns elements.

El flux de **Start new project** comença amb la definició de la identitat de la *run*: nom, descripció, directori de sortida, AOI, CRS, resolució, fitxer de projecte i etapes d'execució. Aquesta pantalla estableix l'envolupant general del *dataset* abans d'afegir-hi les variables finals. A partir d'aquí, la UI guia l'usuari cap al constructor de *features*.

El **Feature builder** és el nucli funcional de la UI. Permet dues vies principals: crear una *feature* **personalitzada** o afegir **capas oficials de font** com a sortides finals. La primera opció és adequada per a variables derivades, màscares, expressions, distàncies, estadístics focals o receptes guiades. La segona és útil quan l'usuari vol incorporar directament diverses variables d'una font oficial sense transformacions addicionals, però mantenint la selecció de dimensions, temporalitat i remostreig.

El selector d'inputs està organitzat de manera progressiva. Primer es tria si l'entrada prové d'una **font oficial** o d'una *feature* **ja creada** dins del projecte. Després se selecciona el proveïdor, el producte, la variable, les classes categòriques si n'hi ha, les dimensions no temporals, les opcions temporals i el mètode de remostreig. Aquesta seqüència evita que l'usuari triï una font de manera ambigua sense concretar quina variable, quina temporalitat o quin tractament vol aplicar.

La UI també incorpora un apartat de **variables derivades**. Aquest apartat permet construir receptes guiades, màscares binàries, operacions espacials i expressions avançades. Les receptes guiades cobreixen combinacions habituals com rang tèrmic, balanç hídric, índex d'aridesa, persistència de neu o contrastos estacionals. Les operacions espacials permeten generar derivades de terreny, estadístics focals i distàncies a màscares o classes. Les expressions avançades ofereixen una forma controlada de *map algebra* amb funcions segures i metadades explícites de sortida.

La part de **temporalitat** permet treballar amb fonts estàtiques, capas subministrades directament, agregacions, talls temporals o postprocessats temporals, sempre que la font ho suporti. La interfície distingeix entre dimensions del producte (escenaris, períodes o resolucions natives) i sortides temporals (anys, mesos, estacions o agregacions). Aquesta distinció és important perquè evita confondre variants del producte amb períodes d'observació.

La pestanya o pantalla de **Review** presenta la configuració final abans d'executar-la. Mostra les capas planificades, les *features* derivades i el YAML resultant, i ofereix accions per validar, renderitzar, copiar, descarregar o guardar la configuració dins de **configs/runs/**. Aquest pas tanca el circuit entre la configuració assistida i el funcionament reproducible del sistema: encara que l'usuari hagi treballat visualment, el resultat final és un fitxer YAML formal i executable.

Cal remarcar també que **no** pretén fer la UI. No és un SIG complet ni una eina d'anàlisi cartogràfica avançada; tampoc substitueix l'execució final de la *pipeline* per terminal quan es

tracta de generar *datasets* grans. La seva funció principal és assistir en la preparació, revisió i validació de configuracions. Aquesta delimitació manté clara la separació entre la capa d'usabilitat i el nucli funcional de processament.




Figura 2.3: Pantalla inicial del *workbench* de `pirineus-raster`.




Figura 2.4: Creació assistida d'una àrea d'interès i de la graella de referència.

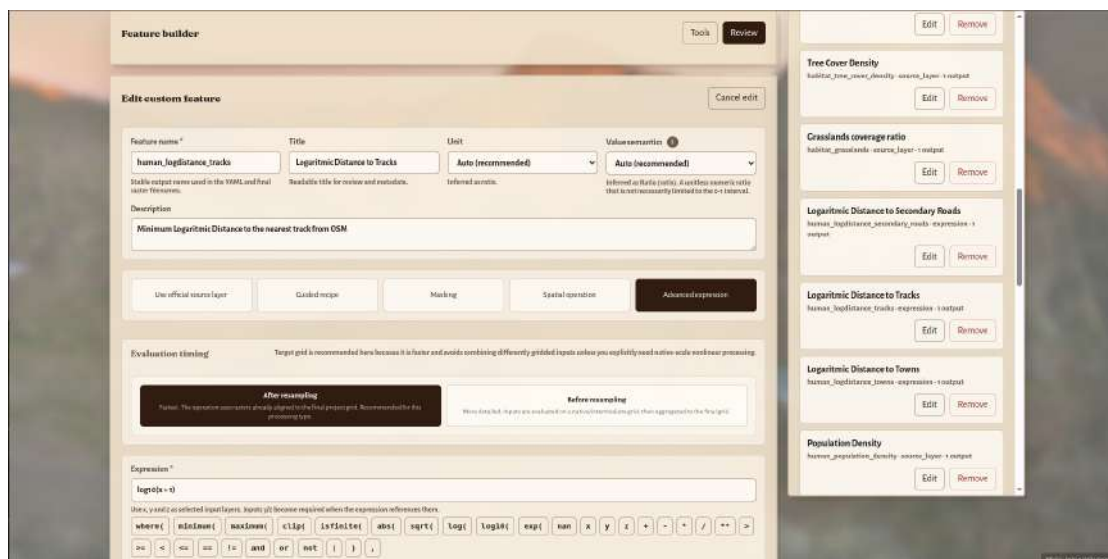


Figura 2.5: Construcció assistida d'una variable del *feature builder* de la UI.




Figura 2.6: Revisió d'una configuració de *run* des de la UI.

2.4 Parametrització del flux de treball

La parametrització del flux de treball és el mecanisme que permet adaptar **pirineus-raster** a escenaris diferents sense modificar el codi intern. En aquest projecte, les decisions principals es representen mitjançant configuracions: quin territori es processa, quina resolució es vol obtenir, quines fonts intervenen, quines variables finals es generen, quin tractament temporal s'aplica i com s'organitzen les sortides.

Aquesta parametrització és especialment important perquè les decisions espacials i metodològiques condicionen directament el resultat. Canviar la resolució, l'AOI, una variable o un mètode de remostreig pot generar un *dataset* diferent. Per això totes aquestes opcions han de quedar explícites i associades a la *run* que les utilitza.

2.4.1 Configuració territorial

La **configuració territorial** es defineix mitjançant els fitxers d'A0I. Aquests fitxers indiquen el domini espacial de treball i condicionen totes les capes posteriors: la graella de referència, el retall de les fonts, el nombre de cel·les i l'estructura de sortida. Al repositori es mantenen diverses àrees, com `pyrenees_full`, `pyrenees_pdca_full`, `experimental_pallars_sobira` i `ursus_arctos_pyrenees`.

Aquesta organització permet treballar amb dominis de prova i dominis finals. Les àrees petites són útils per desenvolupar i depurar el flux amb menys cost computacional; les àrees completes permeten generar *datasets* finals per a anàlisi o modelització. En tots dos casos, el codi és el mateix i el canvi principal recau en la configuració territorial.

2.4.2 Configuració de variables ambientals

La **configuració de variables ambientals** es basa en el catàleg de fonts i en les *runs*. El catàleg descriu quines variables ofereix cada font; la *run* decideix quines d'aquestes variables s'utilitzen finalment. Aquesta separació evita duplicar informació i permet reutilitzar una mateixa font en diversos *datasets*.

A més, la configuració no es limita a activar o desactivar capes originals. També permet definir variables finals d'alt nivell, construïdes a partir de fonts, agregacions temporals, fraccions categòriques, màscares, operacions espacials o expressions. Això és el que permet que el sistema sigui orientat a *features*: l'usuari defineix les variables finals que necessita, i l'eina resol com generar-les.

2.4.3 Configuració de sortides

La **configuració de sortides** estableix on i com s'escriuen els productes generats. El sistema diferencia entre `data_processed/features/`, on es poden guardar capes processades individuals, i `data_processed/datasets/`, on s'organitzen *datasets* finals associats a una *run* concreta.

Aquesta distinció permet separar productes reutilitzables de paquets finals. Una *feature* processada pot ser útil en més d'un *dataset*, mentre que un *dataset* final ha de correspondre a una execució concreta, amb la seva configuració, metadades i *manifest*. També facilita que els *notebooks* o models posteriors consumeixin una estructura de dades clara i estable.

2.4.4 Model de *features* i compilador de configuracions

El **model de *features*** permet descriure el *dataset* en termes de variables finals. Una *feature* pot correspondre a una capa de font, a una variable derivada, a una expressió, a una recepta, a una màscara o a una operació espacial. Aquesta abstracció redueix la complexitat perquè l'usuari pot definir què necessita obtenir, sense haver de descriure manualment tots els passos interns.

El **compilador** converteix aquesta definició en una configuració executable. Per fer-ho, resol

dependències entre inputs i outputs, agrupa requisits de fonts, interpreta la temporalitat, aplica opcions de remostreig i prepara el pla d'execució que després utilitzarà el *pipeline*. Aquesta peça és una de les contribucions més rellevants del projecte, perquè connecta la configuració orientada a l'investigador amb el processament efectiu de dades.

2.5 Flux de processament

El flux de processament comença amb la lectura de les configuracions i acaba amb la generació d'un *dataset* final. Des del punt de vista de l'usuari, el procés s'inicia amb una *run*; des del punt de vista intern, aquesta *run* es valida, es compila i es transforma en una seqüència d'operacions geoespacials.

El primer pas és establir el **marc espacial**: projecte, AOI, CRS, resolució i graella de referència. Aquesta graella actua com a plantilla comuna i és el criteri final d'alineació de totes les capes.

El segon pas és la **preparació de fonts**. El sistema localitza o descarrega les dades originals, aplica les opcions pròpies de cada font i prepara els fitxers per al processament comú. Aquesta fase pot variar segons el proveïdor, però queda encapsulada dins dels mòduls específics de fonts.

El tercer pas és l'**harmonització geoespacial**. Les capes es retallen, es reprojecten, es remostregen i s'adapten a la graella de referència. En aquest punt, el sistema converteix dades que originalment podien tenir resolucions, extensions o projeccions diferents en capes comparables cel · la a cel · la.

El quart pas és la **generació de variables finals**. Quan una *feature* no correspon directament a una capa d'origen, s'apliquen expressions, receptes, màscares, operacions espacials, estadístics focals o tractaments temporals. Aquest pas és el que permet passar de fonts ambientals originals a predictors realment útils per a l'anàlisi.

El cinquè pas és la **validació i empaquetat**. El sistema comprova la coherència geomètrica i estadística de les sortides i organitza el resultat final amb capes **GeoTIFF**, metadades, *manifests*, *logs* i còpies de configuració. El resultat és un *dataset* preparat per ser consumit per *notebooks*, models o altres fluxos d'anàlisi.

2.6 Traçabilitat, metadades i control de versions

La traçabilitat de `pirineus-raster` es basa en associar cada resultat amb la configuració i el procés que l'han generat. Una capa final no és només un fitxer **GeoTIFF**; és el resultat d'una font, una variable, una AOI, una resolució, unes opcions de processament i unes operacions concretes.

Aquesta traçabilitat s'aconsegueix mitjançant **còpies de configuració**, **metadades**, *manifests* i *logs*. Les còpies de configuració permeten reconstruir la *run*; les metadades descriuen les propietats de les capes; els *manifests* resumeixen el conjunt de productes generats; i els *logs* documenten el desenvolupament de l'execució.

El control de versions del codi complementa aquesta informació. Les configuracions poden

evolucionar, les fonts externes poden actualitzar-se i el codi pot millorar amb el temps. Per això és important que les sortides finals quedin vinculades a l'estat del projecte amb què s'han generat. Aquesta relació entre codi, configuració i resultats és essencial per a la revisió científica.

En el cas de la modelització ecològica, la traçabilitat és especialment important. Si una variable ambiental apareix com a predictor rellevant en un model, cal poder saber de quina font prové, com s'ha processat i quina semàntica tenen els seus valors. Sense aquesta informació, la interpretació ecològica del model quedaria debilitada.

2.7 Publicació, reutilització i modes d'ús

El codi de **pirineus-raster** està pensat per publicar-se en un repositori públic de GitHub, de manera que pugui ser revisat, reutilitzat i ampliat en altres projectes [4]. Aquesta publicació inclou el codi font, configuracions representatives, documentació bàsica i instruccions de reproducció. Les dades pesades no formen part del repositori, però el projecte documenta l'estructura esperada de directoris i les ordres necessàries per regenerar les sortides principals.

L'eina es pot utilitzar de diverses maneres. El mode principal d'execució és la **CLI**, que permet validar configuracions, crear graelles, executar *runs*, processar fonts, inspeccionar resultats i validar *datasets* finals. Aquest mode és el més adequat per a execucions reproduïbles, automatització i entorns HPC.

El segon mode és l'**edició directa de fitxers YAML**. Aquest ús és adequat per a usuaris avançats que volen controlar amb precisió les configuracions o versionar-les mitjançant Git. El tercer mode és la **UI/workbench**, que facilita la creació i revisió de configuracions complexes. Finalment, el projecte inclou suport per a **execució en HPC** mitjançant scripts **SLURM**, útils quan el volum de dades o la resolució fan poc pràctica l'execució local.

Aquesta combinació de modes d'ús permet adaptar l'eina a perfils diferents. Un usuari pot crear una configuració des de la UI, revisar o ajustar el **YAML** manualment, validar-lo per terminal i executar-lo en local o en un clúster. Tot i que els camins d'entrada són diferents, tots acaben alimentant el mateix sistema de configuració, validació i processament.

2.8 Adequació de l'eina al problema plantejat

Les decisions de disseny de **pirineus-raster** responen directament al problema plantejat en aquest treball: la dificultat de convertir fonts ambientals heterogènies en dades *raster* coherents, traçables i preparades per a l'anàlisi.

La separació entre **configuració i codi** respon a la necessitat de modificar experiments sense alterar el funcionament intern de l'eina. La definició d'**AQIs i graelles de referència** resol el problema de la comparabilitat espacial. El **catàleg de fonts** permet integrar proveïdors diferents dins d'un mateix marc. El **model de features** apropa la configuració a les variables finals que necessita l'investigador. I el **compilador** connecta aquesta definició conceptual amb un pla d'execució concret.

Alhora, el ***pipeline* funcional** resol la part operativa: descàrrega o localització de fonts, retall, reprojecció, remostreig, tractament temporal, generació de variables derivades i escriptura de sortides. Les comprovacions de validació i les metadades asseguruen que els resultats no siguin només fitxers generats, sinó productes auditables.

La **UI/*workbench*** reforça la usabilitat de l'eina, especialment quan el nombre de fonts i variables creix. Permet preparar configuracions complexes amb menys risc d'error, però manté el principi fonamental del projecte: el resultat final continua essent una configuració formal i reproduïble, executable des de la línia de comandes.

En conjunt, **pirineus-raster** converteix un problema habitual en estudis ambientals —la fragmentació de les fonts geoespacials— en un flux de treball configurable, modular, validable i reproduïble. Aquesta arquitectura constitueix la base sobre la qual es desenvolupa el capítol següent, dedicat a la construcció automatitzada dels *datasets raster* preparats per a l'anàlisi.

Capítol 3

Construcció automatitzada de *datasets* raster preparats per a l'anàlisi

El capítol anterior ha presentat **pirineus-raster** des del punt de vista del disseny del sistema: arquitectura, configuracions, repositori, interfície de treball, modes d'execució i mecanismes generals de traçabilitat. Aquest capítol, en canvi, se centra en el procés metodològic que materialitza aquesta arquitectura. L'objectiu és explicar com una col·lecció de fonts ambientals heterogènies es transforma en un conjunt de capes *raster* harmonitzades, documentades i preparades per alimentar anàlisis espacials o models ecològics.

Al llarg del capítol, la metodologia general s'il·lustra amb la *run* principal del projecte, associada al cas d'ús de femelles d'ós bru amb cries als Pirineus. Aquest exemple no condiciona el disseny general del sistema, però permet mostrar com les decisions metodològiques descrites (AOI, resolució, fonts, temporalitat, remostreig, variables derivades i control de qualitat) es concreten en una execució real. D'aquesta manera, el capítol manté una doble lectura: descriu el procés general de construcció de col·leccions de dades i, alhora, documenta la generació del *dataset* que s'utilitzarà al capítol 4.

3.1 Criteris de construcció del *dataset*

La construcció d'una col·lecció de dades *raster* preparada per a l'anàlisi exigeix, com a mínim, que totes les capes finals comparteixin unes propietats espacials i documentals comunes. En el cas de **pirineus-raster**, el primer criteri principal és que cada variable final quedi expressada sobre una **graella de referència comuna**. Això implica que totes les capes han de tenir el mateix sistema de coordenades, la mateixa extensió, la mateixa resolució, el mateix *transform affine*, les mateixes dimensions de matriu i una gestió compatible dels valors absents.

Aquest criteri espacial no és només una qüestió formal. En el moment que diferents capes s'han d'apilar per extreure predictors, entrenar models o comparar cel·les, una petita diferència en l'origen de píxel, en l'extensió o en la projecció pot produir valors mal alineats. Per tant, una capa no es considera finalitzada només pel fet d'estar descarregada o retallada, sinó quan ha estat ajustada a la graella de treball i pot combinar-se amb la resta sense operacions manuals addicionals.

Un segon criteri és la **coherència semàntica de les variables**. No totes les capes representen el mateix tipus d'informació: una temperatura és una variable intensiva, una classe de coberta del sòl és categòrica, una densitat de població pot representar un recompte o una magnitud

extensiva, i l'orientació topogràfica és circular. Per tant, el sistema no pot aplicar el mateix tractament a totes les dades. Cada variable ha d'incorporar, sempre que sigui possible, una semàntica explícita que orienti el remostreig, la interpretació i la validació posterior.

El tercer criteri és la **traçabilitat**. Cada capa final ha de poder relacionar-se amb la font original, la variable processada, l'A0I, la resolució, el tractament aplicat, els paràmetres de temporalitat, el mètode de remostreig i la configuració de la *run*. Aquesta traçabilitat es concreta en fitxers GeoTIFF, metadades JSON, *manifests*, *logs* i còpies de configuració. Així doncs, el *dataset* final no és només una carpeta de rasters i prou, sinó una sortida auditada i regenerable.

Finalment, les capes generades han de presentar **valors plausibles i documentats**. Això inclou valors NoData coherents, rangs mínims i màxims compatibles amb la variable, absència d'artefactes evidents, cobertura espacial suficient dins de l'A0I i nomenclatura homogènia. Aquests criteris vertebren la resta del capítol i permeten avaluar si la col·lecció de dades és realment apta per a l'anàlisi.

3.2 Àrea d'estudi i graella de referència

3.2.1 Definició de l'A0I i límits de treball

El sistema permet definir lliurement l'àrea d'interès d'una execució. Tanmateix, **pirineus-raster** ha estat concebut, configurat i validat per treballar dins del **domini pirinenc**. Això vol dir que una A0I situada fora d'aquest àmbit pot quedar afectada per buits de cobertura, fonts no disponibles, productes retallats prèviament o incoherències entre capes. Per tant, l'ús flexible d'A0Is no s'ha d'interpretar com una garantia de funcionament global, sinó com la possibilitat d'adaptar el sistema a diferents dominis dins del marc territorial per al qual s'han preparat les fonts.

El límit general de treball del projecte queda representat principalment per la configuració **pyrenees_full**, que actua com a *bounding box* generós al voltant dels Pirineus. Aquesta A0I està definida en EPSG:3035 amb límits $xmin = 3300000$, $xmax = 3770000$, $ymin = 2120000$ i $ymax = 2345000$. En coordenades geogràfiques, aquest embolcall correspon aproximadament a una longitud entre -2.29 i 3.18 graus i una latitud entre 41.96 i 43.47 graus. No es tracta d'una delimitació física exacta de la serralada, sinó d'un domini operatiu prou ampli per retallar fonts globals o europees i preparar-les per a execucions pirinenques.

Actualment, les A0Is del sistema es defineixen com **polígons rectangulars alineats amb els eixos del sistema de coordenades**. Aquesta restricció simplifica la construcció de la graella, l'alineació de píxels i la validació geomètrica de les sortides. Això comporta que l'eina encara no admeti directament A0Is amb polígons complexos, màscares irregulars, geometries diagonals o delimitacions no rectangulars. Aquest és un límit assumit de la versió actual; amb tot, l'arquitectura permetria incorporar en el futur màscares territorials més complexes per restringir l'anàlisi dins d'un rectangle de treball. Cada A0I es declara en un fitxer de configuració independent dins de **configs/aoi/**. Això permet conservar tantes àrees d'interès com calgui i alternar-les entre *runs* modificant simplement el camp **aoi_config**.

En el cas de l'ós bru, la *run* principal no usa tot l'embolcall `pyrenees_full`, sinó l'`AOI ursus_arctos_pyrenees`. Aquesta delimitació cobreix el domini pirinenc potencialment rellevant per a femelles d'ós bru amb cries, d'acord amb el marc espacial del cas d'ús, i està definida amb límits `xmin = 3375000`, `xmax = 3716000`, `ymin = 2140000` i `ymax = 2300000` en EPSG:3035. La figura 3.1 representa l'extensió de l'`AOI` aplicada al cas de l'ós.




Figura 3.1: Extensió de l'`AOI` aplicada al cas d'ús de l'ós bru (en verd).

3.2.2 Sistema de coordenades, resolució i alineació de píxels

El sistema de referència de treball del projecte és EPSG:3035. Aquesta projecció és adequada per a anàlisis espacials a escala europea perquè treballa en metres i permet interpretar amb coherència distàncies, àrees, buffers, distàncies euclidianes i mides de píxel. En el context de `pyreneus-raster`, aquesta elecció és especialment rellevant perquè moltes variables derivades depenen de magnituds espacials (pendent, distàncies a carreteres, estadístics focals o fraccions de cobertura).

La configuració global del projecte preveu resolucions de **10, 30, 50 i 100 metres**. Ara bé, una `AOI` només pot convertir-se en graella si l'amplada i l'alçada del seu *bounding box* són divisibles de manera exacta per la resolució escollida. Si aquesta condició no es compleix, apareixerien cel·les parcials o dimensions no enteres, fet que trencaria la correspondència entre extensió, mida de píxel i *transform affine*. Així doncs, la compatibilitat entre `AOI` i resolució és un requisit geomètric previ a qualsevol processament.

Per facilitar aquesta comprovació, la UI incorpora controls que indiquen si l'`AOI` definida és divisible per les resolucions base del projecte. Quan els límits no encaixen exactament, l'eina pot aplicar un ajust conservador que expandeix mínimament els *bounds* cap enfora fins que la divisió

és entera. Aquesta correcció evita modificar manualment coordenades i, alhora, garanteix que la graella resultant sigui regular i reproduïble.

En el cas d'ús del projecte es treballa a **100 m**. Aquesta resolució ofereix un compromís raonable entre detall espacial, cost computacional i coherència amb l'escala del cas d'ús. En el cas de femelles d'ós bru amb cries, una graella de 10 o 30 m hauria incrementat molt el volum de dades i podria transmetre una precisió espacial excessiva respecte a la incertesa de les observacions i a l'escala ecològica del moviment. En canvi, els 100 m permeten representar patrons ambientals rellevants sense fer que el processament sigui innecessàriament pesant. Amb aquesta resolució, l'AOI `ursus_arctos_pyrenees` genera una graella de **3410 columnes per 1600 files**, és a dir, aproximadament **5,46 milions de cel · les** per capa. Totes les variables de la *run* final (topografia, hàbitat, pressió humana, clima o neu) s'escriuen sobre aquesta mateixa estructura espacial. D'aquesta manera, qualsevol cel · la de qualsevol capa representa exactament el mateix fragment del territori.

3.3 Ingesta i preparació de fonts ambientals

La ingesta de fonts és el procés mitjançant el qual `pirineus-raster` obté o localitza les dades originals i les posa en condicions de ser transformades. Les fonts integrades al repositori difereixen profundament entre si: algunes són rasters globals, d'altres són productes europeus ja en EPSG:3035, algunes funcionen amb sèries temporals, altres són col · leccions anuals, i algunes són dades vectorials que cal rasteritzar o convertir en distàncies.

Per evitar que aquesta diversitat es converteixi en codi dispers i difícil de mantenir, el sistema encapsula cada font en una configuració específica i, quan cal, en un mòdul propi de processament. Amb tot, el flux general conserva sempre una estructura comuna: localitzar o descarregar, preparar espacialment, construir la capa final i registrar metadades.

3.3.1 Descàrrega o localització de dades originals

L'etapa `download` és la responsable d'obtenir les dades originals o de comprovar que ja existeixen en el directori esperat. En la majoria de casos implementats, la descàrrega pot automatitzar-se a partir d'URL configurades o patrons de fitxers. En d'altres, el sistema treballa amb fitxers prèviament descarregats o amb fonts que requereixen credencials, catàlegs externs o serveis específics. Això afecta, per exemple, productes Copernicus distribuïts mitjançant serveis externs, productes globals organitzats per *tiles*, o fonts locals com el topoclima pirinenc.

Aquesta fase no pretén homogenitzar encara les capes. La seva funció és assegurar que la dada bruta existeix, queda situada dins de l'estructura `data_raw/` i pot ser recuperada de manera reproduïble per les fases següents. Per tant, `download` és una etapa d'accés i inventari, no pas de transformació final. Cal tenir en compte, tanmateix, que pot ser exigent pel que fa a **espai d'emmagatzematge**: sovint cal obtenir productes complets, *tiles* sencers o capes amb una resolució més fina que la necessària per al *dataset* final. Un cop les dades han estat retallades o convertides en productes intermedis, el sistema permet gestionar les dades originals separatament,

fet que facilita alliberar espai quan ja no cal conservar-les localment.

3.3.2 Validació inicial de fonts i metadades

Abans de processar una font, el sistema comprova que la informació definida en la configuració sigui suficient i coherent. Aquesta validació inicial inclou l'existència dels fitxers o enllaços esperats, la llegibilitat del format, la presència d'un CRS interpretable, la variable demanada, la resolució nativa o configurada, els valors `NoData`, el factor d'escala i les metadades bàsiques de la font.

Aquest control és necessari perquè moltes incidències en dades geoespacials no apareixen com a errors evidents. Una capa pot obrir-se correctament, però correspondre a un any equivocat, tenir una codificació categòrica diferent, portar un factor d'escala no aplicat o cobrir només una part de l'AOI. Detectar aquestes qüestions abans del *build* redueix el risc d'obtenir sortides formalment vàlides però conceptualment errònies.

3.3.3 Catàleg de fonts ambientals integrades

El catàleg del repositori inclou **23 configuracions de fonts** organitzades per proveïdor, producte i variable. Aquest catàleg no és només una llista de noms, sinó una part funcional del sistema: cada configuració descriu com s'accedeix a la font, quines variables finals pot generar, quina resolució o estructura temporal té, quina semàntica de valors s'hi associa i quin tractament principal cal aplicar abans d'integrar-la en una col·lecció de dades harmonitzada.

La taula 3.1 en presenta una **síntesi agrupada**. Per tant, la taula no mostra totes les variants internes de cada font ni totes les variables finals configurades, sinó les famílies de dades que formen el catàleg ambiental de **pirineus-raster**. El catàleg combina fonts climàtiques, topogràfiques, de coberta del sòl, de neu, de biomassa i de pressió humana procedents de productes com WorldClim, CRU TS, CMIP6, Copernicus, PDCA, ESA CCI Biomass, OpenStreetMap i GHSL [5], [6], [7], [8], [9], [10], [11], [12], [13], [14]. El detall operatiu queda expressat en els fitxers de configuració de `configs/sources/`, on cada font concreta defineix les seves variables, dimensions, metadades, modes temporals i criteris de processament.

Taula 3.1: Fonts ambientals integrades al catàleg de *pirineus-raster*.

Família o producte	Tipus de variables	Resolució nativa configurada	Tractament principal	Ús principal
WorldClim v2.1 normals, bioclim i elevació [5]	Clima normal, índexs bioclimàtics i elevació global	10arcmin en la configuració	Selecció de variables, agregació mensual o índexs, reprojecció i harmonització	Predictors climàtics i context topogràfic
WorldClim CRU TS 4.09 monthly [6]	Temperatura mínima, màxima i precipitació mensual històrica	10arcmin	Sèries any-mes, selecció de períodes i agregacions temporals	Variabls climàtiques estacionals o anuals
WorldClim CMIP6 future [7]	Escenaris climàtics futurs per GCM, SSP, període i variable	10arcmin	Selecció de dimensions climàtiques i agregació de bandes mensuals	Extensió climàtica futura
Copernicus DEM GLO-30 [8]	Elevació	30 m	Reprojecció, remostreig i derivades topogràfiques	Topografia base
Copernicus CLMS CLC, CLC+, Forest, Grasslands, Imperviousness, Water/Wetness i Small Landscape Features [15], [16], [17]	Coberta del sòl, bosc, pastures, artificialització, aigua i elements del paisatge	10 m o 100 m segons producte	Reclassificació, fraccions de cobertura, màscares i harmonització	Hàbitat i pressió humana
Copernicus HR-VPP [10]	Fenologia i productivitat vegetal anual	10 m	Selecció d'anys, estacions de creixement i agregacions	Productivitat i estructura vegetal
Copernicus HRSI Snow [11]	Fracció de neu i agregacions de cobertura nival	20 m	Postprocessat temporal, recomptes i mitjanes per períodes	Persistència de neu
PDCA Topoclimate 1950–2012 [9]	Temperatura, precipitació, PET, disponibilitat hídrica, radiació i GDD	30 m	Lectura de capes anuals, mensuals i estacionals subministrades	Clima local pirinenc
OpenStreetMap Geofabrik [13]	Xarxa viària, pistes, camins i assentaments	Vectorial	Retall, rasterització temàtica i distàncies euclidianes	Pressió humana i accessibilitat
GHSL R2023A [14]	Població, superfície construïda i model d'assentaments	100 m o 1000 m segons producte	Selecció d'any, harmonització i tractament de comptatges o classes	Pressió humana
ESA CCI Biomass AGB [12]	Biomassa aèria i incertesa associada	100 m	Selecció d'anys i remostreig semàntic	Estructura forestal
ESA WorldCover [18]	Coberta del sòl global	10 m	Reclassificació i fraccions categòriques	Hàbitat
IGME–BRGM Geology 400k	Litologia i informació geològica pirinenca	Escala 1:400.000, vectorial	Rasterització i reclassificació	Context físic

En el cas d'ús de l'ós bru, es defineix una configuració de *run* específica i seleccionada amb cura, en la qual s'empren 10 fonts del catàleg i es construeixen 41 capes finals a partir de variables directes, derivades espacials i expressions. El detall de les variables escollides i la seva justificació ecològica es presenta més endavant, dins del capítol del cas d'ús, a la taula 4.2.

3.3.4 Tractament de variables temporals

Les fonts geoespacialen poden ser **estàtiques** o **temporals**. Les primeres representen una capa sense dimensió temporal explícita en l'execució (per exemple, un DEM o una coberta del sòl d'un any de referència). Les segones contenen mesos, anys, períodes, escenaris, estacions o seqüències diàries que cal seleccionar o agregar abans d'obtenir la variable final.

pirineus-raster tracta aquesta diversitat mitjançant modes temporals explícits. La taula 3.2 resumeix els principals modes disponibles. Aquesta classificació evita confondre productes que aparentment són semblants però que tenen una naturalesa temporal diferent. Per exemple, WorldClim v2.1 normals és una climatologia mensual, CRU TS 4.09 és una sèrie històrica any-mes, PDCA subministra capes mensuals i estacionals ja agregades, i HRSI Snow requereix un postprocessat de sèries temporals de neu.

Taula 3.2: Modes temporals principals usats en la construcció de variables.

Mode	Funció	Exemples de fonts o variables
<code>static</code>	Usa una capa sense agregació temporal dins de la run.	DEM, cobertes estàtiques, capes vectorials transformades.
<code>supplied_layers</code>	Selecciona capes temporals ja subministrades pel producte.	PDCA mensual, estacional o anual; capes anuals categòriques.
<code>aggregate</code>	Agrega mesos, anys o bandes temporals mitjançant mètriques com <code>mean</code> , <code>sum</code> , <code>min</code> , <code>max</code> o <code>std</code> .	WorldClim normals, CRU TS, CMIP6, HR-VPP o biomassa anual.
<code>raw_slices</code>	Conserva talls temporals individuals en lloc d'agregar-los.	Mesos concrets de climatologies o sèries any-mes.
<code>postprocess aggregate</code>	Genera agregacions després de processar observacions temporals originals.	HRSI Snow, amb mitjanes, recomptes o l·lindars de cobertura nival.

Aquest tractament temporal és cabdal en modelització ecològica. Una temperatura anual, una temperatura d'hivern, una fracció de neu de primavera o una productivitat mitjana no representen el mateix procés ambiental. En el cas de l'ós bru, aquesta distinció permet construir predictors estacionals que s'ajusten millor al calendari ecològic de l'espècie i a la data de les observacions.

3.4 Harmonització geoespacial de les capes

Un cop les dades originals són disponibles, la *pipeline* aplica una seqüència d'operacions destinada a convertir-les en capes comparables. Aquest procés no consisteix simplement a canviar el format del fitxer; implica adaptar fonts amb CRS, cobertura, resolució, semàntica i estructura temporal diferents a un mateix marc espacial. La figura 3.2 resumeix aquest flux.




Figura 3.2: Flux general d'harmonització geoespacial d'una font fins a obtenir una capa final preparada per a l'anàlisi.

3.4.1 Retall espacial i adaptació a l'AOI

El **retall espacial** limita cada font al domini necessari per a l'execució. Moltes dades originals cobreixen àmbits molt més grans que els Pirineus (productes globals, europeus o pan-europeus), mentre que d'altres tenen una cobertura més específica. L'etapa `clip` redueix aquest volum, conserva només les porcions rellevants i prepara les dades perquè la fase de construcció no hagi de treballar amb fitxers innecessàriament grans.

El retall no s'ha d'entendre com una operació cartogràfica superficial. És el pas que connecta la font amb l'AOI configurada i amb la futura màscara de treball. També permet detectar fonts amb cobertura insuficient, *tiles* incomplets o productes que no abasten tot el domini requerit. Així mateix, en fonts vectorials, com OpenStreetMap o geologia, el retall simplifica les geometries que després es rasteritzaran o s'usaran per calcular distàncies.

En la *run* de l'ós bru, aquesta fase restringeix totes les fonts seleccionades al domini `ursus_arctos_pyrenees`. Algunes dades ja arriben prèviament retallades o mosaïcades dins del marc pirinenc general; tanmateix, el *clip* final garanteix que totes acabin ajustades a l'AOI efectiva de modelització.

3.4.2 Reprojecció al sistema de referència comú

La **reprojecció** transforma les fonts que arriben en altres sistemes de coordenades cap al CRS de treball, `EPSG:3035`. Aquesta operació és imprescindible perquè el *dataset* final no pot combinar capes en coordenades geogràfiques, projeccions globals o sistemes locals sense una transformació prèvia. En el catàleg hi conviuen fonts en `EPSG:4326`, `EPSG:3035`, `EPSG:25830`, `ESRI:54009` i altres sistemes associats a fonts concretes.

Reprojectar no és només modificar una etiqueta del fitxer. La transformació afecta la mida real dels píxels, les distàncies, les àrees i l'alineació. Per aquest motiu, la reprojecció es fa conjuntament amb l'ajust a la graella comuna: la capa resultant no només queda en `EPSG:3035`, sinó que també adopta l'origen, el *transform* i les dimensions definides per la *run*. En el *dataset* de l'ós, aquesta decisió és especialment útil perquè les distàncies a elements humans, les derivades topogràfiques i els estadístics espacials es calculen tots en metres i sobre un mateix marc de referència.

3.4.3 Remostreig segons la semàntica de variable

El **remostreig** és una de les operacions més delicades de tot el procés d'harmonització. Quan una capa es transforma a una nova graella, el valor de cada píxel final no és una simple còpia del valor original, sinó el resultat d'un criteri d'interpolació, agregació o selecció. Per tant, una decisió aparentment tècnica pot modificar de manera substancial el significat de la variable resultant. Per aquest motiu, **pirineus-raster** no es limita a aplicar una regla genèrica del tipus interpolació bilineal per a variables contínues i veí més proper per a variables categòriques. Al contrari, cada variable pot definir una `value_semantics`, que descriu com s'han d'interpretar els seus valors i orienta el mètode de remostreig més coherent.

Aquesta semàntica no substitueix el criteri de l'investigador, sinó que el fa explícit. El catàleg de fonts pot assignar un mètode per defecte a cada variable, i la configuració de la *run* pot ajustar-lo quan l'objectiu analític ho requereix. Aquesta decisió depèn, com a mínim, de tres factors: el tipus de variable, la resolució nativa de la font i la resolució final de treball. No és el mateix reduir una capa de 10 m a una graella de 100 m, augmentar una font cap a una resolució més fina o mantenir una resolució similar però reprojectar-la a una nova graella. En cada cas, cal valorar si interessa preservar codis, calcular proporcions, conservar totals, suavitzar valors o evitar interpolacions que generarien valors sense sentit.

La taula 3.3 resumeix les semàntiques disponibles, el criteri habitual de tractament i els mètodes que poden ser adients en cada cas. La taula s'ha d'entendre com una guia de decisió, no com una norma rígida aplicable a totes les situacions.

Taula 3.3: Tipus de `value_semantics` i criteris de remostreig.

Semàntica	Exemples	Criteri habitual de tractament	Mètodes adients disponibles
categorical ordinal	Coberta del sòl, geologia, classes forestals o classes ordenades	Preservar codis o classes quan el valor representa una categoria. Si interessa una cobertura proporcional, convé generar fraccions abans del remostreig.	nearest , mode . En casos concrets: category_fraction seguit d' average .
binary	Màscares, presència o absència d'una classe, zones vàlides o no vàlides	Mantenir valors 0/1 si la sortida final és una màscara. Si es vol representar presència parcial dins del píxel final, es pot agregar com a proporció.	nearest , mode , average , min , max .
intensive	Elevació, temperatura, distàncies, índexs de vegetació o biomassa per unitat de superfície	Representar un valor local, mitjà o característic de la cel · la final, sense conservar cap suma total.	bilinear , cubic , cubic_spline , lanczos , average , min , max , med , q1 , q3 .
intensive_depth	Precipitació en mm, acumulacions de neu o variables de profunditat acumulada	Tractar la variable com una intensitat o profunditat per unitat d'àrea, no com un total de cel · la. En conseqüència, no s'ha de redistribuir com si fos una magnitud extensiva.	bilinear , average , min , max , med , q1 , q3 .
percentage fraction ratio	Percentatge de bosc, impermeabilització, fracció de neu o proporcions entre variables	Mantenir rangs i proporcions. En agregacions cap a una graella de més baixa resolució, l'opció més habitual és calcular un valor mitjà representatiu.	average , bilinear , min , max , med , q1 , q3 .
extensive count	Població, superfície construïda, nombre de dies o altres comptatges per cel · la	Preservar magnituds totals quan el valor representa una quantitat acumulada en una cel · la. Aquest cas és especialment sensible quan es canvia de resolució.	sum , conservative_sum , extensive_sum . En alguns casos descriptius: average .
circular	Aspecte, orientació topogràfica o angles	Evitar mitjanes lineals directes, perquè 0 i 360 graus són valors veïns. El tractament ha de respectar la naturalesa angular de la variable.	Remostreig circular específic quan és disponible, components circulars, o criteris conservadors com nearest segons l'ús final.

Els mètodes executables disponibles combinen interpolació raster, estadístics de finestra, agregacions per suma i operacions específiques per a categories. Els mètodes de suma conservadora s'han incorporat per tractar variables extensives, en què el valor representa un total associat a la cel · la i no una intensitat local. Un cas especialment útil és **category_fraction**. Aquesta operació converteix una classe categòrica en una màscara binària en l'espai original i, tot seguit, la remostreja amb mitjana. Així, una cel · la final de 100 m pot representar la fracció de coberta de bosc, matollar, roquissar o una altra categoria dins del píxel. Aquest enfocament evita perdre informació quan es passa d'una font d'alta resolució a una graella més grollera, perquè no força tota la cel · la final a adoptar una única classe dominant. En el cas de l'ós, aquest criteri permet

transformar cobertes del sòl de 10 m en predictors continus de disponibilitat d'hàbitat dins de cada cel·la de modelització.

Així doncs, el remostreig no és un pas merament mecànic, sinó una decisió metodològica cabdal. L'objectiu és modificar la dada original el mínim imprescindible, però prou perquè pugui conviure amb la resta de capes dins d'una mateixa col·lecció de dades. Per això, cada variable ha de ser interpretada segons la seva semàntica, la seva resolució d'origen, la resolució final i l'ús analític previst.

3.4.4 Gestió de valors absents i màscares

La gestió de **NoData** és essencial per construir matrius de modelització. Les fonts originals poden codificar els valors absents amb nombres diferents, màscares internes, absència de píxel o categories específiques. Internament, el sistema treballa amb valors no finits durant el processament i escriu les sortides amb el valor **-9999.0** definit a la configuració global.

Aquesta normalització permet distingir entre tres situacions: píxels fora de l'AOI, zones sense cobertura de la font i valors realment absents dins del domini d'estudi. Sense aquesta distinció, l'extracció de predictors podria barrejar zeros reals amb absències, o considerar com a vàlides cel·les que en realitat no tenen informació.

3.5 Construcció de variables derivades

Moltes variables rellevants per a l'anàlisi ecològica no existeixen directament com a capes originals. Cal construir-les a partir d'altres fonts: el pendent i l'orientació provenen d'un DEM; les distàncies es calculen a partir de màscares o classes territorials; les fraccions d'hàbitat deriven de cobertes del sòl categòriques; i alguns predictors combinen diverses capes mitjançant expressions matemàtiques. Per aquest motiu, **pirineus-raster** incorpora un **motor de variables derivades** dins de la *pipeline*, pensat per transformar capes de font en variables finals més útils per a l'anàlisi espacial i la modelització.

Aquest motor s'integra en el model de *features* del sistema. Cada variable derivada no es defineix només pel seu nom, sinó també pels seus inputs, el tipus d'operació, els paràmetres, la unitat, la semàntica dels valors, el tipus de dada de sortida i, quan escau, el moment en què s'ha d'avaluar l'operació. Això permet encadenar processos: una capa oficial pot generar una màscara; aquesta màscara pot alimentar una distància; i la distància resultant pot transformar-se posteriorment amb una expressió logarítmica. Així, la col·lecció de dades final pot contenir variables ecològicament interpretables sense que l'usuari hagi d'escriure scripts independents per a cada transformació.

Les famílies d'operacions suportades es resumeixen a la taula 3.4. La taula no recull totes les combinacions possibles, perquè aquestes depenen de les fonts i paràmetres seleccionats a cada *run*, però sí que mostra les capacitats principals del sistema.

Taula 3.4: Famílies principals de variables derivades suportades per `pirineus-raster`.

Família	Operacions disponibles	Funció metodològica	Exemples d'ús
Expressions avançades	Operadors aritmètics, comparacions, lògica booleana, constants numèriques, <code>nan</code> i funcions com <code>where</code> , <code>clip</code> , <code>log10</code> , <code>sqrt</code> , <code>minimum</code> i <code>maximum</code> .	Permeten aplicar àlgebra de mapes sobre inputs alineats, crear ràtios, transformacions, índexs compostos o variables encadenades.	<code>log10(x + 1)</code> , <code>where(y > 0, x / y, nan)</code> .
Receptes guiades	<code>thermal_range</code> , <code>water_balance</code> , <code>aridity_index</code> , <code>seasonal_contrast</code> i <code>snow_persistence_ratio</code> .	Formalitzen fórmules habituals amb inputs esperats i validació més estricta que una expressió lliure.	Rang tèrmic, balanç hídric, índex d'aridesa o persistència de neu.
Màscares i reclassificacions	<code>binary_threshold_mask</code> , <code>class_mask</code> i <code>re_classification</code> .	Converteixen variables contínues o categòriques en capes binàries, classes simplificades o codis reclassificats.	Màscara de bosc, reclassificació de litologia o selecció d'una classe de coberta.
Derivades topogràfiques	<code>slope</code> , <code>aspect</code> , <code>ruggedness</code> , <code>tpi</code> i <code>roughness</code> .	Extreuen informació morfològica a partir d'un DEM, ja sigui per cel·la o mitjançant una finestra local.	Pendent, orientació, rugositat o posició topogràfica.
Estadístics focals	<code>mean</code> , <code>std</code> , <code>min</code> , <code>max</code> , <code>sum</code> , <code>majority</code> i <code>diversity</code> .	Resumeixen el context espacial al voltant de cada píxel mitjançant una finestra de radi configurable.	Mitjana local d'elevació, diversitat de cobertes o classe majoritària.
Distàncies espacials	<code>distance_to_mask</code> i <code>distance_to_class</code> .	Calculen la distància euclidiana, en metres, fins a la cel·la positiva o classe categòrica més propera.	Distància a carreteres, pistes, nuclis o elements d'hàbitat.

Una part cabdal d'aquest motor és el sistema d'**expressions avançades**. Aquest mecanisme funciona com una àlgebra de mapes segura: els inputs es representen amb noms simples (principalment `x`, `y` i `z`) i l'usuari pot definir fórmules sobre capes raster ja alineades. S'hi permeten operadors aritmètics (+, -, *, / i **), comparacions, lògica booleana (`and`, `or`, `not`), constants numèriques i la constant `nan`. També s'accepta un conjunt tancat de funcions matemàtiques: `abs`, `sqrt`, `log`, `log10`, `exp`, `minimum`, `maximum`, `where`, `clip` i `isfinite`.

Aquesta flexibilitat no implica executar codi arbitrari. Les expressions es validen abans de l'execució mitjançant un avaluador restringit: no es permeten imports, funcions desconegudes, crides amb arguments amb nom ni estructures de Python alienes a l'àlgebra raster prevista. A més, els resultats no finits (infinitos, divisions invàlides o valors no definits) es transformen en valors absents quan correspon. Això permet escriure expressions útils i relativament complexes, però dins d'un marc controlat. Per exemple, una divisió protegida es pot expressar com `where(y > 0, x / y, nan)`, una distància es pot comprimir amb `log10(x + 1)`, i una combinació de fraccions d'hàbitat es pot limitar amb `minimum(x + y + z, 1)`.

Les **receptes guiades** cobreixen fórmules habituals que convé encapsular de manera més estricta. Per exemple, `thermal_range` calcula la diferència entre temperatura màxima i mínima; `water_balance` resta l'evapotranspiració potencial a la precipitació; `aridity_index` calcula una ràtio entre precipitació i evapotranspiració potencial segons la convenció definida; `seasonal_contrast` compara dues capes (per diferència o ràtio); i `snow_persistence_ratio` divideix els dies amb neu pels dies amb observació vàlida. Aquestes receptes són especialment útils quan es treballa amb variables climàtiques, nivals o estacionals, perquè redueixen errors de formulació i obliguen a fer explícits els inputs necessaris.

El sistema també incorpora operacions de **màscara i reclassificació**. Una màscara de llindar transforma una variable numèrica en una capa 0/1 segons un valor de tall; una màscara de classe selecciona una categoria concreta d'un raster temàtic; i una reclassificació permet mapar codis originals cap a nous valors. Aquest conjunt d'operacions és útil per generar presències d'una classe, simplificar cartografies temàtiques o preparar capes que després alimentaran càlculs de distància.

Cal distingir aquestes màscares de les fraccions categòriques descrites a la secció 3.4.3. La màscara de classe treballa sobre categories ja alineades a la graella final; en canvi, la fracció categòrica preserva la composició subpíxel abans del remostreig.

Les **operacions espacials** aporten context territorial més enllà del valor de cada cel·la. Les derivades topogràfiques calculen pendent i orientació a partir del gradient del DEM, i també mesures locals com la rugositat, el *Topographic Position Index* (TPI) o el *roughness*. Les operacions focals resumeixen l'entorn immediat de cada píxel mitjançant una finestra de radi configurable, amb estadístics com mitjana, desviació típica, mínim, màxim, suma, classe majoritària o diversitat de classes. Finalment, les operacions de distància calculen superfícies contínues de distància fins a una màscara positiva o fins a una classe concreta, cosa que permet representar gradients de pressió humana, accessibilitat o proximitat a determinats elements del paisatge.

Un aspecte metodològic important és **quan** s'avalua una derivada. Algunes operacions es poden calcular directament sobre la graella final (`target_grid`), però d'altres convé executar-les abans del remostreig o en una graella intermèdia més propera a la resolució nativa (`native_then_resample`, `pre_resample` o `source_grid`). Aquesta decisió és especialment rellevant en el cas de les derivades topogràfiques i les finestres focals, ja que calcular el pendent o la rugositat sobre un DEM ja agregat a 100 m pot suavitzar massa el relleu, mentre que calcular-los primer a resolució més fina i agregar-ne després el resultat pot preservar millor l'estructura original. De manera anàloga, una distància calculada sobre una màscara d'alta resolució pot conservar millor la localització d'elements lineals o puntuals abans de transferir-se a la graella final.

En la *run* principal del cas de l'ós, aquestes capacitats es fan servir per construir variables topogràfiques (pendent, aspecte, rugositat, TPI i *roughness*), distàncies a elements humans, transformacions logarítmiques de distància i combinacions de cobertes d'hàbitat. Això permet que el model no treballi només amb capes originals, sinó amb predictors més propers a preguntes ecològiques concretes: complexitat del relleu, disponibilitat d'hàbitat, proximitat a fonts de pertorbació i gradients ambientals interpretables.

3.6 Organització del *dataset* final

3.6.1 Estructura de sortida i productes generats

El resultat de la *pipeline* no és una única capa, sinó un paquet de dades organitzat. Les capes individuals generades per fonts o *features* poden aparèixer a `data_processed/features/`, mentre que les col·leccions finals associades a una *run* s'organitzen a `data_processed/datasets/`. Aquesta distinció és útil perquè una mateixa capa harmonitzada pot reutilitzar-se en diversos projectes, mentre que un *dataset* final representa una execució concreta amb una AOI, una resolució i una selecció de variables determinades.

Cada paquet final conté normalment una carpeta de **rasters**, una carpeta de **metadata**, una carpeta de **config** i, quan escau, una carpeta de **logs**. Els GeoTIFF representen les capes finals; els JSON laterals descriuen metadades per capa; el `manifest.json` actua com a índex del *dataset*; el `run_summary.json` resumeix l'execució; i les còpies de configuració conserven l'escenari que ha produït les sortides.

3.6.2 Metadades, *manifest* i nomenclatura

La nomenclatura dels fitxers és una part pràctica de la traçabilitat. Els noms de sortida tendeixen a incorporar el bloc temàtic, la variable, l'agregació temporal, l'any o l'estació quan aquesta informació és rellevant. Així, noms com `climate_mean_temperature_winter`, `human_logdistance_tracks` o `habitat_tree_cover_density` permeten identificar la naturalesa de la capa abans d'obrir-la.

El *manifest* completa aquesta informació. Mentre que el nom del fitxer facilita l'ús quotidià en *notebooks* o scripts, el *manifest* conserva la relació entre el raster final, la font, la configuració, la ruta original i les metadades associades. Aquesta combinació de noms llegibles i metadades estructurades fa que el *dataset* sigui més còmode d'usar i, alhora, més fàcil d'auditar.

La taula 3.5 resumeix les propietats principals de la *run* de l'ós bru a partir de la configuració disponible al repositori.

Taula 3.5: Resum tècnic de la *run* principal del *dataset* de l'ós bru.

Camp	Valor
<i>Run</i> principal	ursus_arctos_pyrenees_100m.yaml
AOI	ursus_arctos_pyrenees
CRS i resolució	EPSG:3035, 100 m
Dimensions de la graella	3410 columnes × 1600 files (aprox. 5,46 milions de cel·les per capa)
Fonts del catàleg integrades	23 configuracions de fonts
Fonts emprades a la <i>run</i> principal	10 fonts
Entrades de <i>feature</i> definides a la <i>run</i>	29 entrades de <i>feature</i>
Capes finals previstes	41 capes finals (31 de font, 6 espacials i 4 d'expressió)
Volum del <i>dataset</i> final	aproximadament 645 MB
Productes generats	GeoTIFF, metadades JSON, <i>manifest</i> , resum de <i>run</i> , <i>logs</i> i còpies de configuració

3.7 Control de qualitat

La generació automàtica de capes no és suficient si no s'acompanya de controls de qualitat. En aquest projecte, la validació té tres nivells principals: comprovacions geomètriques, comprovacions estadístiques i inspecció visual. Aquestes tres mirades són complementàries. Una capa pot tenir el CRS correcte però valors incoherents; una altra pot tenir valors plausibles però estar desplaçada; i una tercera pot superar comprovacions bàsiques però presentar errors visibles.

3.7.1 Comprovacions geomètriques

Les comprovacions geomètriques verifiquen que cada raster final coincideix amb la graella de referència. El sistema comprova el CRS, l'amplada i alçada de la matriu, la resolució, els límits espacials, el *transform affine*, el nombre de bandes i el valor **NoData**. Aquestes comprovacions són estrictes perquè l'objectiu és poder apilar capes sense cap transformació addicional.

També es valida la pròpia graella. La validació de graella compara el fitxer de referència amb la configuració del projecte i de l'AOI: resolució esperada, bounds, dimensions, CRS i valor **NoData**. D'aquesta manera, abans de processar fonts pesades, el sistema pot assegurar que la base espacial de la run és coherent.

3.7.2 Comprovacions estadístiques

Les comprovacions estadístiques resumeixen el contingut de cada capa: nombre de píxels vàlids, nombre de píxels **NoData**, percentatge d'absència, mínim, màxim, mitjana i desviació estàndard. Aquest resum permet detectar problemes habituals, com capes completament buides, valors fora de rang, factors d'escala no aplicats, unitats inesperades o errors en la codificació de categories.

En variables categòriques, el control estadístic s'ha d'interpretar amb prudència, ja que la mitjana d'una classe no té significat ecològic. En aquests casos, és més útil comprovar valors únics,

presència de categories esperades i coherència amb la reclassificació aplicada. Per contra, en variables contínues o percentuals, els rangs mínim i màxim són especialment informatius.

3.7.3 Inspecció visual i coherència espacial

La inspecció visual és l'últim nivell de control. Serveix per detectar errors que poden passar desapercebuts en comprovacions numèriques: desplaçaments, inversions, vores artificials, discontinuïtats entre *tiles*, patrons de remostreig massa visibles o zones sense cobertura. En aquest sentit, els mapes de control no són només figures decoratives, sinó una part del procés de validació.

Per al *dataset* de l'ós bru, s'han revisat visualment pràcticament totes les capes amb el programari QGIS. No s'hi han detectat desplaçaments, patrons incoherents ni artefactes visuals rellevants. Per aquest motiu, un cop superades les comprovacions geomètriques, estadístiques i visuals, i revisades les metadades corresponents, la col·lecció de dades obtinguda s'ha considerat coherent i apta per alimentar el cas d'ús.

3.8 Síntesi tècnica del procés de generació

L'objectiu d'aquest capítol era explicar com **pirineus-raster** transforma fonts ambientals heterogènies en una col·lecció de dades raster preparada per a l'anàlisi. Un cop descrit el procés complet, es pot afirmar que aquesta transformació no depèn d'una única operació, sinó de la combinació ordenada de les següents decisions tècniques: la definició d'una AOI compatible amb una graella regular, l'adopció d'un sistema de referència comú, la ingesta de fonts diverses, el tractament temporal, el retall espacial, la reprojecció, el remostreig semàntic, la generació de variables derivades, l'organització de sortides i el control de qualitat.

El resultat metodològic més rellevant és, en conseqüència, la construcció d'un flux capaç de convertir dades inicialment no comparables en capes coherents entre si. Les fonts originals difereixen en resolució, CRS, format, cobertura territorial, temporalitat, semàntica de valors i mecanismes d'accés. Tanmateix, la *pipeline* les condueix cap a una mateixa representació final: fitxers GeoTIFF alineats, documentats, amb NoData coherent, metadades associades i una nomenclatura prou explícita per poder ser reutilitzats sense repetir manualment el preprocessament. En aquest sentit, el valor del procés no rau només a obtenir capes, sinó a garantir que es poden apilar, inspeccionar, auditar i utilitzar conjuntament.

Convé remarcar que l'element vertebrador de tot aquest procés és la graella comuna. Totes les operacions descrites convergeixen a fer que variables provinents de fonts molt diferents acabin compartint extensió, resolució, alineació de píxels i sistema de coordenades. Per tant, el retall, la reprojecció i el remostreig no són passos auxiliars, sinó les operacions que fan possible la comparabilitat espacial. De manera semblant, la gestió de valors absents i de màscares evita que les diferències de cobertura entre fonts esdevinguin errors silenciosos en les anàlisis posteriors.

Un altre resultat rellevant és la incorporació d'una lògica de processament sensible al significat de les variables. El sistema no tracta de la mateixa manera una classe de coberta del sòl, una temperatura, un recompte de població, una fracció de neu o una orientació topogràfica. La

semàntica de valors, els criteris de remostreig, les fraccions categòriques i les variables derivades permeten que la col·lecció final no sigui només homogènia des del punt de vista geomètric, sinó també més coherent des del punt de vista analític. Això és especialment important en estudis ecològics, on una decisió aparentment menor (com representar una coberta categòrica per classe dominant o per fracció de cobertura) pot modificar el sentit del predictor resultant.

En el cas d'ús de l'ós bru, tots aquests processos es concreten en la configuració de la *run ursus_arctos_pyrenees_100m.yaml*. Tal com resumeix la taula 3.5, aquesta *run* selecciona una part del catàleg ambiental, treballa sobre l'AOI *ursus_arctos_pyrenees*, adopta una resolució de 100 m i genera un conjunt de capes finals que combinen variables directes de font, derivades espacials i expressions. Aquesta col·lecció de dades no és encara el model ecològic, sinó la seva base territorial i ambiental: el producte intermedi imprescindible que permet construir posteriorment la matriu de modelització.

Així doncs, el capítol assoleix l'objectiu plantejat inicialment: demostrar com una eina configurable pot passar de fonts geoespacials disperses a un *dataset* ambiental harmonitzat, verificable i preparat per alimentar anàlisis espacials. El capítol següent parteix precisament d'aquesta col·lecció de dades per avaluar-ne la utilitat en un cas d'ús realista de modelització ecològica de femelles d'ós bru amb cries als Pirineus.

Capítol 4

Cas d'ús: modelització ecològica de l'ós bru als Pirineus

Els capítols anteriors han presentat **pirineus-raster** com una eina per construir col·leccions de dades raster ambientals harmonitzades. Aquest capítol trasllada aquesta base a un cas d'ús ecològic concret: la modelització de la idoneïtat d'hàbitat de femelles d'ós bru (*Ursus arctos*) amb cries als Pirineus. El cas d'ús permet comprovar, en un escenari aplicat, fins a quin punt les capes generades són aptes per alimentar un flux complet de *Species Distribution Modelling* (SDM), però també serveix per explorar una aproximació metodològica pròpia i complementària als treballs previs.

El punt de partida conceptual és la línia desenvolupada en el marc de CARTOBIO, que ha modelitzat l'hàbitat de l'ós bru al Pirineu separant grups d'edat i sexe, amb una atenció específica a les femelles amb cries menors d'un any [1], [19]. En aquest marc, les zones utilitzades durant els primers mesos de vida de les cries es consideren especialment rellevants per a la conservació de l'espècie [2]. Aquest treball manté aquesta orientació ecològica, però no pretén reproduir literalment l'exercici CARTOBIO. Al contrari, l'utilitza com a referència per avaluar una proposta alternativa basada en models d'arbres, validació per individu, estimació d'incertesa i auditoria amb observacions independents.

Així doncs, el capítol té una doble lectura. D'una banda, documenta una modelització aplicada a un segment demogràfic sensible de l'ós bru pirinenc. De l'altra, actua com a prova exigent de la col·lecció de dades construïda al capítol 3, ja que si aquesta permet extreure predictors, construir matrius de modelització, entrenar models, generar mapes, classificar zones i contrastar resultats amb dades independents, aleshores el procés desenvolupat als capítols anteriors assoleix la seva finalitat aplicada.

4.1 Objectiu del cas d'ús

L'objectiu general del cas d'ús és desenvolupar i avaluar una modelització d'idoneïtat relativa d'hàbitat per a femelles d'ós bru amb cries als Pirineus, emprant com a base la col·lecció de dades ambientals de 100 m generada amb **pirineus-raster**. Aquest objectiu combina dues preguntes complementàries: primer, si una aproximació basada en Random Forest, XGBoost, combinacions ponderades i validació *leave-one-individual-out* pot oferir resultats coherents i interpretables respecte del marc CARTOBIO/MaxEnt; i segon, si el *dataset* generat és prou complet i robust per sostenir tot el flux SDM, des del càlcul de predictors fins a la producció de mapes finals.

L'anàlisi es concreta en dues classes independents: femelles amb cries de menys de sis mesos (1t6) i femelles amb cries d'entre sis i dotze mesos (6to12). Aquesta separació segueix el criteri adoptat en treballs previs i respon a la hipòtesi que els patrons d'ús de l'espai poden variar durant el primer any de vida de les cries [1], [2]. Per tant, el capítol no modelitza l'espècie en conjunt, sinó un segment demogràfic concret, sensible i rellevant per a la conservació.

Les dades biològiques disponibles condicionen la formulació del problema. Es disposa de localitzacions GPS de femelles monitoritzades i d'observacions independents, però no d'absències reals. Una cel·la sense registre no pot interpretar-se com una cel·la no utilitzada per l'espècie, ja que pot correspondre a una zona no mostrejada, a un període sense seguiment o a un individu no monitoritzat. Per aquest motiu, el problema es formula com una comparació entre localitzacions conegudes d'ús i punts de *background* que representen les condicions ambientals disponibles dins del domini d'estudi.

En conseqüència, la sortida del model s'interpreta com una mesura de **idoneïtat relativa d'hàbitat**, no com una probabilitat absoluta d'ocurrència. El valor assignat a cada cel·la ordena el territori segons la seva semblança ambiental amb les localitzacions utilitzades per les femelles monitoritzades, sota les decisions adoptades sobre dades biològiques, domini de *background*, predictors ambientals, algorisme i estratègia de validació.

Els objectius específics del cas d'ús són: construir les dades de modelització a partir de les capes ambientals i les dades biològiques; comparar dominis d'entrenament regional i localment accessible; avaluar Random Forest, XGBoost i combinacions ponderades mitjançant validació per individu; contrastar aquesta validació amb una partició aleatòria 75/25 tal com s'usa en models clàssics de SDM; generar mapes continus, zones categòriques i superfícies d'incertesa; i discutir la coherència dels resultats amb CARTOBIO i amb observacions independents, sense presentar-los com una substitució de la cartografia experta o oficial.

4.2 Context ecològic i referència metodològica

L'ós bru (*Ursus arctos*) als Pirineus és una espècie legalment protegida i catalogada com a “en perill d'extinció” [20], [21]. L'estratègia estatal per a la conservació de l'ós bru als Pirineus estableix com a objectius garantir el manteniment d'un hàbitat de qualitat, assegurar la connectivitat entre nuclis de població i augmentar el coneixement sobre l'espècie i el seu hàbitat [20]. En aquest context, la modelització espacial de la idoneïtat d'hàbitat no és només un exercici predictiu, sinó una eina potencialment útil per entendre quines condicions ambientals poden ser més favorables per a la conservació de l'espècie.

Dins d'aquest marc general, aquest capítol se centra en les femelles amb cries perquè representen un segment demogràfic especialment sensible. Els primers mesos de vida condicionen fortament la supervivència de les cries, i treballs recents han mostrat la conveniència d'integrar aquests períodes crítics en la regulació temporal de les activitats humanes [2]. A més, CARTOBIO també tracta específicament les femelles amb cries menors d'un any i diferencia entre cries de 0 a 6 mesos i cries de 6 a 12 mesos, ja que aquests dos estadis poden presentar patrons espacials i necessitats ecològiques diferents [1]. Per aquest motiu, aquest treball adopta la mateixa divisió

en dues classes de modelització: **1to6** i **6to12**.

La tria d'aquest segment no implica que el model descrigui l'ús de l'hàbitat de tots els óssos del Pirineu. Al contrari, respon a una decisió deliberadament conservadora. Les femelles amb cries tenen menys marge per a desplaçaments extensos i poden ser més sensibles a factors com el refugi, la disponibilitat de recursos, la tranquil·litat de l'entorn i la baixa pertorbació humana. Per tant, les seves localitzacions poden aportar informació especialment valuosa sobre ambients que no només són utilitzats per l'espècie, sinó que poden reunir condicions compatibles amb la reproducció i la supervivència de les cries. Aquesta lectura és coherent amb el plantejament de CARTOBIO, on la modelització de femelles amb cries s'utilitza per contribuir a la identificació d'àrees crítiques de l'ós bru als Pirineus [1].

Aquesta orientació té una conseqüència important per a la interpretació dels resultats. Els mapes generats en aquest capítol no busquen representar la distribució global de l'ós bru ni substituir les delimitacions expertes o oficials. Més aviat, ordenen el territori segons la semblança ambiental amb les localitzacions conegudes de femelles amb cries, assumint que aquestes localitzacions poden actuar com a indicadors d'hàbitats relativament segurs i funcionals per a una fase especialment exigent del cicle vital de l'espècie. Això pot fer que el model sigui més restrictiu que una modelització de l'espècie en conjunt, però també més prudent des d'una perspectiva de conservació.

El projecte CARTOBIO s'utilitza com a referència principal perquè proporciona un marc metodològic i ecològic directament comparable. En el treball esmentat es van usar variables ambientals actualitzades, dades de telemetria GPS i observacions de camp per modelitzar diferents grups d'óssos al Pirineu. Les variables es van adaptar a una resolució de 100 m i es van agrupar en blocs topogràfics, d'hàbitat i humans [1]. Els models es van desenvolupar amb MaxEnt, un mètode àmpliament utilitzat en modelització de distribució d'espècies amb dades de presència i *background* [22], i els resultats finals es van sintetitzar tant en mapes continus de qualitat d'hàbitat com en categories d'àrees adequades, bones i òptimes [1], [19].

Aquest projecte pren el treball esmentat com a punt de partida per tres motius. Primer, perquè proporciona una justificació clara per focalitzar-se en femelles amb cries i separar les dues classes d'edat de les cries. Segon, perquè fixa una escala espacial comparable, 100 m, adequada per combinar predictors ambientals i dades de localització. Tercer, perquè ofereix una metodologia de categorització d'àrees rellevants que permet comparar, amb prudència, els productes finals d'idoneïtat. Ara bé, la proposta d'aquesta memòria no pretén replicar literalment CARTOBIO ni afirmar una superioritat general sobre aquest exercici. La contribució pròpia consisteix a construir una anàlisi complementària, en la qual s'amplia i harmonitza el conjunt de predictors, es comparen algorismes d'aprenentatge automàtic i s'introdueix una validació més exigent orientada a la transferència entre individus.

4.3 Dades d'entrada per al model

El model combina dues famílies de dades. La primera és biològica i descriu localitzacions de femelles d'ós bru amb cries. La segona és ambiental i prové del *dataset* raster generat per

pirineus-raster. La combinació de totes dues fonts es produeix només després d'haver verificat que els rasters s'han validat correctament i presenten valors vàlids i lògics, tal com s'ha exposat al capítol anterior.

4.3.1 Dades biològiques: GPS, observacions i classes de cria

Les dades biològiques es divideixen en dos orígens: localitzacions de telemetria **GPS** i observacions independents **OBS**. Les dades **GPS** provenen de femelles equipades amb collarets de posicionament en períodes concrets i, per tant, tenen l'avantatge de descriure trajectòries espacials amb una precisió elevada i amb menor dependència de l'accessibilitat humana en el territori. Tanmateix, sí que poden presentar un biaix per individu, ja que només alguns exemplars han estat monitoritzats, i no tots aporten el mateix nombre de registres. En el cas de les femelles amb cries utilitzades en aquest treball, les localitzacions **GPS** corresponen a quatre femelles concretes, Hvala, Melba, Sorita i Ziva, també identificades al treball de referència CARTOBIO [1].

Aquest desequilibri entre individus és una característica habitual de les dades de telemetria ecològica. Una femella monitoritzada durant més temps, o amb una freqüència de registre més elevada, pot aportar moltes més localitzacions que una altra, i això pot fer que el model aprengui en excés les condicions ambientals associades a un sol individu. Per reduir aquest efecte, el tractament inicial conserva una única observació per combinació d'óssa, estació i cel·la de 100 m, i posteriorment aplica una separació mínima de 100 m de la resta de localitzacions de la mateixa óssa-estació. Aquesta decisió busca disminuir la redundància espacial i temporal de registres molt propers, mantenint alhora informació suficient per capturar l'ús de l'espai de cada femella [23]. A més, la validació *leave-one-individual-out* descrita més endavant reforça aquesta precaució, ja que avalua la capacitat del model de transferir-se a una femella que no ha estat usada en l'entrenament.

Les dades **OBS**, en canvi, provenen d'observacions independents de camp. Poden incloure registres procedents de càmeres de fototrampeig, trapes de pèl, observacions visuals, rastres, petjades o altres evidències de presència. Aquestes dades són molt valuoses perquè amplien el conjunt de localitzacions conegudes i poden incorporar registres d'individus o situacions no coberts per la telemetria. Ara bé, no tenen la mateixa naturalesa que les **GPS**. En general, és més probable obtenir observacions en zones accessibles, visibles, freqüentades per equips de seguiment o properes a punts de mostreig. CARTOBIO ja assenyala aquest possible biaix espacial de les observacions: un os pot ser més fàcilment detectat fora del bosc o en zones accessibles que no pas en indrets tancats, remots o poc prospectats [1], [24].

Per aquest motiu, en aquesta anàlisi les dades **OBS** no s'usaran per entrenar ni ajustar els models. Fer-ho podria introduir en el model patrons associats no només a la selecció d'hàbitat de l'espècie, sinó també a la probabilitat humana de detectar-la. En lloc d'això, les **OBS** es mantenen fora de tot el procés d'entrenament i es reserven per a una auditoria externa final. Aquesta decisió dona més força a la validació, perquè si un model entrenat exclusivament amb **GPS** assigna valors d'idoneïtat més elevats a observacions independents que a punts de *background*, això suggereix que el patró aprèn no depèn únicament de les femelles monitoritzades, sinó que captura part d'una estructura ambiental coherent amb altres registres de presència.

El tractament inicial elimina duplicats, conserva només les dues classes de cria considerades (*lt6* i *6to12*), filtra els punts situats dins l'AOI del projecte, interpreta dates amb formats mixtos i assigna a cada registre un mes, una estació i un grup diari. Posteriorment, les coordenades es transformen al CRS de treball i s'assignen a la graella oficial de 100 m. Aquest pas és important perquè la unitat real de modelització no és el punt GPS original, sinó la cel·la raster sobre la qual es poden extreure els predictors ambientals generats al capítol 3.

La taula 4.1 resumeix el volum de dades disponible després del tractament. Les dades GPS constitueixen la base d'entrenament, validació interna i generació de mapes; les OBS, en canvi, queden reservades per a la validació externa descrita a la secció 4.5.4. La figura 4.1 mostra, a més, la distribució estacional dels registres GPS retinguts, un aspecte rellevant perquè les dues classes de cria no es distribueixen de manera uniforme al llarg de l'any.

Taula 4.1: Dades biològiques utilitzades en el cas d'ús després del tractament inicial.

Classe de cria	Origen	Registres utilitzats	Individus o mostra	Ús dins del flux
lt6	GPS	561	4 femelles: Hvala, Melba, Sorita i Ziva	Entrenament, validació LOIO, calibratge fora de mostra i generació de mapes.
6to12	GPS	866	4 femelles: Hvala, Melba, Sorita i Ziva	Entrenament, validació LOIO, calibratge fora de mostra i generació de mapes.
lt6	OBS	266	Observacions independents	Auditoria externa posterior a la selecció del model.
6to12	OBS	901	Observacions independents	Auditoria externa posterior a la selecció del model.

La distribució estacional dels registres GPS, representada a la figura 4.1, mostra una diferència clara entre les dues classes de cria. Aquesta diferència no és accidental, sinó que respon al calendari biològic de l'espècie: les cries neixen durant el període d'hivernada, de manera que els registres de la classe *lt6* es concentren principalment en primavera i estiu, mentre que els registres de la classe *6to12* apareixen sobretot a l'estiu i la tardor. L'absència o escassetat de registres hivernals també és coherent amb el comportament de l'ós bru, ja que durant la hibernació no es considera una fase activa comparable a la resta de l'any dins del flux de modelització. Aquest patró reforça la necessitat d'incorporar variables ambientals amb component temporal o estacional: les dues classes no només representen edats diferents de les cries, sinó també finestres ecològiques diferents dins del cicle anual. Per aquest motiu, en la predicció espacial final s'utilitza una estació representativa per a les variables estacionals, concretament primavera per a *lt6* i tardor per a *6to12*, d'acord amb la temporalitat ecològica dominant de cada classe.




Figura 4.1: Distribució estacional dels registres GPS retinguts per classe de cria.

La distribució espacial de les cel·les ocupades es representa a la figura 4.2. Aquesta figura és important perquè mostra que els individus no ocupen exactament el mateix àmbit espacial. Per tant, una validació aleatòria podria barrejar punts propers o similars en entrenament i test, fent que els resultats fossin més alts del que realment el model és capaç de generalitzar; mentre que una validació per individu pregunta si el model és capaç de transferir-se a una óssa que no ha participat en l'ajust.




Figura 4.2: Cel·les de 100 m ocupades per les femelles monitoritzades, separades per classe de cria.

4.3.2 Variables ambientals explicatives

Les variables explicatives provenen de la col·lecció de dades generada al capítol 3. La sortida inicial conté 41 capes raster finals alineades a 100 m, però aquestes capes no s'usen directament com a 41 predictors independents. Abans de modelitzar, el flux les consolida en variables conceptuals: les capes estacionals s'agrupen sota un mateix predictor, les variables estàtiques o anuals es mantenen com a descriptors globals, i l'aspecte topogràfic es transforma en dues components circulars, sinus i cosinus, per evitar discontinuïtats entre 0 i 360 graus.

A partir d'aquest conjunt candidat es fa una revisió de redundància abans d'entrenar els models.

Es calcula una matriu de correlacions entre predictors extrets als punts de presència per detectar variables que representen gradients molt similars. A partir d'aquesta informació, combinant la interpretabilitat ecològica, el grau de correlació i la utilitat per a l'objectiu final, es decideix el conjunt de predictors que formarà el *dataset* final preparat per a l'anàlisi.

Finalment es conserven 24 predictors. D'entre els descartats, es troben temperatura màxima, temperatura mínima, pendent, *roughness* i densitat de coberta arbòria. Les temperatures màxima i mínima es retiren perquè el gradient tèrmic ja queda representat per la temperatura mitjana estacional; el pendent i el *roughness*, perquè són parcialment redundants amb la rugositat i els índexs de posició topogràfica; i la densitat de coberta arbòria, perquè el bloc d'hàbitat ja incorpora biomassa, productivitat i fraccions forestals diferenciades. La taula 4.2 resumeix el *dataset* final de modelització, seguint una lògica comparable a CARTOBIO però incorporant també variables climàtiques, nivals i hídriques generades per `pirineus-raster` [1].

Taula 4.2: Variables explicatives finals utilitzades en la modelització.

Bloc	Variable final	Font principal	Tractament aplicat	Temporalitat
Topografia	Elevació	Copernicus DEM GLO-30 [8]	Retall, reprojecció a EPSG:3035, re-	Estàtica
Topografia	Rugositat	Copernicus DEM GLO-30 [8]	Derivada del DEM per representar	Estàtica
Topografia	TPI mitjà	Copernicus DEM GLO-30 [8]	complexitat local del relleu.	
Topografia	TPI macro	Copernicus DEM GLO-30 [8]	Posició topogràfica respecte l'entorn	Estàtica
Topografia	Aspecte, sinus	Copernicus DEM GLO-30 [8]	a escala mitjana.	
Topografia	Aspecte, cosinus	Copernicus DEM GLO-30 [8]	Posició topogràfica respecte l'entorn	Estàtica
			ampli, aproximadament 5 km.	
			Orientació transformada en compo-	Estàtica
			nent sinus per tractar la circularitat.	
			Orientació transformada en compo-	Estàtica
			nent cosinus, complementària al si-	
			nus.	
Hàbitat	Biomassa	ESA CCI Biomass [12]	Biomassa aèria harmonitzada i agre-	Estàtica
Hàbitat	Productivitat	Copernicus HR-VPP	gada a la graella de 100 m.	
Hàbitat	Fracció de	[10]	Productivitat vegetal agregada i har-	Anual
Hàbitat	frondoses	Copernicus CLMS	monitzada a la graella comuna.	
Hàbitat	Fracció de	Forest [15]	Classes forestals convertides en frac-	Estàtica
Hàbitat	coníferes	Copernicus CLMS	ció de cobertura per cel · la.	
Hàbitat	Bosc mixt	Forest [15]	Classes de coníferes convertides en	Estàtica
		Copernicus CLMS	fracció de cobertura per cel · la.	
		Forest; derivada [15]	Combinació de frondoses i coníferes	Estàtica
Hàbitat	Pastures	Copernicus CLMS	per representar mosaic mixt.	
		Grasslands [16]	Producte de pastures convertit en	Estàtica
Hàbitat	Matollars	Copernicus CLC+	fracció de cobertura per cel · la.	
		Backbone [17]	Reclassificació de vegetació llenyosa	Estàtica
Hàbitat	Roquissars i	Copernicus CLC+	baixa i fracció de cobertura.	
	tarteres	Backbone [17]	Reclassificació de sòl nu i vegetació	Estàtica
			escassa en fracció de cobertura.	
Clima, neu	Temperatura	PDCA Topoclimate	Capes estacionals harmonitzades i Hiv., prim., estiu,	
i aigua	mitjana	1950–2012 [9]	mostrejades segons la data del regis-	tardor
			tre.	
Clima, neu	Precipitació anual	PDCA Topoclimate	Precipitació anual mitjana harmonit-	Anual
i aigua		1950–2012 [9]	zada a 100 m.	
Clima, neu	Radiació solar	PDCA Topoclimate	Radiació anual mitjana harmonitza-	Anual
i aigua	anual	1950–2012 [9]	da amb la graella de modelització.	
Clima, neu	Disponibilitat	PDCA Topoclimate	Balanç hídric estacional mostrejat Hiv., prim., estiu,	
i aigua	hídrica	1950–2012 [9]	segons la data del registre.	tardor
Clima, neu	Fracció de neu	Copernicus HRSI FSC	Fracció de neu agregada per períodes; Hivern i primavera	
i aigua		[11]	valor nul a estiu/tardor.	
Pressió	Distància log. a	OpenStreetMap [13]	Extracció, rasterització, distància eu-	Estàtica
humana	pistes		clidiana i transformació logarítmica.	
Pressió	Distància log. a	OpenStreetMap [13]	Carreteres secundàries, distància mí-	Estàtica
humana	carreteres		nima i transformació logarítmica.	
Pressió	Distància log. a	OpenStreetMap [13]	Nuclis o assentaments, distància mí-	Estàtica
humana	nuclis		nima i transformació logarítmica.	
Pressió	Usos humans	OpenStreetMap [13]	Rasterització d'usos humans com a	Estàtica
humana			indicador binari de presència.	
Pressió	Densitat de	GHSL GHS-POP	Població harmonitzada i expressada	Estàtica
humana	població	R2023A [14]	com a densitat mitjana per cel · la.	

La taula recull els predictors finals utilitzats per construir la matriu d'entrada dels models. Algunes variables tenen dimensió estacional; això no vol dir que es tractin com a predictors independents per a cada estació, sinó que el valor assignat a cada registre depèn de la data de l'observació. Així, una mateixa variable conceptual pot prendre el valor de primavera, estiu, tardor o hivern segons el període ecològic corresponent.

Un cop definit el conjunt final de predictors, es fa una última comprovació de la relació entre variables. L'objectiu no és intentar que totes les variables siguin independents entre si, cosa poc realista en dades ambientals, sinó identificar possibles redundàncies fortes abans d'interpretar els resultats del model. Per aquest motiu, es calcula la correlació de Spearman entre predictors als punts de presència i es representa a la figura 4.3. Aquesta anàlisi mostra que alguns gradients ambientals continuen relacionats, especialment en el bloc climàtic i topogràfic. Això no impedeix l'ús de Random Forest o XGBoost, ja que aquests models poden treballar amb predictors parcialment correlacionats, però sí que obliga a interpretar amb prudència la importància individual de cada variable: quan dos predictors descriuen informació semblant, el pes atribuït a cadascun pot dependre del model, de la mostra i de la resta de variables disponibles.

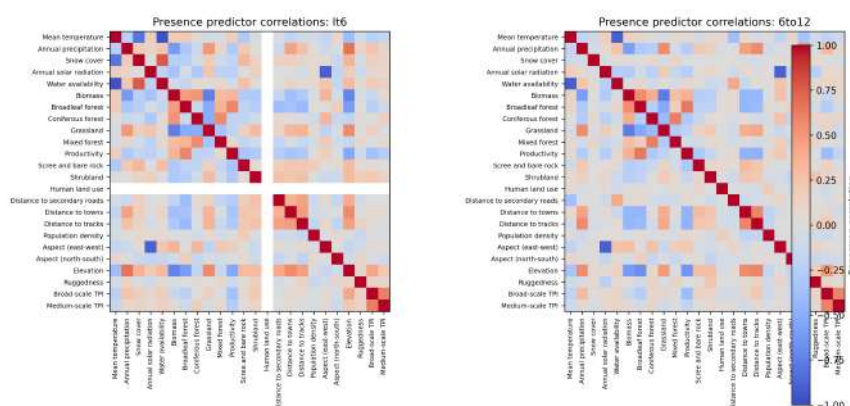


Figura 4.3: Correlació de predictors en les presències de les dues classes de cria.

4.3.3 Construcció de la matriu de modelització

La matriu de modelització és la taula que transforma les capes raster en dades directament utilitzables pels models. Es construeix associant a cada presència i a cada punt de *background* el valor dels predictors ambientals corresponents. En el cas de les variables estàtiques o anuals, el valor s'extreu directament de la capa raster. En canvi, per a les variables estacionals, es fa servir la capa que correspon a l'estació de cada registre en concret. Així, una presència de primavera incorpora les condicions ambientals de primavera, mentre que una presència de tardor incorpora les de tardor. Per als punts de *background*, l'estació s'assigna aleatòriament d'acord amb la distribució estacional de les presències de la mateixa classe de cria. Aquest tractament permet mantenir un únic model per a cada classe de cria, però sense perdre del tot la informació temporal associada a les observacions.

Els punts de *background* es mostregen en dos àmbits espacials diferents, cosa que permet entrenar i comparar models sota dues definicions de disponibilitat ambiental. El primer és l'A0I pirinenca completa de l'ós bru, que representa la disponibilitat ambiental a escala regional. Aquest àmbit inclou una gran diversitat d'ambients, alguns molt allunyats de les zones utilitzades per les femelles monitoritzades. Aquest fet pot facilitar la discriminació entre presències i *background*, ja que és més senzill aprendre a separar hàbitats clarament diferents que discriminar entre ambients molt semblants. Per aquest motiu, les mètriques regionals poden resultar més optimistes que les

obtingudes en una avaluació local.

El segon àmbit és un domini més local, construït a partir del polígon que dibuixen les presències de cada femella, ampliat amb un buffer de 25 km i retallat als límits de l'AOI. Aquest domini no representa una àrea oficial ni completa de l'hàbitat de l'ós, sinó una aproximació de l'espai que les femelles monitoritzades podrien haver tingut més a l'abast. En aquest cas, el repte és més exigent, perquè el model ha d'aprendre a distingir entre ambients més semblants entre si i, per tant, ha d'identificar diferències més fines dins del territori proper a les presències observades. Aquesta aproximació també pot ser més sensible a les particularitats de cada femella i al nombre limitat d'individus disponibles.

Aquesta doble definició del *background* permet comparar dues maneres d'entendre la disponibilitat ambiental. D'una banda, es pot entrenar i avaluar un model en el context regional complet. De l'altra, es pot entrenar i avaluar un model en un context local més restrictiu. Posteriorment, aquests models es contrastaran sobre el domini alternatiu, per ajudar a valorar si un model només funciona bé en el seu propi context o si manté capacitat de generalització. La taula 4.3 resumeix els dos àmbits de mostreig, i la figura 4.4 en mostra la relació amb les presències GPS i els punts de *background*.

Taula 4.3: Àmbits espacials utilitzats per generar els punts de *background*.

Àmbit	Àrea geomètrica	Àrea amb predictors complets	Components	Ús
AOI completa	54.560,0 km ²	46.795,9 km ²	1	Representa la disponibilitat regional del Pirineu i permet avaluar el model en un context ampli.
Domini local	10.775,9 km ²	10.378,0 km ²	2	Representa una disponibilitat més propera a les femelles monitoritzades i obliga el model a discriminar ambients més semblants.




Figura 4.4: AOI completa, domini local accessible, presències GPS i punts de *background*.

Per evitar fugues d'informació entre *train* i *test*, els punts de *background* es divideixen des de l'inici en conjunts independents d'entrenament i d'avaluació. Per a cada àmbit espacial es generen 10.000 cel·les d'entrenament i 2.000 cel·les d'avaluació, sense solapament entre conjunts. D'aquesta manera, tots els models es comparen sobre els mateixos punts d'avaluació i les diferències entre algorismes o àmbits d'entrenament no depenen d'haver utilitzat punts de *background* diferents.

La taula 4.4 resumeix la matriu de modelització que alimenta els models finals. El fet que no hi hagi cel·les amb predictors absents en el conjunt reduït és una evidència operativa de la coherència del *dataset* generat amb *pirineus-raster*: les capes es poden apilar i consultar de manera consistent en tots els punts utilitzats pel procés.

Taula 4.4: Mida de les taules finals de modelització per classe de cria.

Classe	Pres.	Local entren.	Regional entren.	Local aval.	Regional aval.	Missing
1t6	561	10.000	10.000	2.000	2.000	0
6to12	866	10.000	10.000	2.000	2.000	0

Les presències es ponderen perquè cada óssa tingui el mateix pes total i, dins de cada óssa, cada dia observat tingui el mateix pes. Això redueix l'efecte de trajectòries GPS molt denses i evita que l'augment en freqüència o duració del monitoratge GPS domini per sobre de la informació ecològica.

4.4 Estratègia metodològica

4.4.1 Relació amb l'enfocament CARTOBIO/MaxEnt

MaxEnt és una aproximació clàssica i àmpliament emprada per modelitzar distribució d'espècies amb dades de presència i *background* [22]. En el treball CARTOBIO, els models d'ós bru es van ajustar amb MaxEnt, 10.000 punts de *background* i iteracions aleatòries d'entrenament i test,

obtenint mapes continus de qualitat relativa d'hàbitat i mapes categòrics que classifiquen àrees en no adequades, adequades, bones o òptimes [1].

Aquest projecte conserva diversos elements d'aquesta referència: la mateixa font de dades per a les presències d'ós, la separació de dues classes de femelles amb cries, una resolució de 100 m, l'ús de variables topogràfiques, d'hàbitat i de pressió humana, el mateix *background* regional complet i la categorització en zones d'hàbitat. No obstant això, se'n modifiquen tres aspectes rellevants. Primer, el *dataset* elaborat amb **pirineus-raster** manté la lògica dels blocs de variables de CARTOBIO, però hi afegeix predictors climàtics, nivals i hídrics considerats rellevants per al cas d'ús. Segon, els models emprats són Random Forest i XGBoost, escollits per la seva capacitat de capturar relacions no lineals, interaccions entre predictors i patrons espacials complexos [25], [26]. Tercer, l'avaluació principal és *leave-one-individual-out*, més estricta que una partició aleatòria (75/25) perquè deixa completament fora una óssa en cada fold i, per tant, avalua millor la capacitat de generalització del model.

Aquestes diferències fan que la comparació amb CARTOBIO no s'hagi d'entendre com una competició directa entre mapes. Més aviat, el cas d'ús representa una anàlisi complementària al treball de referència i planteja la pregunta següent: què passa si, mantenint l'escala i el plantejament ecològic de referència, s'usa una col·lecció de predictors harmonitzada automàticament (**pirineus-raster**), models d'arbres i una validació LOIO? Aquesta pregunta és rellevant tant per valorar la solidesa de **pirineus-raster** com per explorar alternatives metodològiques en SDM. Una partició aleatòria pot produir bones mètriques si punts propers del mateix individu apareixen tant en entrenament com en test. En canvi, deixar fora una óssa sencera avalua la capacitat del model de generalitzar a un individu no vist, una qüestió més exigent i ecològicament més prudent.

4.4.2 Models d'aprenentatge automàtic i candidats comparats

El procés d'entrenament es planteja com una comparació sistemàtica de candidats. Per a cada classe de cria i per a cada domini espacial d'entrenament, s'ajusten models Random Forest i XGBoost, se n'optimitzen els hiperparàmetres i, posteriorment, es construeixen combinacions ponderades de les seves prediccions. D'aquesta manera, el model final no es decideix només entre dos algorismes, sinó entre diverses alternatives definides pel tipus de model, el domini d'entrenament i el rendiment obtingut en validació.

El Random Forest combina molts arbres de decisió entrenats sobre mostres i subconjunts de variables, fet que el fa robust davant relacions no lineals i interaccions complexes [25]. L'XGBoost, en canvi, construeix arbres seqüencialment i corregeix errors de prediccions anteriors mitjançant *gradient boosting*, amb regularització i control explícit de la complexitat [26]. A més dels dos algorismes purs, es comparen tres combinacions ponderades: RF 25% - XGBoost 75%, RF 50% - XGBoost 50% i RF 75% - XGBoost 25%. Aquestes combinacions permeten valorar si una mitjana ponderada entre candidats redueix la variabilitat i millora la robustesa de les prediccions.

La comparació també incorpora el domini espacial d'entrenament. Cada algorisme es prova tant amb el conjunt regional, basat en l'AOI completa, com amb el conjunt local, basat en l'àmbit accessible al voltant de les femelles monitoritzades. Per tant, un candidat final queda definit per

la combinació entre domini d'entrenament i tipus de model. Aquesta decisió permet comprovar si els models entrenats en un context regional generalitzen millor, o si el domini local permet discriminar amb més precisió hàbitats semblants als realment utilitzats per les femelles amb cries.

Els hiperparàmetres s'ajusten dins del procés d'entrenament de RF i XGBoost. En el cas de RF, es fa una cerca aleatòria sobre combinacions de paràmetres com el nombre d'arbres, la profunditat màxima, el nombre de variables candidates per partició i el nombre mínim de mostres per fulla. En el cas de XGBoost, la cerca es fa amb Optuna, que explora de manera optimitzada combinacions de profunditat, taxa d'aprenentatge, *subsampling*, regularització i altres paràmetres. En tots dos casos, l'objectiu és trobar la configuració que maximitza el rendiment del model en validació interna, sense utilitzar la informació reservada per al test extern del fold.

Per evitar que l'avaluació sigui massa optimista, l'ajust dels hiperparàmetres es fa sempre sense utilitzar l'individu que queda reservat per al test. Així, quan es validen els diferents models amb una óssa que no ha participat en l'entrenament, aquesta tampoc ha influït en la tria dels hiperparàmetres, de manera que les mètriques finals no quedin contaminades per informació de l'individu retingut. Finalment, tots els candidats es comparen amb els mateixos conjunts d'avaluació local i regional, i per a cada classe de cria se selecciona el model que ofereix el millor equilibri entre rendiment, estabilitat i capacitat de generalitzar a altres àmbits.

4.4.3 Validació *leave-one-individual-out*

La validació principal és *leave-one-individual-out* (LOIO). En cada iteració, totes les dades d'una óssa es reserven com a test i el model s'entrena amb la resta d'individus. Aquest procediment s'aplica per cada classe de cria i per cada candidat de model. En cada fold, les presències de l'individu retingut es comparen amb dos escenaris de *background* d'avaluació: el local i el regional complet.

Aquesta estratègia és més conservadora que una validació aleatòria. La telemetria GPS genera punts autocorrelacionats en l'espai i el temps, de manera que, si els punts d'una mateixa trajectòria es dividissin aleatòriament entre entrenament i test, el model podria semblar molt bo perquè reconeix entorns molt semblants als que ja ha vist. En canvi, LOIO força el model a transferir-se a un individu nou. Per això, les mètriques LOIO s'interpreten com la prova principal de generalització, mentre que les mètriques 75/25 aleatòries només s'usen per facilitar la comparació amb CARTOBIO.

Per triar el model final de cada classe de cria s'aplica un criteri de selecció pensat per prioritzar la robustesa, i no només el millor resultat mitjà. Primer es maximitza el pitjor valor entre tres indicadors: AUC-ROC mitjà local, AUC-ROC mitjà regional i pitjor AUC-ROC local per individu. Després es resolen empats amb AUC-ROC mitjà, Boyce mitjà i Brier score. Finalment, un model només es considera *management-ready* si el Boyce local mitjà no és negatiu. Si no supera aquest llindar, el millor candidat es conserva com a exploratori.

4.4.4 Calibratge, bootstrap i validació externa

Un cop seleccionat el model final, es torna a entrenar amb el conjunt de dades corresponent i se'n generen 10 rèpliques mitjançant *bootstrap*. El *bootstrap* consisteix a construir diverses versions del conjunt d'entrenament remostrejant les dades disponibles, de manera que es pugui observar fins a quin punt el resultat depèn de la mostra concreta utilitzada. En aquest cas, el remostreig no es fa punt a punt, sinó per dies observats dins de cada óssa. Això és important perquè les localitzacions GPS d'un mateix dia no són completament independents entre elles i formen part d'una mateixa trajectòria. D'aquesta manera, el *bootstrap* manté millor l'estructura temporal de les dades i permet generar una predicció mitjana més estable. La superfície contínua final correspon a la mitjana de les prediccions de les rèpliques.

A més de generar una predicció mitjana, les rèpliques *bootstrap* permeten estimar una part de la incertesa del model. Si les rèpliques produeixen valors semblants en una zona, el resultat és més estable respecte a la mostra d'entrenament. En canvi, si les prediccions varien molt entre rèpliques, aquella zona s'interpreta com a més sensible a la composició de les dades utilitzades. Aquesta informació no substitueix la validació del model, però ajuda a distingir entre àrees amb idoneïtat consistent i àrees on la predicció és més fràgil.

Les prediccions també es calibren amb informació fora de mostra. Quan és possible, s'utilitza regressió isotònica; si no, una regressió logística actua com a alternativa. Aquest calibratge ajusta l'escala de les puntuacions perquè siguin més coherents amb el comportament observat en validació, però no les converteix en probabilitats absolutes d'ocurrència, ja que la prevalença depèn del mostreig de *background*. Per tant, la interpretació correcta continua essent la d'un índex d'idoneïtat relatiu a les presències detectades.

Les observacions OBS es mantenen completament fora de l'entrenament, la selecció de models, els llinars i el calibratge. Només s'utilitzen al final, com a auditoria externa. Per a cada classe de cria, es comparen les OBS amb un nombre igual de punts de *background* regional i s'avalua si les observacions independents reben valors d'idoneïtat superiors. La prova de Mann–Whitney unilateral quantifica aquesta comparació de manera no paramètrica.

4.4.5 Mètriques d'avaluació

L'avaluació combina diverses mètriques per descriure diferents propietats del model de presència-*background* [3].

L'**AUC-ROC** mesura la capacitat del model d'ordenar presències per sobre dels punts de *background* [27]. Es pot expressar com:

$$\text{AUC}_{\text{ROC}} = \frac{1}{n_+ n_-} \sum_{i=1}^{n_+} \sum_{j=1}^{n_-} \left(I(s_i^+ > s_j^-) + 0,5 I(s_i^+ = s_j^-) \right).$$

Aquesta expressió representa la probabilitat que una presència triada a l'atzar rebi una puntuació més alta que un punt de *background* triat a l'atzar. Pren valors entre 0 i 1: 0,5 indica un comportament equivalent a l'atzar, valors propers a 1 indiquen una bona separació, i valors

inferiors a 0,5 indiquen una ordenació pitjor que l'atzar.

L'**AUC-PR** és l'àrea sota la corba precisió-*recall* [28]. La precisió i el *recall* es defineixen com:

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}.$$

Per tant,

$$\text{AUC}_{\text{PR}} = \int_0^1 \text{Precision}(r) dr.$$

Aquesta mètrica dona més importància a la capacitat de recuperar presències i a la fiabilitat dels punts classificats com a favorables. Pren valors entre 0 i 1 i, en aquest treball, com que l'avaluació aplica pesos equilibrats entre presències i *background*, aquest valor de referència és aproximadament 0,5.

El **Boyce index** avalua si les presències observades es concentren en els intervals de major idoneïtat predita [29]. Per cada interval k del gradient d'idoneïtat, es compara la proporció de presències observades amb la proporció d'àrea disponible:

$$\left(\frac{P}{E}\right)_k = \frac{u_k/U}{a_k/A}, \quad B = \rho_{\text{Spearman}}(c_k, (P/E)_k).$$

El valor final és una correlació de Spearman entre la idoneïtat dels intervals i la ràtio presència/disponibilitat. Pren valors entre -1 i 1: valors positius indiquen que les presències es concentren en zones d'alta idoneïtat, valors propers a 0 indiquen poca relació, i valors negatius indiquen un patró contrari al desitjat.

El **TSS** (*True Skill Statistic*) avalua el model després de transformar la puntuació contínua en una classificació binària [30]. Es calcula com:

$$\begin{aligned} \text{TSS} &= \text{Sensitivity} + \text{Specificity} - 1 \\ &= \frac{TP}{TP + FN} + \frac{TN}{TN + FP} - 1. \end{aligned}$$

En aquest treball, el llindar de classificació es tria amb el criteri de Youden, és a dir, el punt de tall que maximitza aquest mateix equilibri entre sensibilitat i especificitat. El TSS pren valors entre -1 i 1: 1 indica classificació perfecta, 0 indica un resultat equivalent a l'atzar, i valors negatius indiquen una classificació pitjor que l'atzar.

El **Brier score** mesura l'error quadràtic mitjà entre la puntuació predita i la classe observada [31]. Es calcula com:

$$\text{Brier} = \frac{1}{N} \sum_{i=1}^N (\hat{p}_i - y_i)^2.$$

En classificació binària pren valors entre 0 i 1, i valors més baixos indiquen prediccions més ajustades. A diferència de l'AUC, no mesura només si els punts estan ben ordenats, sinó també si les puntuacions assignades són coherents amb la classe observada.

El **log-loss** o pèrdua logística mesura el cost d'assignar una determinada puntuació a la classe observada [32]. Es calcula com:

$$\text{LogLoss} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)].$$

Aquesta mètrica penalitza especialment les prediccions molt segures però equivocades. Pren valors a partir de 0 i no té límit superior; com més baix és el valor, millor és el comportament del model.

En les fórmules, s_i^+ és la puntuació assignada a una presència, s_j^- la puntuació assignada a un punt de *background*, n_+ el nombre de presències i n_- el nombre de punts de *background*. $I(\cdot)$ és una funció indicadora que val 1 si la condició és certa i 0 si és falsa. TP , FP , TN i FN representen, respectivament, veritables positius, falsos positius, veritables negatius i falsos negatius. En el Boyce index, u_k és el nombre de presències dins l'interval k , U el nombre total de presències, a_k l'àrea o nombre de cel·les disponibles dins l'interval, A l'àrea o nombre total de cel·les disponibles, c_k el valor central de l'interval i ρ_{Spearman} la correlació de Spearman. Finalment, y_i és la classe observada, amb valor 1 per a presència i 0 per a *background*, $\hat{p}_i$ és la puntuació predita pel model i N és el nombre total d'observacions avaluades.

4.5 Resultats del model

4.5.1 Rendiment predictiu i selecció de models

La taula 4.5 resumeix els dos models finals seleccionats i el seu comportament en els dos escenaris principals d'avaluació: el domini local i l'AOI completa. Aquesta separació és important perquè les dues avaluacions no responen exactament la mateixa pregunta. L'avaluació regional mesura fins a quin punt el model separa les presències respecte del conjunt ampli de condicions disponibles als Pirineus, mentre que l'avaluació local comprova si aquesta separació es manté quan el model ha de discriminar entre ambients més propers i més semblants als utilitzats per les femelles monitoritzades.

Taula 4.5: Rendiment dels models finals sota validació *leave-one-individual-out*.

Classe	Model final	Avaluació	AUC-ROC	AUC-PR	Boyce	TSS	Brier	Estat
1t6	RF25-XGB75	Local	0,773	0,719	0,283	0,494	0,279	<i>management-ready</i>
1t6	RF25-XGB75	Regional	0,914	0,864	0,385	0,745	0,258	<i>management-ready</i>
6to12	RF	Local	0,724	0,640	-0,377	0,433	0,365	Exploratori
6to12	RF	Regional	0,887	0,818	-0,255	0,718	0,355	Exploratori

Per a **1t6**, el model final és una combinació ponderada entre Random Forest i XGBoost, amb un pes del 25% per a RF i del 75% per a XGBoost. Els resultats indiquen una gran capacitat de discriminació, amb valors de l'AUC-ROC del 0,773 en avaluació local i del 0,914 en avaluació regional. L'AUC-PR també és clarament superior al valor de referència aproximat de 0,5, amb valors de 0,719 i 0,864 respectivament, fet que indica que el model concentra bona part de les presències en valors alts d'idoneïtat.

El resultat més important en **1t6** és que el Boyce és positiu tant en l'avaluació local com en la regional. Això vol dir que, a mesura que augmenta la idoneïtat predita, les presències tendeixen a aparèixer amb més freqüència. Per tant, el model no només separa presències i *background*, sinó que també genera una gradient d'idoneïtat coherent amb les dades retingudes en validació. Per aquest motiu, i segons el criteri establert en aquest treball, el model es considera *management-ready*. Aquesta etiqueta, però, no implica que el mapa sigui una delimitació oficial, sinó que el resultat supera els controls interns de robustesa definits per al cas d'ús.

Per a **6to12**, el model final és un Random Forest entrenat sobre l'A0I completa. Les mètriques mostren que no es tracta d'un mal model, ja que s'obtenen valors en l'AUC-ROC de 0,724 en avaluació local i de 0,887 en avaluació regional, i en l'AUC-PR de 0,640 i 0,818 respectivament. Aquests valors indiquen que el model té capacitat de discriminar presències respecte del *background*, especialment a escala regional. A més, el TSS regional de 0,718 mostra que, un cop fixat un llindar de classificació, el model separa força bé zones favorables i no favorables en el context ampli de l'A0I.

Tanmateix, el model **6to12** queda classificat com a exploratori perquè el Boyce local mitjà és negatiu. Aquesta és una diferència important respecte de l'AUC-ROC, i és que un model pot predir raonablement bé presències i *background* en termes generals, però no generar una gradient d'idoneïtat prou coherent dins del domini elegit. En aquest cas, el resultat suggereix que, quan l'avaluació es fa sobre ambients més semblants i amb individus no vistos, les presències de **6to12** no es concentren de manera prou consistent en les classes més altes d'idoneïtat. Per això, les zones categòriques derivades d'aquest model s'han d'interpretar amb més prudència.

Una hipòtesi plausible per entendre aquesta diferència entre classes d'edat és que les femelles amb cries de 6 a 12 mesos poden tenir una mobilitat més gran que les femelles amb cries més petites i, per tant, utilitzar un rang més ampli d'hàbitats. Això pot fer que el senyal ecològic sigui més difús i que sigui més difícil resumir-lo en un gradient local estable. A aquesta dificultat s'hi afegeix el nombre reduït d'individus monitoritzats, que limita la capacitat del model per capturar patrons generals més enllà de les particularitats de cada femella.

A causa del resultat exploratori en la classe **6to12**, s'han revisat les mètriques de tots els candidats entrenats per comprovar si algun model *management-ready* havia quedat descartat pel criteri de selecció. El resultat d'aquesta revisió és clar: cap dels models provats assoleix un Boyce local mitjà positiu. Per tant, la classificació exploratòria no deriva d'una mala elecció del candidat final, sinó d'una limitació compartida per tots els models en aquesta classe. Tot i obtenir bones mètriques de discriminació, especialment en AUC-ROC, el gradient local d'idoneïtat no és prou consistent per interpretar les zones de **6to12** amb el mateix grau de confiança que les de **1t6**.

4.5.2 Interpretació de les variables importants

La importància de variables s'ha estimat mitjançant *out-of-fold permutation importance*. En aquest procediment, cada predictor es desordena en el conjunt de test de l'individu retingut i es mesura quanta capacitat predictiva perd el model. Per tant, una variable és important si, quan se'n trenca la relació amb les presències, el rendiment del model empitjora. Els resultats principals es resumeixen a la taula 4.6

Els resultats d'importància de variables s'han d'interpretar amb prudència. Les variables topogràfiques tenen un pes elevat en les dues classes, especialment l'elevació i la rugositat. Això és coherent amb el cas d'estudi, però no necessàriament vol dir que aquestes variables actuïn com a factors causals directes. En bona part, poden estar resumint una lògica territorial ja coneguda: l'hàbitat de les femelles amb cries es concentra en ambients pirinencs de muntanya, sovint forestals, humits i relativament allunyats de la presència humana. En aquest context, l'elevació ajuda a separar grans gradients del territori: zones fora de l'àmbit pirinenc, fons de vall més humanitzats i sectors de muntanya més propers als ambients utilitzats per l'espècie.

Una lectura semblant es pot fer de la rugositat. Les zones més planes tendeixen a correspondre, sovint, a fons de vall, zones agrícoles, nuclis o espais més accessibles. En canvi, els sectors més rugosos poden indicar vessants, boscos de muntanya, barrancs o àrees més difícils d'accedir. Per tant, la importància d'aquestes variables no aporta necessàriament una explicació ecològica nova, però sí que confirma que el model està capturant gradients territorials coherents amb el coneixement previ sobre l'espècie i amb la distribució observada de les presències.

Per a 1t6, destaca especialment la distància logarítmica a pistes. Aquesta variable és interpretable com un indicador indirecte de pertorbació i accessibilitat humana. Té sentit que les femelles amb cries molt petites apareguin associades a ambients més tranquils o més allunyats de vies d'accés, ja que aquesta és la fase més sensible del període reproductor. En canvi, per a 6to12, la importància es reparteix més entre elevació, rugositat, biomassa i disponibilitat hídrica. Aquesta combinació suggereix un patró menys restringit, on el model continua capturant el gradient de muntanya, però també comencen a aparèixer variables relacionades amb l'estructura forestal i la productivitat dels hàbitats.

Les variables de biomassa i disponibilitat hídrica també s'han de llegir conjuntament amb la resta del bloc ambiental. Encara que no representin exactament el mateix, poden estar relacionades amb ambients forestals, humits i productius, que són més compatibles amb l'ús de l'espai per part de l'ós bru que no pas les zones obertes d'alta muntanya sense bosc o els fons de vall més humanitzats. Això reforça la idea que el model no identifica només una variable aïllada, sinó un conjunt de condicions ambientals que, combinades, descriuen millor els hàbitats potencialment favorables.

Finalment, cal recordar que la importància per permutació pot quedar afectada per la correlació entre predictors. Quan dues variables expliquen una part semblant del gradient ambiental, el model pot mantenir part del rendiment encara que se'n desordeni una, perquè l'altra conserva informació relacionada. Això pot fer que algunes variables ecològicament importants apareguin amb una importància menor del que s'esperaria. A la inversa, variables menys correlacionades amb la resta, com la distància a pistes, poden destacar més perquè aporten informació més

específica. Per aquest motiu, les rellevàncies no s'han de llegir com un rànquing causal estricte, sinó com una eina per entendre quins gradients ambientals han ajudat més el model a discriminar presències i *background*. Aquesta cautela és especialment important en 6to12, ja que el model final d'aquesta classe ha estat classificat com a exploratori.

Taula 4.6: Principals predictors segons importància per permutació fora de mostra.

Classe	Predictor	Pèrdua AUC	Lectura principal
1t6	Distància logarítmica a pistes	0,0665	Possible indicador de pertorbació o accessibilitat humana.
1t6	Elevació	0,0594	Gradient altitudinal i condicions associades al relleu.
1t6	Rugositat	0,0527	Complexitat topogràfica i disponibilitat potencial de refugi.
1t6	Precipitació anual	0,0254	Gradient climàtic associat a condicions humides i de muntanya.
6to12	Elevació	0,0569	Gradient altitudinal dominant.
6to12	Rugositat	0,0555	Relleu complex i heterogeneïtat territorial.
6to12	Biomassa	0,0289	Estructura forestal i disponibilitat d'hàbitat.
6to12	Disponibilitat hídrica	0,0254	Gradient climàtic i productiu associat a condicions ambientals favorables.




Figura 4.5: Importància per permutació fora de mostra per a les dues classes de cria.

4.5.3 Mapes d'idoneïtat i classificació de zones

Els productes espacials finals inclouen, per a cada classe de cria, un mapa continu d'idoneïtat relativa, un mapa categòric de zones i una superfície d'incertesa relativa. El mapa continu és el producte principal, perquè conserva tota la gradació espacial de la predicció. Les zones adequades, bones i òptimes són una síntesi posterior basada en lindars, i per tant s'han d'interpretar com una classificació derivada, no com una delimitació oficial.

La temporada representativa del mapa final és primavera per a **1t6** i tardor per a **6to12**. Aquesta decisió afecta només la projecció cartogràfica final. Durant l'entrenament, cada observació utilitza les variables estacionals corresponents a la seva data. La figura 4.6 mostra els mapes continus, les zones derivades i la incertesa relativa. Per consultar cada mapa amb més resolució, vegeu l'annex E.




Figura 4.6: Mapes finals d'idoneïtat, zones categòriques i incertesa relativa per a **1t6** i **6to12**.

Els lindars de les diferents zones es calculen amb dues aproximacions complementàries. La primera és una versió compatible amb la metodologia emprada en **CARTOBIO**, en què el llinar de zona adequada es defineix com la mitjana del 10% de presències amb menor puntuació d'idoneïtat en el mapa continu; a continuació, el llinar de zona bona es calcula com la mitjana dels valors de tots els píxels del mapa que superen el llinar de zona adequada; finalment, el llinar de zona òptima es calcula de la mateixa manera, com la mitjana dels píxels que superen el llinar de zona bona [1]. Aquesta aproximació manté una lectura metodològicament comparable amb la cartografia de referència, però es calcula sobre les puntuacions del model final ajustat.

La segona aproximació aplica la mateixa recurrència de lindars, però modifica l'origen de les puntuacions utilitzades per definir el primer tall. En lloc d'emprar les puntuacions de presència del model final, utilitza les puntuacions calibrades fora de mostra obtingudes durant la validació **LOIO**; és a dir, cada presència contribueix al llinar amb una predicció generada per un model que no havia estat entrenat amb l'individu corresponent. A partir d'aquest primer llinar, els lindars de zona bona i zona òptima es calculen sobre el mapa final calibrat, fent la mitjana dels píxels que superen successivament el tall anterior. Aquesta segona aproximació és més prudent, perquè redueix el risc que la categorització depengui de puntuacions massa optimistes del model

ajustat final. En tots dos casos, els fragments connectats menors de 0,5 km² s'eliminen, seguint el criteri de no considerar petits polígons aïllats com a zones suficients per a femelles amb cries [1].

Els mapes categòrics mostrats a la figura 4.6 corresponen a aquesta segona aproximació, implementada com a llindars calibrats fora de mostra. Els valors categòrics van del 0 al 3, els quals indiquen zona no adequada, zona adequada, zona bona i zona òptima, respectivament.

La comparació entre àrees classificades mostra que el pas de mapa continu a categories és molt sensible al criteri de llindar. En particular, els llindars calibrats generen una categoria adequada molt extensa, especialment per a **1t6**. Això no invalida el mapa, però sí que remarca que s'ha de prendre amb cautela, ja que la informació més estable és el gradient continu d'idoneïtat, mentre que les categories serveixen com a resum visual i depenen de decisions metodològiques concretes. Aquesta prudència és encara més necessària en **6to12**, perquè el model final ha estat classificat com a exploratori.

4.5.4 Validació externa amb observacions independents

La validació externa amb observacions **OBS** serveix per comprovar si els mapes finals són coherents amb registres de presència que no han intervingut en cap fase del model. Aquestes observacions no s'han utilitzat ni en l'entrenament, ni en la selecció dels candidats, ni en el càlcul dels llindars. Per tant, funcionen com una prova complementària, permetent veure si el model assigna valors d'idoneïtat alts a punts d'observació independents.

Els resultats són coherents en les dues classes de cria. En **1t6**, les **OBS** obtenen una idoneïtat mitjana de 0,654, molt per sobre del valor mitjà del *background* regional, que és de 0,201. En **6to12**, el patró es repeteix, ja que les **OBS** tenen una mitjana de 0,383, mentre que el *background* queda en 0,059. L'AUC-ROC de l'auditoria externa també és elevat i molt semblant en totes dues classes, amb valors de 0,925 i 0,926. Això indica que, a escala regional, els mapes tendeixen a assignar més idoneïtat a observacions independents que no pas a punts disponibles del territori.

Taula 4.7: Auditoria externa amb observacions independents **OBS**.

Classe	N OBS	Mitjana OBS	Mitjana <i>background</i>	AUC-ROC	Boyce
1t6	266	0,654	0,201	0,925	0,964
6to12	901	0,383	0,059	0,926	0,976

Com ja s'ha comentat anteriorment, aquesta auditoria amb **OBS** no substitueix les validacions anteriors, sinó que afegeix una comprovació complementària amb dades independents. En aquest sentit, el resultat és força positiu: les observacions de femelles amb cries, que no han participat en l'entrenament ni en la selecció dels models, reben valors d'idoneïtat clarament superiors als del *background* regional. Això indica que els models no només funcionen sobre les dades **GPS** utilitzades per construir-los, sinó que també són capaços de reconèixer com a favorables altres punts on realment s'han observat femelles amb cries. Per tant, tot i les cauteles metodològiques ja exposades, l'auditoria externa reforça la coherència general dels mapes i mostra que els models tenen una capacitat predictiva prou bona sobre dades que no havien vist prèviament.

4.5.5 Comparació amb CARTOBIO/MaxEnt

La comparació amb CARTOBIO s'ha d'entendre com una referència metodològica i cartogràfica, no com una competició directa. Els dos exercicis comparteixen escala de treball, classes de cria i voluntat de generar mapes d'idoneïtat i zones rellevants. També comparteixen la idea que les femelles amb cries menors de sis mesos i les de sis a dotze mesos poden utilitzar el territori de manera diferent [1].

La diferència principal és el disseny de validació. CARTOBIO reporta AUC mitjans elevats per als models MaxEnt de femelles amb cries, amb valors de 0,943 per a cries de menys de 6 mesos i 0,930 per a cries de 6 a 12 mesos. En aquest projecte, les validacions aleatòries 75/25 també donen valors molt elevats, 0,965 i 0,977 respectivament. Tanmateix, les mètriques LOIO són més baixes, especialment en el domini local. Això no implica necessàriament un pitjor model, sinó una major exigència en la validació de la generalització.

Taula 4.8: Comparació sintètica entre el plantejament CARTOBIO i el cas d'ús d'aquest treball.

Aspecte	CARTOBIO/MaxEnt	Aquest treball
Objectiu	Cartografia d'hàbitat i àrees rellevants de l'ós bru per grups d'edat i sexe.	Modelització complementària amb RF/XGBoost i validació de la col·lecció de dades generada per pirineus-raster en un flux SDM complet.
Classes tractades	Femelles amb cries, femelles sense cries i mascles.	Només femelles amb cries 1t6 i 6to12 .
Algorisme principal	MaxEnt.	RF, XGBoost i combinacions ponderades.
Validació principal	Particions internes i AUC mitjà.	Validació <i>leave-one-individual-out</i> , més auditoria OBS externa.
Productes finals	Qualitat d'hàbitat i zones adequades, bones i òptimes.	Idoneïtat relativa contínua, zones derivades, incertesa relativa i diagnòstics d'extrapolació.

La lectura final és que aquest treball parteix del marc conceptual de CARTOBIO, però no es limita a reproduir-lo. Hi afegeix una infraestructura de dades reproduïble, una avaluació més explícita de la robustesa i una família de models alternativa basada en arbres de decisió. El resultat és, per tant, complementari però també comparable: quan la comparació es fa en condicions semblants, mitjançant una validació aleatòria 75/25, els models desenvolupats en aquest treball obtenen mètriques igualment elevades, fins i tot superiors en alguns indicadors. Ara bé, aquesta lectura s'ha de fer amb prudència, ja que no es disposa d'una validació equivalent a LOIO per als resultats de CARTOBIO. Per això, més que afirmar una superioritat directa, el valor del cas d'ús rau a mostrar que el *dataset* generat, els models d'arbres i les decisions metodològiques adoptades poden produir resultats competitiu i, alhora, avaluats amb criteris de robustesa més exigents.

4.6 Síntesi del cas d'ús

El cas d'ús permet tancar la doble pregunta plantejada a l'inici del capítol. Des del punt de vista tècnic, la col·lecció de dades generada amb **pirineus-raster** ha estat suficient per construir una matriu de modelització completa, sense valors absents en els punts utilitzats, i per sostenir un flux complet que inclou entrenament, validació per individu, calibratge, estimació d'incertesa, generació de mapes i auditoria externa. Això demostra que l'eina no només produeix capes raster harmonitzades, sinó que aquestes capes poden alimentar una anàlisi ecològica exigent i reproduïble.

Des del punt de vista ecològic i metodològic, els resultats són coherents però demanen una lectura prudent. El model **1t6** mostra un patró d'ideïtat relativament estable i supera els criteris interns de robustesa definits. El model **6to12**, en canvi, conserva capacitat predictiva i obté una auditoria externa positiva, però no aconsegueix la consistència local requerida pel Boyce per considerar-se *management-ready*. Aquesta diferència no invalida el cas d'ús; al contrari, mostra que el procediment és capaç de distingir entre resultats més robustos i resultats que s'han de mantenir en un pla exploratori.

En conjunt, el capítol mostra que **pirineus-raster** pot servir com a base per a models d'ideïtat d'hàbitat comparables amb aproximacions de referència, però també que la qualitat del resultat final depèn de la naturalesa de les dades biològiques, del domini de *background*, del disseny de validació i de la interpretació experta dels mapes. Per aquest motiu, els productes obtinguts s'han d'entendre com una aportació complementària i reproduïble, no com una substitució de la cartografia experta o de les decisions de gestió.

Conclusions i treball futur

5.1 Síntesi del treball desenvolupat

Aquest treball ha desenvolupat `pirineus-raster`, una eina de processament geoespacial configurable, reproduïble i extensible per generar *datasets* raster ambientals harmonitzats als Pirineus. El projecte parteix d'una necessitat molt concreta, que és la dificultat de construir una base ambiental coherent quan les fonts disponibles, malgrat ser nombroses i sovint d'accés obert, no han estat pensades per conviure directament dins d'una mateixa anàlisi. Les capes difereixen en sistema de referència de coordenades, resolució, extensió, estructura temporal, semàntica de variable, convencions de `NoData` i mecanismes de distribució, de manera que qualsevol estudi que vulgui integrar-les acaba assumint una feina prèvia d'harmonització que acostuma a ser llarga, repetitiva i poc documentada.

La resposta proposada ha consistit a transformar aquesta dificultat en un flux de treball formalitzat. `pirineus-raster` separa codi, configuració i dades, de manera que les configuracions `YAML` defineixen l'àrea d'interès, la resolució, les fonts, les variables i les sortides, mentre que el sistema interpreta aquestes decisions de manera estable i auditable. El compilador de configuracions converteix definicions d'alt nivell en plans d'execució concrets, el catàleg de fonts encapsula les particularitats de 23 productes ambientals, el motor de variables derivades permet construir predictors ecològicament interpretables sense recórrer a scripts puntuals, i el sistema de validació, metadades i *manifests* garanteix que cada producte final pugui ser revisat, entès i regenerat.

Sobre aquesta infraestructura s'ha construït i validat un *dataset* ambiental de 41 capes raster alineades a 100 m per al domini pirinenc de l'ós bru (`ursus_arctos_pyrenees`), a partir de 10 fonts del catàleg. Aquest *dataset* ha alimentat un flux complet de modelització d'idoneïtat d'hàbitat per a femelles d'*Ursus arctos* amb cries, que ha inclòs entrenament de Random Forest i XGBoost, validació *leave-one-individual-out*, calibratge, estimació d'incertesa, generació de mapes i auditoria externa amb observacions independents. En conseqüència, el cas d'ús no només ha servit per obtenir uns mapes finals, sinó també per comprovar que el procés desenvolupat és capaç de sostenir una anàlisi ecològica exigent de principi a fi.

5.2 Grau d'assoliment dels objectius

Els objectius específics formulats a la introducció s'han assolit de manera satisfactòria, tot i que cadascun d'ells ho ha fet amb un abast diferent i amb les limitacions pròpies d'un treball que combina desenvolupament de programari, integració de dades geoespacial i modelització

ecològica aplicada.

L'objectiu de dissenyar i implementar una arquitectura reproduïble i configurable queda cobert pel funcionament general de **pirineus-raster**. L'eina disposa d'una *pipeline* executable per CLI, amb etapes diferenciades de descàrrega, retall, harmonització, derivades, validació i empaquetament, i es fonamenta en un model de configuració que permet adaptar l'experiment sense modificar el codi intern. Aquesta separació és la que converteix el projecte en una infraestructura reutilitzable i no en un conjunt de scripts lligats a un únic cas d'ús.

També s'ha assolit l'objectiu d'integrar fonts heterogènies en una graella comuna. Les 10 fonts emprades en la *run* principal i les 23 fonts del catàleg han estat organitzades dins d'un mateix marc de processament, i la graella de referència garanteix que les capes finals comparteixin **CRS**, extensió, resolució, *transform affine* i **NoData**. Les comprovacions geomètriques i la inspecció visual han permès verificar que les sortides generades són apilables i comparables cel · la a cel · la.

El tercer objectiu, relacionat amb la definició de *datasets* mitjançant configuracions d'alt nivell orientades a *features*, s'ha materialitzat en el compilador de configuracions i en el model de variables finals. L'usuari pot descriure predictors en termes conceptuals, mentre que el sistema resol les dependències, interpreta les fonts, aplica les opcions temporals i tradueix aquesta definició en una seqüència d'operacions concreta. Això redueix la distància entre la pregunta ambiental que es vol estudiar i el processament tècnic necessari per preparar-ne les dades.

Pel que fa a la generació de productes raster *analysis-ready*, el resultat és igualment satisfactori. El *dataset* final inclou fitxers **GeoTIFF** alineats, metadades per capa, *manifest* del conjunt, còpies de configuració i *logs* d'execució. La inspecció en **QGIS** no ha revelat desplaçaments ni artefactes espacials rellevants, i les comprovacions estadístiques han permès detectar i revisar la coherència dels valors generats. Per tant, les sortides no són només fitxers raster, sinó productes documentats i preparats per a l'anàlisi.

L'objectiu de validar l'eina mitjançant el cas d'ús de l'ós bru també s'ha assolit. El *dataset* generat ha sustentat tot el flux **SDM** sense valors absents en cap dels punts de modelització, i tant la classe **1to6** com la classe **6to12** han produït mètriques raonables, mapes interpretables i una auditoria externa positiva. Ara bé, el grau de confiança no és el mateix en totes dues classes, ja que el model **1to6** supera els criteris interns de robustesa, mentre que **6to12** queda justificadament classificat com a exploratori.

La comparació amb **CARTOBIO/MaxEnt** s'ha pogut dur a terme, però amb la prudència necessària. La validació principal d'aquest treball és **L0I0**, mentre que **CARTOBIO** reporta mètriques obtingudes en particions internes, i per això la comparació directa no pot llegir-se com una competició entre models. Quan s'usa una partició aleatòria 75/25, més propera a l'esquema clàssic, els models d'arbres obtenen mètriques igualment elevades i, en alguns indicadors, lleugerament superiors. Tanmateix, la conclusió rellevant no és una superioritat absoluta, sinó la coherència general dels resultats i el valor d'una aproximació complementària, més estricta en la validació entre individus.

Finalment, l'objectiu de documentar decisions tècniques, limitacions i instruccions de reproduïbilitat queda recollit tant en el cos de la memòria com en els annexos. L'annex de reproduïbilitat descriu l'entorn, les ordres de configuració, la creació de graelles, l'execució de la *pipeline*, la

validació de resultats i el flux del *notebook* del cas d'ús, de manera que el treball no queda restringit als resultats obtinguts, sinó que deixa constància del camí necessari per arribar-hi.

5.3 Aportacions de *pirineus-raster*

La contribució central de *pirineus-raster* no és el *dataset* concret que genera, sinó la infraestructura que fa possible generar-lo, revisar-lo i adaptar-lo. Aquesta distinció és important, perquè un script capaç de preparar un conjunt de capes per a un cas particular pot tenir utilitat immediata, però difícilment resol el problema general de la fragmentació de les fonts geoespacionals. *pirineus-raster*, en canvi, proposa un marc de treball que pot créixer amb noves fonts, noves àrees d'interès, noves resolucions i nous casos d'ús.

La primera aportació tècnica és l'arquitectura configurable. La separació entre configuració, codi i dades permet modificar completament l'àrea d'estudi, la resolució, les fonts o les variables sense alterar la lògica interna del sistema. Aquesta decisió fa que el projecte sigui més mantenible, més fàcil de versionar i més adequat per a recerca reproducible. La segona aportació és la gestió semàntica del remostreig, ja que l'eina no tracta igual una categoria, una variable intensiva, una magnitud extensiva, una fracció, un percentatge o una variable circular. D'aquesta manera, les capes finals no són només coherents geomètricament, sinó també més fidels al significat ambiental de les variables que representen.

Una tercera aportació és el motor de variables derivades, que integra expressions algebraiques segures, receptes guiades, derivades topogràfiques, estadístics focals i distàncies a màscares dins del mateix flux de traçabilitat que la resta de capes. Aquesta capacitat és especialment rellevant perquè molts predictors útils en ecologia no existeixen directament com a fonts originals, sinó que s'han de construir a partir de transformacions, agregacions o relacions espacionals. Finalment, el *workbench* visual en React aporta una capa d'usabilitat que facilita la creació i revisió de configuracions complexes, sense renunciar al principi fonamental del projecte, que és acabar sempre en un fitxer **YAML** formal, revisable i executable.

Des del punt de vista de la comunitat científica i tècnica, l'aportació de *pirineus-raster* es pot entendre com una reducció de la distància entre l'existència de fonts ambientals obertes i la seva utilitat real en anàlisi espacial. Disposar de dades Copernicus, PDCA, WorldClim, ESA, OpenStreetMap o GHSL no equival automàticament a tenir un *dataset* harmonitzat i preparat. L'eina desenvolupada en aquest TFG se situa precisament en aquest espai intermedi, sovint invisible però decisiu, on les dades passen de ser productes dispersos a convertir-se en una base comuna per a la recerca.

5.4 Conclusions sobre el cas de l'ós bru

El cas d'ús ha complert la doble funció prevista, ja que ha validat la utilitat de les dades generades i ha permès explorar una metodologia complementària a CARTOBIO en el context de la modelització d'idoneïtat d'hàbitat per a femelles d'*Ursus arctos* amb cries als Pirineus.

Des del punt de vista de la infraestructura, el resultat és clar. Les 41 capes generades per **pirineus-raster** han permès construir una matriu de modelització sense cap valor absent en els punts utilitzats, fet que confirma que el *dataset* és coherent, apilable i directament consumible. Això demostra que la *pipeline* no produeix capes aïllades, sinó un conjunt integrat de predictors que pot alimentar un flux SDM complet.

Des del punt de vista ecològic, les dues classes de cria mostren perfils diferenciats. El model per a **1t6**, corresponent a femelles amb cries de menys de sis mesos, ofereix un gradient d'idoneïtat estable i supera tots els criteris interns de robustesa. L'AUC-ROC en validació LOIO assoleix 0,773 en el domini local i 0,914 en el regional, el Boyce és positiu en ambdós contextos i l'auditoria externa obté un AUC-ROC de 0,925 i un Boyce de 0,964. Per això el model es considera *management-ready* dins del marc intern d'aquest treball, encara que aquesta etiqueta no s'ha d'interpretar com una delimitació oficial ni com un instrument directe de gestió.

El model per a **6to12**, que representa femelles amb cries d'entre sis i dotze mesos, conserva capacitat predictiva, amb AUC-ROC de 0,724 i 0,887 en validació LOIO, i presenta també una auditoria externa positiva, amb AUC-ROC de 0,926 i Boyce de 0,976. Tanmateix, no assoleix la consistència local requerida, ja que el Boyce LOIO és negatiu en el domini local per a tots els candidats provats. Per aquest motiu es classifica com a exploratori, no perquè sigui incoherent, sinó perquè el gradient local no es manté prou estable quan s'avalua sobre individus no vistos. Una explicació ecològica plausible és que les femelles amb cries de sis a dotze mesos tenen una mobilitat més àmplia i un ús del territori més divers, cosa que difumina el senyal ambiental i fa més difícil resumir-lo en un patró local robust. El nombre reduït d'individus monitoritzats reforça aquesta lectura prudent.

Quant a les variables rellevants, l'elevació i la rugositat dominen en les dues classes, fet coherent amb la concentració de les presències en ambients pirinencs de muntanya, forestals i relativament allunyats de la pressió humana. La distància logarítmica a pistes és especialment important en **1t6**, la qual cosa suggereix una selecció d'ambients de baixa accessibilitat quan les cries són molt petites. En **6to12**, la biomassa i la disponibilitat hídrica guanyen pes relatiu, possiblement perquè descriuen ambients forestals, humits i productius. En qualsevol cas, les importàncies per permutació s'han d'interpretar amb cautela, especialment quan hi ha predictors correlacionats, i no com un rànquing causal estricte.

Les conclusions ecològiques queden, doncs, ben delimitades. El treball aporta mapes d'idoneïtat relativa i una lectura metodològica complementària, però no substitueix el criteri expert ni les decisions de gestió territorial. Amb quatre femelles monitoritzades, un domini pirinenc específic i una formulació sense absències verificades, els resultats s'han d'entendre com una base d'anàlisi rigorosa i reproduïble, no com una cartografia definitiva de l'espècie.

5.5 Impacte potencial en recerca i conservació

L'impacte principal de **pirineus-raster** no recau de manera directa sobre la conservació, sinó sobre la infraestructura que pot fer més fàcil, més transparent i més reproduïble la recerca ambiental al Pirineu. Avui, la generació de *datasets* raster harmonitzats continua sent un esforç manual

en molts projectes, sovint resolt amb scripts particulars, decisions poc documentades i processos difícils de repetir. Quan el codi i les configuracions de `pirineus-raster` estiguin disponibles públicament, un investigador que vulgui construir predictors ambientals pirinencs podrà partir d'una base ja verificada, en lloc de reconstruir des de zero tota la cadena d'harmonització.

Aquesta reducció de la barrera tècnica pot tenir efectes concrets. Pot facilitar que projectes amb recursos limitats accedeixin a *datasets* de qualitat comparable als de grups amb més capacitat de preprocessament, pot millorar la comparabilitat entre estudis que comparteixin una mateixa graella o unes mateixes fonts harmonitzades, i pot reforçar la reproductibilitat, ja que les configuracions que han produït cada *dataset* es conserven com a part del resultat. En conseqüència, l'eina no només estalvia temps, sinó que també fa més explícites les decisions que condicionen les anàlisis posteriors.

En l'àmbit de la conservació, la contribució és potencial i indirecta. Els mapes generats en el cas de l'ós bru no delimiten zones de protecció ni substitueixen cartografies oficials, però aporten una perspectiva complementària a treballs com CARTOBIO, amb una anàlisi reproduïble i una validació LOIO explícita. A més llarg termini, una eina d'aquest tipus podria contribuir que estudis similars fossin més accessibles per a altres espècies, altres hàbitats i altres preguntes de gestió, accelerant el pas entre la disponibilitat de dades i la generació de coneixement útil per al territori.

5.6 Limitacions del treball

Les limitacions del treball es poden agrupar en dos àmbits, el de la infraestructura i el del cas d'ús, que convé diferenciar perquè afecten aspectes diferents de la interpretació dels resultats.

Pel que fa a la infraestructura, la primera limitació és la dependència de fonts externes. Les configuracions del catàleg reflecteixen l'estat de les fonts en el moment del desenvolupament, amb URLs, versions, estructures de fitxers i metadades que poden canviar amb el temps. Mantenir aquest catàleg actualitzat requereix un esforç continu que excedeix l'abast d'un TFG. La segona limitació és territorial, ja que `pirineus-raster` ha estat verificat per al domini pirinenc, mentre que l'extensió a altres regions exigiria integrar noves fonts i validar el comportament de les existents en contextos no provats. La tercera és la cobertura encara millorable de tests automatitzats, perquè, tot i que l'eina incorpora validacions de sortida, caldria ampliar les proves unitàries i d'integració per garantir l'estabilitat del sistema en futures modificacions. També cal considerar el cost computacional i d'emmagatzematge associat a fonts d'alta resolució, atès que generar el *dataset* de l'ós bru a 100 m és assumible en HPC, però treballar a 10 o 30 m sobre el conjunt del Pirineu implicaria un volum de dades molt més exigent. Finalment, la UI/*workbench*, per bé que és funcional, manté encara un caràcter de prototip i no ha estat validada amb un conjunt ampli d'usuaris externs.

Pel que fa al cas d'ús, la limitació principal és el nombre reduït d'individus monitoritzats, ja que es disposa de quatre femelles GPS per a cada classe de cria. Amb una mostra tan petita, la validació LOIO deixa fora en cada *fold* una part molt rellevant de la informació individual disponible, i la capacitat del model per capturar patrons generals queda condicionada pels comportaments

particulars de cada femella. Això no invalida els resultats, però sí que obliga a interpretar-los amb cautela i a evitar conclusions excessivament generals sobre l'espècie en conjunt. També hi pot haver biaixos espacials en les dades, perquè les femelles GPS han estat monitoritzades en àrees i períodes concrets, mentre que les observacions OBS tendeixen a concentrar-se en zones més accessibles. L'estratègia de validació adreça parcialment aquest problema, però no l'elimina. Finalment, la resolució de 100 m, tot i ser adequada per al propòsit general del treball, pot no capturar patrons de selecció d'hàbitat molt locals en àrees de relleu complex, on les condicions ambientals varien de manera abrupta dins d'una mateixa cel·la.

5.7 Línies futures

5.7.1 Ampliació de fonts i variables ambientals

El catàleg actual de `pirineus-raster` recull 23 configuracions de fonts, però el conjunt de productes ambientals disponibles a escala europea i global és molt més ampli. Entre les incorporacions més naturals hi hauria dades de connectivitat forestal, índexs de pertorbació humana com la *Human Footprint*, variables de fragmentació del paisatge, dades de productivitat neta de l'ecosistema a escala mensual, productes de canvi de coberta del sòl interanual i fonts de topoclima a resolucions més fines. En l'àmbit nival, la incorporació de productes de neu més recents o amb més continuïtat temporal podria millorar la representació d'un factor especialment rellevant per a espècies de muntanya. Paral·lelament, l'actualització de les versions existents, com noves edicions de CLC+, versions actualitzades d'ESA CCI Biomass o nous productes GHSL, és una tasca de manteniment continu que l'arquitectura modular facilita, però que requerirà atenció periòdica.

5.7.2 Nous casos d'ús ecològics

L'eina `pirineus-raster` no ha estat concebuda exclusivament per a l'ús bru ni per a la modelització d'idoneïtat d'hàbitat. Qualsevol estudi que necessiti predictors ambientals raster harmonitzats al Pirineu pot beneficiar-se de la infraestructura desenvolupada. Entre els casos d'ús més immediats hi hauria la modelització de distribució d'altres espècies amenaçades de la serralada, com el trençalòs, la perdiu blanca o el gall fer, l'anàlisi de la vulnerabilitat d'hàbitats al canvi climàtic, la identificació de corredors ecològics o l'estudi de l'impacte de la ramaderia i el turisme sobre la biodiversitat. En tots aquests casos, l'eina podria generar el *dataset* de predictors de manera ràpida i documentada, permetent que l'esforç de recerca se centrés en les preguntes ecològiques i en el disseny de la modelització, no en la preparació repetitiva de les dades.

Un cas especialment significatiu, i que va estar molt a prop de convertir-se en el cas d'ús principal del TFG, és el de la singratalla pallaresa o sargantana pallaresa (*Iberolacerta aurelioi*), una espècie endèmica i amenaçada pròpia dels roquissars d'alta muntanya de l'Alt Pirineu. Des del punt de vista territorial i ecològic, aquest cas encaixava molt bé amb l'esperit del projecte, ja que hauria permès treballar sobre una espècie molt vinculada al Pirineu i encara poc modelitzada.

Tanmateix, la manca inicial d'un conjunt de dades biològiques prou consolidat, juntament amb les limitacions temporals pròpies del TFG, va fer més raonable decantar el cas d'ús cap a l'ós bru. Aquesta decisió també tenia un avantatge metodològic evident, perquè l'ós bru ja disposava d'una cartografia i d'una modelització de referència, especialment en el marc de CARTOBIO, fet que permetia comparar resultats, discutir-ne la coherència i validar millor la utilitat de la infraestructura desenvolupada.

Això no resta interès al cas de la singratalla pallaresa, sinó que en reforça el valor com a línia futura. Precisament perquè encara no disposa d'un marc de modelització tan consolidat, **pirineus-raster** podria oferir una base molt útil perquè un equip d'experts hi construís un estudi específic, partint d'un *dataset* ambiental harmonitzat i adaptat als ambients rocallosos d'alta muntanya. En aquest sentit, el projecte de l'ós bru s'ha d'entendre com una validació aplicada de l'eina, mentre que casos com el de la singratalla pallaresa mostren el potencial de transferència de la infraestructura cap a noves preguntes de conservació.

Una extensió especialment interessant seria la generació de *datasets* temporals dinàmics, aprofitant fonts amb sèries anuals llargues, com CRU TS, HR-VPP o HRSI Snow, per construir predictors capaços de capturar canvis en les condicions ambientals al llarg del temps. Això permetria estudiar com evoluciona la idoneïtat d'hàbitat en resposta a transformacions climàtiques, nivells o d'ús del sòl.

5.7.3 Millores tècniques i operatives

En l'àmbit tècnic, diverses millores podrien incrementar la robustesa i l'accessibilitat de l'eina. La primera és l'empaquetat formal del projecte com a paquet Python publicat a PyPI, amb documentació d'usuari i de desenvolupador, gestió explícita de dependències i versionat semàntic. Això facilitaria la instal·lació en nous entorns i reduiria la fricció d'adopció per a usuaris externs. La segona és l'extensió de la cobertura de tests automatitzats, tant unitaris, aplicats a funcions de remostreig, derivades o expressions, com d'integració, aplicats a *pipelines* completes amb dades de referència petites. La tercera és la incorporació de suport natiu per a AOIs amb geometries no rectangulars, que permetria delimitar dominis d'estudi irregulars sense dependre exclusivament d'un *bounding box* circumscrit.

Quant al rendiment computacional, la millora del control de memòria en processament de grans dominis i la paral·lelització de les etapes més costoses, com la descàrrega, les derivades topogràfiques o les distàncies, permetrien reduir els temps d'execució en entorns locals i en HPC. També seria útil generar automàticament reports de control de qualitat en format PDF o HTML, amb estadístiques i mapes d'inspecció per a cada capa del *dataset*, ja que això reduiria la càrrega de validació manual. Finalment, una evolució natural del *workbench* seria incorporar la visualització de capes generades i la comparació interactiva de configuracions, de manera que la interfície passés de ser sobretot un espai de preparació a esdevenir també una eina de revisió i exploració.

5.8 Valoració final

Aquest treball va néixer d'una voluntat senzilla, però exigent, que era fer un projecte arrelat al Pirineu i capaç de tenir una utilitat real. El camí ha anat desplaçant el centre de gravetat des d'un cas d'ús ecològic concret cap a una pregunta més general, perquè abans de modelitzar l'hàbitat d'una espècie cal disposar d'una base ambiental coherent, i abans de disposar d'aquesta base cal resoldre una fragmentació de dades que sovint queda amagada darrere dels resultats finals. En aquest sentit, **pirineus-raster** és la resposta tècnica a una necessitat que és alhora científica i territorial.

El cas d'ús de l'ós bru ha demostrat que aquesta infraestructura és funcional en un escenari aplicat exigent. Les capes generades han sustentat un flux SDM complet, els models obtinguts són interpretables i coherents amb el coneixement previ de l'espècie, i la validació LOIO ha permès avaluar la robustesa dels resultats amb un criteri més prudent que els esquemes clàssics de partició aleatòria. Que el model de **1t6** es consideri *management-ready* i el de **6to12** exploratori no és un resultat contradictori, sinó una mostra que el sistema de control funciona correctament, distingint entre resultats amb graus de robustesa diferents i evitant que tots els mapes s'acceptin amb la mateixa confiança.

Els productes d'aquest treball s'han d'entendre, per tant, com una aportació complementària al coneixement disponible sobre l'hàbitat de l'ós bru pirinenc i, sobretot, com una infraestructura de dades que pot servir de base per a futurs estudis ambientals i ecològics a la serralada. No substitueixen la cartografia experta ni les decisions de gestió del territori, però sí que aporten reproductibilitat, transparència metodològica i una base harmonitzada sobre la qual continuar treballant. El fet que el projecte hagi pogut orientar-se inicialment cap a una espècie tan poc estudiada com la singratalla pallaresa, i que finalment hagi trobat en l'ós bru un cas d'ús més contrastable, mostra també una de les seves virtuts principals, que és la capacitat d'adaptar-se a preguntes ecològiques diferents sense perdre coherència metodològica. Aquesta és, en última instància, la contribució principal del projecte, ja que posa una eina al servei d'un territori complex, valuós i fràgil, i obre la porta perquè noves preguntes ecològiques es puguin formular amb menys temps dedicat a preparar dades i més temps dedicat a entendre el medi que aquestes dades descriuen.

Bibliografia

- [1] D. Muñoz Ferrándiz et al., «CARTOBIO: modelització de l'hàbitat de l'os bru (*Ursus arctos*) segons grups d'edat al Pirineu», Centre de Ciència i Tecnologia Forestal de Catalunya i Generalitat de Catalunya, Memòria tècnica, 2023.
- [2] A. Planella, J. Jiménez, G. Palomero, F. Ballesteros, J. C. Blanco i J. V. López-Bao, «Integrating critical periods for bear cub survival into temporal regulations of human activities», *Biological Conservation*, vol. 236, pàg. 489-495, 2019. DOI: [10.1016/j.biocon.2019.06.019](https://doi.org/10.1016/j.biocon.2019.06.019)
- [3] D. Zurell et al., «A standard protocol for reporting species distribution models», *Ecography*, vol. 43, núm. 9, pàg. 1261-1277, 2020. DOI: [10.1111/ecog.04960](https://doi.org/10.1111/ecog.04960)
- [4] A. Garriga Torra, *pirineus_raster: generació automatitzada de datasets raster ambientals als Pirineus*, Repositori de codi a GitHub, Projecte acadèmic, Universitat Politècnica de Catalunya, 2026. adr.: <https://github.com/AniolGarrigaTorra/pirineus-raster>
- [5] S. E. Fick i R. J. Hijmans, «WorldClim 2: new 1-km spatial resolution climate surfaces for global land areas», *International Journal of Climatology*, vol. 37, núm. 12, pàg. 4302-4315, 2017. DOI: [10.1002/joc.5086](https://doi.org/10.1002/joc.5086)
- [6] I. Harris, T. J. Osborn, P. Jones i D. Lister, «Version 4 of the CRU TS monthly high-resolution gridded multivariate climate dataset», *Scientific Data*, vol. 7, pàg. 109, 2020. DOI: [10.1038/s41597-020-0453-3](https://doi.org/10.1038/s41597-020-0453-3)
- [7] V. Eyring et al., «Overview of the Coupled Model Intercomparison Project Phase 6 (CMIP6) experimental design and organization», *Geoscientific Model Development*, vol. 9, pàg. 1937-1958, 2016. DOI: [10.5194/gmd-9-1937-2016](https://doi.org/10.5194/gmd-9-1937-2016)
- [8] European Space Agency i European Union, *Copernicus Digital Elevation Model*, <https://dataspace.copernicus.eu>, GLO-30 product. Consulta: 2026-06-16, 2023. DOI: [10.5270/ESA-c5d3d65](https://doi.org/10.5270/ESA-c5d3d65)
- [9] M. Batalla, M. Ninyerola i J. Catalan, «Digital long-term topoclimate surfaces of the Pyrenees mountain range for the period 1950–2012», *Geoscience Data Journal*, 2018, Dataset associated with the Pyrenean Digital Climate Atlas (PDCA). DOI: [10.1002/gdj3.52](https://doi.org/10.1002/gdj3.52)
- [10] Copernicus Land Monitoring Service, *High Resolution Vegetation Phenology and Productivity*, <https://land.copernicus.eu/en/products/vegetation>, Consulta: 2026-06-16, s.d.
- [11] Copernicus Land Monitoring Service, *Fractional Snow Cover 2016–present (raster 20 m), Europe*, <https://land.copernicus.eu/en/products/snow/fractional-snow-cover>, Consulta: 2026-06-16, s.d.
- [12] M. Santoro i O. Cartus, *ESA Biomass Climate Change Initiative (Biomass_cci): Global datasets of forest above-ground biomass*, NERC EDS Centre for Environmental Data Analysis, Consulta: 2026-06-16, 2025. DOI: [10.5285/95913ffb6467447ca72c4e9d8cf30501](https://doi.org/10.5285/95913ffb6467447ca72c4e9d8cf30501)

- [13] OpenStreetMap contributors, *OpenStreetMap*, <https://www.openstreetmap.org>, Available as open data under the Open Data Commons Open Database License (ODbL). Consulta: 2026-06-16, 2024.
- [14] M. Schiavina, S. Freire i K. MacManus, *GHS-POP R2023A – GHS population grid multitemporal (1975–2030)*, https://human-settlement.emergency.copernicus.eu/ghs_pop2023.php, Consulta: 2026-06-16, 2023.
- [15] Copernicus Land Monitoring Service, *Tree Cover and Forests products*, <https://land.copernicus.eu/en/products/forest>, Consulta: 2026-06-16, s.d.
- [16] Copernicus Land Monitoring Service, *Grasslands products*, <https://land.copernicus.eu/en/products/grassland>, Consulta: 2026-06-16, s.d.
- [17] Copernicus Land Monitoring Service, *CLCplus Backbone*, <https://land.copernicus.eu/en/products/clc-backbone>, Consulta: 2026-06-16, s.d.
- [18] European Space Agency, *ESA WorldCover 10 m 2021 v200*, Zenodo, Producte de coberta del sòl global a 10 m. Consulta: 2026-06-17, 2022. DOI: 10.5281/zenodo.7254221
- [19] L. Brotons, M. Pla, D. Villero i C. Camino, «Cartografia d'espècies de conservació prioritària a Catalunya: aplicacions de la conservació de l'hàbitat», Departament de Medi Ambient i Habitatge i Centre Tecnològic Forestal de Catalunya, Informe inèdit, 2008.
- [20] Ministerio para la Transición Ecológica y el Reto Demográfico, *Estrategia para la conservación del oso pardo (Ursus arctos) en los Pirineos*, <https://www.miteco.gob.es/es/biodiversidad/publicaciones/pbl-fauna-flora-estrategias-oso-pirineos.html>, Consulta: 2026-06-16, 2006.
- [21] Generalitat de Catalunya, *Os bru*, https://mediambient.gencat.cat/ca/05_ambits_dactuacio/patrimoni_natural/fauna-autoctona-protegida/gestio-especies-protegides-amenacades/mamifers/os_bru/, Consulta: 2026-06-16, s.d.
- [22] S. J. Phillips, R. P. Anderson i R. E. Schapire, «Maximum entropy modeling of species geographic distributions», *Ecological Modelling*, vol. 190, núm. 3–4, pàg. 231–259, 2006. DOI: 10.1016/j.ecolmodel.2005.03.026
- [23] J. V. Lombardi, H. L. Perotto-Baldivieso, D. G. Hewitt, D. G. Scognamillo, T. A. Campbell i M. E. Tewes, «Assessment of appropriate species-specific time intervals to integrate GPS telemetry data in ecological niche models», *Ecological Informatics*, vol. 70, pàg. 101–107, 2022. DOI: 10.1016/j.ecoinf.2022.101701
- [24] S. Kramer-Schadt et al., «The importance of correcting for sampling bias in MaxEnt species distribution models», *Diversity and Distributions*, vol. 19, núm. 11, pàg. 1366–1379, 2013. DOI: 10.1111/ddi.12096
- [25] L. Breiman, «Random Forests», *Machine Learning*, vol. 45, pàg. 5–32, 2001. DOI: 10.1023/A:1010933404324
- [26] T. Chen i C. Guestrin, «XGBoost: A scalable tree boosting system», a *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pàg. 785–794. DOI: 10.1145/2939672.2939785
- [27] T. Fawcett, «An introduction to ROC analysis», *Pattern Recognition Letters*, vol. 27, núm. 8, pàg. 861–874, 2006. DOI: 10.1016/j.patrec.2005.10.010

- [28] T. Saito i M. Rehmsmeier, «The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets», *PLOS ONE*, vol. 10, núm. 3, e0118432, 2015. DOI: [10.1371/journal.pone.0118432](https://doi.org/10.1371/journal.pone.0118432)
- [29] M. S. Boyce, P. R. Vernier, S. E. Nielsen i F. K. A. Schmiegelow, «Evaluating resource selection functions», *Ecological Modelling*, vol. 157, núm. 2–3, pàg. 281 - 300, 2002. DOI: [10.1016/S0304-3800\(02\)00200-4](https://doi.org/10.1016/S0304-3800(02)00200-4)
- [30] O. Allouche, A. Tsoar i R. Kadmon, «Assessing the accuracy of species distribution models: prevalence, kappa and the true skill statistic (TSS)», *Journal of Applied Ecology*, vol. 43, núm. 6, pàg. 1223- 1232, 2006. DOI: [10.1111/j.1365-2664.2006.01214.x](https://doi.org/10.1111/j.1365-2664.2006.01214.x)
- [31] G. W. Brier, «Verification of forecasts expressed in terms of probability», *Monthly Weather Review*, vol. 78, núm. 1, pàg. 1 - 3, 1950. DOI: [10.1175/1520-0493\(1950\)078<0001:VOFEIT>2.0.CO;2](https://doi.org/10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2)
- [32] K. P. Murphy, *Machine Learning: A Probabilistic Perspective*. Cambridge, MA: MIT Press, 2012.

Planificació i metodologia de treball

A.1 Fases del projecte

El projecte té els seus orígens a principis del curs anterior, quan es van establir els primers contactes amb el Departament de Seguiment de Fauna de l'Alt Pirineu. En aquelles converses inicials es va plantejar la possibilitat d'utilitzar dades de telemetria GPS de femelles d'ós bru en un projecte de ciència de dades, i es va avaluar quina informació biològica podria estar disponible. Aquella presa de contacte va ser el punt de partida que acabaria definint el cas d'ús del treball.

Les primeres reunions formals amb els directors del projecte es van produir a principis d'any. En aquell moment, la idea original era més centrada en la modelització ecològica: construir un *dataset* ambiental adequat i aplicar-lo a un cas d'ús concret amb l'ós bru, amb possibilitat d'extensió a altres espècies. Tanmateix, a mesura que avançava la fase de disseny i es posava en comú amb experts del sector, va quedar clar que la preparació d'un *dataset* ambiental harmonitzat per al Pirineu era en si mateixa una tasca molt més exigent del que s'havia previst inicialment, i que hi havia una necessitat real i poc coberta d'una eina que automatitzés aquest procés de manera reproducible. Diverses persones del sector geoespacial i de la conservació van fer palesa la manca d'una infraestructura d'aquest tipus per a l'àmbit pirinenc. Aquesta constatació va portar a reformular l'abast del treball: en lloc de centrar-se únicament en el cas de l'ós, el projecte passaria a tenir com a nucli el desenvolupament de **pirineus-raster**, amb el cas d'ús de l'ós bru com a validació aplicada.

A partir d'aquí, el projecte es pot desglossar en quatre fases principals. La primera, que va ocupar aproximadament el primer mes i mig, va consistir en el disseny de l'arquitectura: definir el model de configuració, l'estructura del repositori, la separació entre codi i dades, el model de *features* i el compilador de configuracions. Aquesta fase va requerir moltes decisions de disseny que condicionarien tota la resta del desenvolupament. La segona fase, la més extensa, va estar dedicada a la implementació i integració de fonts: construir la *pipeline*, incorporar les 23 fonts del catàleg, desenvolupar el motor de variables derivades, implementar el sistema de validació, construir el *workbench* visual i depurar el funcionament general de l'eina. Aquesta fase va durar aproximadament tres mesos i va concentrar la gran majoria de les hores del projecte. La tercera fase, d'uns deu dies de durada, va consistir en la construcció del cas d'ús de l'ós bru: generació del *dataset* final, construcció de la matriu de modelització, entrenament i validació dels models, generació de mapes i auditoria externa. Finalment, els darrers quinze dies es van dedicar a la redacció de la memòria i a la preparació de la presentació.

A.2 Seguiment i iteracions

El desenvolupament de **pirineus-raster** no ha seguit un procés lineal. La naturalesa de l'eina, que integra fonts molt diverses amb particularitats pròpies, ha fet necessari un procés iteratiu on cada nova font o funcionalitat requeria revisar decisions prèvies i, en alguns casos, refactoritzar components ja implementats. Per exemple, la incorporació de fonts amb estructures temporals complexes va obligar a estendre el model de modes temporals; la integració de fonts vectorials com OpenStreetMap va requerir afegir lògica de rasterització que inicialment no estava prevista; i el tractament semàntic del remostreig va anar guanyant complexitat a mesura que apareixien casos que el criteri genèric no cobria correctament.

Les reunions de seguiment amb els directors han servit per revisar l'estat del desenvolupament, prioritzar funcionalitats, discutir decisions d'arquitectura i avaluar si l'abast del projecte s'ajustava als objectius inicials. A mesura que el *dataset* i el cas d'ús anaven prenent forma, les revisions intermedis de resultats parcials han permès detectar inconsistències en les capes generades i ajustar configuracions o mètodes de processament abans d'arribar al producte final.

A.3 Riscos identificats

El risc més important del projecte és l'escala del desenvolupament en relació amb els recursos disponibles. **pirineus-raster** és una eina de processament geoespacial amb un catàleg de 23 fonts, un motor de derivades, un compilador de configuracions, un sistema de validació i una interfície visual: un conjunt de components que en un projecte professional hauria estat desenvolupat per un equip. Haver-ho construït una sola persona implica que, malgrat les validacions realitzades, és probable que existeixin errors o comportaments inesperats en casos d'ús no provats explícitament. Les combinacions de fonts, AOIs, resolucions i opcions temporals que l'eina permet generar són molt nombroses, i la cobertura de tests automatitzats no garanteix que tots els camins d'execució hagin estat verificats.

Un segon risc és la dependència de fonts externes. Les configuracions del catàleg reflecteixen l'estat de les fonts en el moment del desenvolupament, i canvis en URLs, versions, formats o credencials poden fer que algunes fonts deixin de funcionar sense preavís. Aquest risc és inherent a qualsevol sistema que integri dades de tercers i no es pot eliminar completament, només mitigar amb un manteniment periòdic.

El tercer risc és la limitació de les dades biològiques per al cas d'ús. Amb quatre femelles GPS per classe de cria, la capacitat del model per capturar patrons generals més enllà dels comportaments individuals és limitada. Això no invalida els resultats, però condiciona directament la robustesa de les conclusions ecològiques i fa que la validació LOIO sigui especialment exigent.

Finalment, el risc de desviació d'abast ha estat present durant tot el projecte. La construcció de **pirineus-raster** és una tasca de complexitat oberta: sempre és possible afegir noves fonts, millorar el motor de derivades, estendre el *workbench* o millorar la cobertura de tests. Mantenir el focus en un abast manejable per a un treball d'aquestes característiques ha requerit decisions deliberades de prioritització, i és probable que algunes funcionalitats desitjables hagin quedat fora

de l'abast actual.

Annex B

Viabilitat, manteniment i escalabilitat

B.1 Recursos utilitzats

El projecte s'ha desenvolupat íntegrament amb programari lliure i dades d'accés obert, cosa que elimina costos de llicència i facilita la reproducció per part de tercers. L'entorn de treball ha estat Python 3.11 gestionat amb conda, amb un conjunt de llibreries geoespaciales estàndard: `rasterio` i `GDAL` per a la lectura i escriptura de rasters, `geopandas` i `shapely` per a operacions vectorials, `numpy` per a computació sobre matrius, `pyproj` per a transformacions de coordenades, i `pydantic` per a la validació de configuracions. La modelització del cas d'ús ha emprat `scikit-learn`, `xgboost` i `optuna`. La interfície visual s'ha desenvolupat amb React i biblioteques de mapes de codi obert.

El desenvolupament s'ha dut a terme principalment en un equip local amb 32 GB de RAM i emmagatzematge SSD, suficient per a la major part de les tasques de configuració, depuració i validació de capes individuals. Les execucions més exigents, concretament la generació completa del *dataset* a 100 m i el flux de modelització del cas d'ús, s'han executat al clúster HPC CSL de la UPC, que ha permès disposar de nodes amb major memòria i paral·lelitzar algunes etapes costoses.

Les fonts de dades emprades són totes de distribució pública i gratuïta: Copernicus (DEM, CLMS, HR-VPP, HRSI), ESA CCI Biomass, PDCA Topoclimate, OpenStreetMap, GHSL i ESA WorldCover. La majoria no requereixen credencials; les que sí en necessiten (alguns productes Copernicus distribuïts via serveis HDA) disposen d'accés gratuït mitjançant registre. Quant al temps dedicat, el projecte ha suposat aproximadament 700–800 hores de treball distribuïdes entre disseny de l'arquitectura, implementació, integració de fonts, generació del *dataset*, modelització i redacció de la memòria.

B.2 Cost aproximat del projecte

El cost principal del projecte és el cost d'oportunitat del temps de l'autor. Si es valora a un preu orientatiu de 25 €/h per a un perfil junior en ciència de dades, les 700–800 hores dedicades representen un cost de desenvolupament d'entre 17.500 i 20.000 €. Aquest valor inclou disseny, implementació, depuració, generació del *dataset*, modelització i documentació, però no el cost d'un eventual manteniment continu posterior.

El cost computacional ha estat modest. L'accés al clúster CSL de la UPC ha estat gratuït per a estudiants del grau, i el temps de còmput total emprat és difícil de quantificar amb precisió,

però es pot estimar en unes 50–80 hores de CPU efectives per a totes les execucions del projecte. L'emmagatzematge total de dades originals, intermedis i processats és d'aproximadament 200 GB, assequible en disc local o en solucions de núvol estàndard.

Un aspecte rellevant és la distinció entre el cost de desenvolupament i el cost incremental d'ús futur. Un cop l'eina **pirineus-raster** està implementada i les fonts configurades, generar un nou *dataset* per a una AOI diferent o una resolució alternativa té un cost marginal molt baix: uns minuts de configuració i unes poques hores d'execució computacional, depenent del volum de dades. Això fa que la inversió inicial en infraestructura tingui un retorn creixent a mesura que s'incorporen nous casos d'ús.

B.3 Manteniment de fonts i connectors

Una part essencial de la viabilitat a llarg termini de **pirineus-raster** és el manteniment de les configuracions de fonts. Les fonts geoespacionals externes evolucionen: les URLs canvien, els portals es reestructuren, es publiquen noves versions dels productes, apareixen nous formats o s'eliminen els antics, i en alguns casos canvien les credencials o els termes d'accés. Sense un manteniment periòdic de les configuracions, el sistema pot continuar funcionant com a *pipeline*, però algunes fonts poden deixar d'estar disponibles o generar resultats incorrectes.

L'arquitectura de **pirineus-raster** redueix aquest risc de dues maneres. En primer lloc, la separació entre codi i configuració fa que actualitzar una font sigui equivalent a modificar el seu fitxer de configuració a `configs/sources/`, sense necessitat de tocar la lògica general del *pipeline*. En segon lloc, els mòduls específics de fonts encapsulen les particularitats de cada proveïdor, de manera que un canvi en una font no afecta les altres. Això localitza el manteniment i el fa manejable.

Tot i així, el manteniment no és gratuït. Requereix que algú amb coneixement del projecte faci revisions periòdiques de l'estat de les fonts, comprovi que les descàrregues continuen funcionant i actualitzi les configuracions quan és necessari. En un context de recerca, aquesta tasca pot assumir-la el grup que utilitza l'eina o la persona que l'ha desenvolupat. La publicació del repositori a GitHub facilita que la comunitat pugui contribuir a detectar i corregir problemes a mesura que apareguin [4].

B.4 Viabilitat de continuïtat

El projecte no depèn d'un entorn tancat ni de serveis de pagament, de manera que la seva continuïtat no s'interromp amb la finalització del projecte. Un cop publicat el repositori a GitHub, qualsevol investigador o grup amb accés a les fonts de dades i a un entorn Python adequat podrà instal·lar l'eina, explorar les configuracions existents i generar nous *datasets* sense necessitat d'interacció directa amb l'autor.

L'arquitectura modular facilita l'extensió independent de les seves parts. Un investigador pot afegir una nova font al catàleg sense modificar el *pipeline*; un altre pot definir nous tipus de

variables derivades sense alterar la lògica de configuració; i un tercer pot adaptar una AOI existent per a una espècie diferent sense tocar cap altre component del sistema. Aquesta independència entre components és el que fa que el projecte pugui créixer de manera orgànica.

El potencial d'integració en projectes de recerca existents també reforça la continuïtat. Grups que treballen en modelització ecològica pirinenca, en seguiment de la biodiversitat o en anàlisi de l'impacte del canvi climàtic sobre els ecosistemes de muntanya podrien beneficiar-se directament de la infraestructura sense haver de replicar el treball d'harmonització de fonts. En aquest sentit, **pirineus-raster** pot funcionar com una base de dades compartida, generada de manera transparent i reproduïble, sobre la qual construir projectes de recerca col·laboratius.

B.5 Escalabilitat territorial i computacional

L'eina **pirineus-raster** admet, en principi, qualsevol AOI definible com a rectangle alineat dins del domini pirinenc. Això inclou des d'àrees experimentals de pocs quilòmetres quadrats, útils per a depurar configuracions o fer proves ràpides, fins al domini complet dels Pirineus, que a 100 m representa una graella de l'ordre de cinc milions de cel·les per capa. En la pràctica, l'escalabilitat és un compromís entre resolució, extensió i recursos disponibles.

A 100 m, el *dataset* del cas d'ús de l'ós bru (3410×1600 cel·les, 41 capes, aproximadament 645 MB) és plenament manejable en un equip local amb 16 GB de RAM, sempre que el *pipeline* no carregui totes les capes simultàniament a memòria. L'eina **pirineus-raster** incorpora mecanismes de control de memòria que permeten processar capes de manera seqüencial i alliberar recursos entre etapes, la qual cosa fa que l'execució local sigui viable fins i tot amb *datasets* de centenars de capes.

A 30 m sobre el mateix domini, el volum de dades creixeria aproximadament onze vegades, fins a uns 7 GB per al *dataset* equivalent. Aquesta escala és manejable en HPC però comença a ser exigent en equips locals, especialment per a les etapes de derivades topogràfiques i distàncies, que requereixen operar sobre la graella completa. A 10 m, el volum seria cent vegades superior al de 100 m, i el processament requeriria necessàriament un entorn HPC amb gestió explícita de memòria i possible divisió del domini en tessel·les.

Per a entorns HPC, el projecte inclou *scripts* SLURM a `jobs/` que permeten llançar les etapes principals com a *jobs* independents: creació de la graella, processament de fonts, generació de derivades i execució del *notebook* de modelització. Aquesta estructura permet paral·lelitzar fonts independents, gestionar cues de memòria i reproduir execucions costoses de manera controlada. La combinació entre configuració YAML i *scripts* SLURM garanteix que l'escalabilitat computacional no compromet la reproductibilitat del procés.

Aspectes ètics, socials i ambientals

C.1 Impacte científic i social

L'impacte social i científic de **pirineus-raster** s'articula principalment a través de la reducció de barreres tècniques en la recerca ambiental. La generació de *datasets* raster harmonitzats a partir de fonts heterogènies és una tasca habitual però costosa en projectes d'anàlisi espacial i modelització ecològica. En molts casos, aquest treball previ consumeix una part desproporcionada dels recursos disponibles, en detriment del temps dedicat a les preguntes científiques pròpies de cada estudi. **pirineus-raster** aborda directament aquest problema oferint una infraestructura que pot reutilitzar-se en múltiples contextos sense repetir la cadena d'harmonització.

Aquesta reducció de fricció té implicacions socials concretes. En primer lloc, fa que la recerca ambiental de qualitat sigui més accessible per a grups amb recursos limitats, que no disposen de personal especialitzat en processament geoespacial. En segon lloc, facilita la comparabilitat entre estudis: quan dos grups generen *datasets* amb la mateixa eina i les mateixes configuracions, els seus predictors comparteixen per construcció el mateix marc espacial, cosa que permet contrastar resultats de manera directa. En tercer lloc, promou la transparència i la reproductibilitat científica, atès que les configuracions que han produït un *dataset* formen part del *dataset* mateix i poden ser revisades per altres investigadors.

L'ús exclusiu de programari lliure i dades d'accés obert és també una decisió amb implicacions socials. Significa que el projecte no genera dependències de plataformes comercials, que qualsevol persona amb un ordinador i connexió a internet pot reproduir els resultats, i que no hi ha barreres econòmiques per adoptar l'eina en contextos de recerca o de gestió pública del territori.

C.2 Contribució a la conservació de la biodiversitat

El cas d'ús de l'ós bru connecta directament el projecte amb una qüestió de conservació rellevant al Pirineu. L'*Ursus arctos* és una espècie protegida i en perill d'extinció a la serralada, on el nucli reproductor és extremadament reduït i la seva recuperació depèn de decisions de gestió territorial ben fonamentades. Les femelles amb cries representen el segment demogràfic més sensible: els primers mesos de vida de les cries condicionen fortament la supervivència de la pròxima generació, i les zones que utilitzen durant aquest període poden ser especialment rellevants per a estratègies de protecció i regulació d'activitats humanes.

En aquest context, els mapes d'idoneïtat generats en el capítol 4 no substitueixen la cartografia experta ni les decisions de les autoritats competents. El seu valor és el d'una aportació metodo-

lògica complementària: una anàlisi reproducible, basada en dades obertes i amb una validació explícita, que pot ser contrastada amb altres estudis i que aporta una perspectiva addicional sobre quines condicions ambientals caracteritzen les zones d'ús de femelles amb cries. Interpretats amb prudència i en conjunt amb el coneixement expert existent, aquests resultats poden contribuir a informar decisions de gestió, però no les substitueixen.

Més enllà de l'ós bru, la infraestructura desenvolupada podria aplicar-se a altres espècies amenaçades del Pirineu que requereixin predictors ambientals harmonitzats: isard, trençalòs, perdiu blanca o diverses espècies de papallones de muntanya, entre d'altres. En tots aquests casos, la disponibilitat d'un *dataset* base reutilitzable pot accelerar l'inici de noves anàlisis i reduir el risc d'errors de preprocessament que podrien comprometre la qualitat dels models resultants.

C.3 Sostenibilitat i Objectius de Desenvolupament Sostenible

El projecte s'alinea amb diversos Objectius de Desenvolupament Sostenible (ODS) de l'Agenda 2030, tot i que la seva contribució és de caràcter indirecte, com a infraestructura de dades i recerca, i no com a intervenció directa sobre els problemes esmentats.

L'ODS 15 (Vida terrestre) és el més directament relacionat amb el projecte. La disponibilitat de dades ambientals harmonitzades i reproduïbles contribueix a millorar la base d'informació per a estudis de conservació de la biodiversitat terrestre, modelització d'hàbitats i avaluació de l'impacte d'activitats humanes sobre ecosistemes sensibles. El cas d'ús de l'ós bru n'és un exemple concret, centrat en una espècie protegida en un dels espais naturals transfronterers més rellevants d'Europa.

L'ODS 13 (Acció climàtica) és rellevant perquè part del catàleg de fonts de **pirineus-raster** inclou variables climàtiques i nivells que poden ser útils per analitzar l'impacte del canvi climàtic sobre la distribució i l'hàbitat d'espècies de muntanya. La infraestructura permet construir *datasets* que combinen condicions climàtiques actuals i potencialment futures, obrint la porta a estudis de vulnerabilitat i adaptació.

L'ODS 9 (Indústria, innovació i infraestructura) s'aplica en el sentit que **pirineus-raster** contribueix a la infraestructura científica de recerca ambiental: no és una innovació de producte, sinó una innovació de procés que millora l'eficiència i la reproductibilitat de la recerca en ciències de la terra i l'ecologia. Finalment, l'ODS 17 (Aliances per als objectius) es reflecteix en el caràcter obert del projecte, dissenyat per ser compartit, reutilitzat i estès per altres grups de recerca.

C.4 Riscos, biaixos i ús responsable de les dades

L'ús de dades geoespacionals i models predictius en el context de la conservació d'espècies comporta riscos que convé reconèixer explícitament.

El primer és el risc de sobreinterpretació dels mapes d'idoneïtat. Un mapa continu d'idoneïtat relativa expressa la semblança ambiental de cada cel·la amb les localitzacions conegudes de presència, però no és una probabilitat d'ocurrència ni una delimitació oficial d'hàbitat. Interpretar-

lo com a tal podria conduir a decisions de gestió mal fonamentades: protegir zones basant-se únicament en el valor d'ideïtat d'un model exploratori, o descartar zones amb valor baix sense considerar que el model pot no capturar tots els factors rellevants. Per aquest motiu, els resultats del cas d'ús sempre s'han presentat amb les seves mètriques de robustesa i amb indicació explícita de l'estat de cada model.

El segon és el biaix de detecció en les dades biològiques. Les localitzacions **GPS** provenen d'un nombre reduït d'individus monitoritzats en àrees i períodes concrets, i les observacions **OBS** tendeixen a concentrar-se en zones accessibles o freqüentades per equips de seguiment. Ambdós tipus de dades poden subestimar l'ús de zones remotes, de difícil accés o poc prospectades, cosa que podria fer que els models assignessin una ideïtat baixa a zones que l'espècie utilitza però on no s'ha detectat. Aquest biaix és inherent a les dades disponibles i no s'elimina amb cap tècnica de modelització; cal tenir-lo present en qualsevol interpretació dels resultats.

El tercer és el risc associat a la difusió de localitzacions precises d'espècies amenaçades. La publicació de dades **GPS** de femelles d'ós bru amb cries podria, en casos extrems, facilitar la localització d'individus en períodes crítics i exposar-los a pertorbació humana o a activitats il·lícites. En aquest projecte, les coordenades individuals no s'han publicat, i els mapes finals expressen ideïtat a resolució de 100 m, sense revelar localitzacions concretes. Qualsevol ús futur de les dades biològiques hauria de mantenir el mateix nivell de precaució i seguir els protocols establerts per les autoritats competents en matèria de conservació.

Finalment, el risc d'errors en el preprocessament de fonts externes és rellevant en qualsevol projecte basat en dades heterogènies. Tot i que l'eina **pirineus-raster** incorpora validacions geomètriques, estadístiques i visuals, no és possible garantir que totes les fonts estiguin lliures d'errors o inconsistències. Per aquest motiu, qualsevol *dataset* generat amb l'eina hauria de ser revisat per l'investigador que l'utilitza, especialment quan es treballa amb fonts poc familiars o en dominis espacials nous.

Ús d'eines d'intel·ligència artificial

D.1 Tasques assistides per IA

Al llarg del projecte s'han utilitzat eines d'intel·ligència artificial generativa, principalment com a assistent de programació i de redacció. En cap cas han substituït les decisions tècniques, el judici de l'autor ni la validació dels resultats.

En l'àmbit del desenvolupament, la IA ha estat útil per consultar aspectes complexos d'implementació: construcció del *workbench* en React, integració de components de mapes, gestió d'estat i renderització de configuracions **YAML**; lògica de compilació de configuracions i resolució de dependències entre *features*; operacions raster avançades amb **rasterio** i **GDAL**; implementació del motor d'expressions i del sistema de validació; i estructuració de mòduls, patrons de disseny i depuració de comportaments inesperats. En tots els casos, el codi suggerit es revisava, s'adaptava al context real del projecte, s'executava i es verificava el seu funcionament. En molts casos s'hi introduïen canvis substancials o es descartava completament la proposta inicial.

En l'àmbit de la redacció, la IA s'ha emprat com a assistent de llenguatge i d'organització: per revisar la fluïdesa i coherència de fragments complexos, per trobar maneres alternatives d'explicar conceptes tècnics, per ajudar amb la sintaxi **L^AT_EX** i l'estructura del document, i per verificar que el registre acadèmic es mantenia consistent al llarg del text. La redacció final de tots els capítols ha estat revisada, reescrita i condicionada per l'autor.

D.2 Criteris de supervisió i validació humana

Totes les decisions tècniques rellevants del projecte han estat preses per l'autor: l'arquitectura de **pirineus-raster**, el model de configuració, la semàntica del remostreig, el disseny del cas d'ús, l'estratègia de validació **L0I0** i la interpretació dels resultats. La IA no ha pres cap d'aquestes decisions ni ha tingut accés als resultats finals per avaluar-ne la correcció.

Tot el codi que forma part del repositori ha estat llegit, entès i provat per l'autor. Cap fragment ha estat incorporat sense verificar-ne el comportament en el context real d'execució. De manera equivalent, tot el text de la memòria ha estat revisat, modificat i aprovat per l'autor; cap paràgraf s'ha inclòs directament sense revisió crítica del seu contingut i adequació al projecte.

D.3 Limitacions de l'assistència amb IA

Les eines d'IA generativa produeixen sovint suggeriments plausibles però incorrectes: codi que compila però no fa el que s'espera, afirmacions tècnicament imprecises, referències bibliogràfiques inventades o solucions que no s'adapten al context específic del problema. Aquestes limitacions s'han tingut presents durant tot el projecte. Qualsevol suggeriment s'ha contrastat amb la documentació oficial de les llibreries, amb proves d'execució reals i amb el criteri propi acumulat al llarg del desenvolupament.

En resum, la IA s'ha utilitzat com una eina de suport que ha contribuït a millorar l'eficiència en algunes tasques, però l'autoria intel·lectual del projecte, la responsabilitat sobre les decisions adoptades i la validació de tots els productes finals corresponen íntegrament a l'autor del treball.

Annex E

Mapes finals del cas d'ús de l'ós bru

Aquest annex presenta, en format ampliat, els sis mapes finals resumits a la figura 4.6: idoneïtat relativa, zones categòriques i incertesa relativa per a les classes 1t6 i 6to12.




Figura E.1: Mapa d'idoneïtat relativa per a la classe 1t6 en EPSG:3035.




Figura E.2: Mapa d'idoneïtat relativa per a la classe 6to12 en EPSG:3035.




Figura E.3: Mapa de zones categòriques per a la classe 1t6 en EPSG:3035.




Figura E.4: Mapa de zones categòriques per a la classe 6to12 en EPSG:3035.




Figura E.5: Mapa d'incertesa relativa per a la classe 1t6 en EPSG:3035.




Figura E.6: Mapa d'incertesa relativa per a la classe 6to12 en EPSG:3035.

Annex F

Instruccions de reproductibilitat

Aquest annex descriu com preparar l'entorn, configurar el projecte i executar **pirineus-raster** per reproduir el *dataset* ambiental generat en aquesta memòria. Les instruccions es basen en el contingut del repositori públic del projecte, on es troben totes les configuracions, el codi font i la documentació tècnica [4].

F.1 Requisits de l'entorn

El projecte requereix Python 3.11 o superior. Es recomana utilitzar conda per gestionar l'entorn, ja que la pila geoespacial depèn de biblioteques compilades com GDAL, PROJ, **rasterio**, **geopandas** i **pyogrio**, que conda resol de manera més fiable que pip sol.

Per crear i activar l'entorn:

```
conda env create -f environment.yml
conda activate pirineus-raster
```

Un cop activat l'entorn, cal instal·lar el paquet en mode editable des de l'arrel del repositori:

```
pip install -e .
```

Es pot verificar que la CLI és accessible amb:

```
pirineus-raster --help
```

Per al *workbench* visual, cal instal·lar les dependències de Node una sola vegada:

```
cd ui
npm install
cd ..
```

Algunes fonts Copernicus distribuïdes via el servei WEkEO/HDA requereixen credencials. Es poden configurar de manera interactiva amb:

```
pirineus-raster check-credentials --setup
```

Això crea o actualitza el fitxer `~/hdarc` amb les credencials de l'usuari. Les *runs* que no utilitzen fonts autenticades no necessiten aquest pas.

F.2 Estructura de configuracions

Totes les decisions de l'experiment queden expressades en fitxers de configuració YAML organitzats a `configs/`. Els quatre components principals són:

`configs/project.yaml` defineix els paràmetres globals del projecte: el CRS de treball, els directoris de dades, el valor `NoData`, les resolucions disponibles i les opcions de nomenclatura de sortides. És el punt de referència comú per a totes les execucions.

`configs/aoi/` conté les definicions d'àrees d'interès. Cada fitxer AOI especifica els límits espacials d'un domini concret. Per al cas d'ús de l'ós bru, l'AOI rellevant és `ursus_arctos_pyrenees.yaml`. L'AOI ha de ser compatible amb la resolució escollida: els límits han de ser divisibles exactament per la mida de píxel perquè la graella resultant sigui regular.

`configs/sources/` actua com a catàleg de fonts. Cada fitxer descriu un producte ambiental concret: el proveïdor, les variables disponibles, les dimensions temporals, la resolució nativa i els paràmetres de descàrrega o localització. Aquestes configuracions no cal modificar-les per executar una *run* existent.

`configs/runs/` conté les receptes de *dataset*. Cada fitxer de *run* especifica quina AOI s'utilitza, a quina resolució es treballa, quines *features* finals es volen generar i on s'escriuen les sortides. La *run* principal del cas d'ús és `ursus_arctos_pyrenees_100m.yaml`.

F.3 Validació i renderització de configuracions

Abans d'executar una *run* amb dades reals, es recomana validar la configuració per detectar errors de fonts, variables inexistents, incompatibilitats temporals o problemes de resolució:

```
pirineus-raster validate-config \  
  configs/runs/ursus_arctos_pyrenees_100m.yaml
```

Per veure el pla d'execució complet que el compilador deriva de la configuració d'alt nivell, incloent-hi totes les fonts i operacions derivades resoltes:

```
pirineus-raster render-run \  
  configs/runs/ursus_arctos_pyrenees_100m.yaml
```

Aquests dos passos permeten detectar problemes abans de llançar descàrregues o processaments costosos. Es recomana executar-los sempre que es modifiqui una configuració de *run* o s'afegeixi una nova *feature*.

F.4 Creació de la graella de referència

La graella de referència defineix el marc espacial comú al qual s'alinearan totes les capes del *dataset*. Cal crear-la abans d'executar cap etapa de processament. Per a l'AOI i resolució del cas d'ús:

```
pirineus-raster make-grid \  
  --project-config configs/project.yaml \  
  --aoi-config configs/aoi/ursus_arctos_pyrenees.yaml \  
  --resolution 100
```

Això genera un fitxer raster de referència a la carpeta de dades processades que el *pipeline* consultarà durant el *build*. La graella resultant per a *ursus_arctos_pyrenees* a 100 m té 3410 columnes i 1600 files, en EPSG:3035. Es pot inspeccionar i verificar la seva coherència amb la configuració del projecte amb:

```
pirineus-raster validate-config \  
  configs/runs/ursus_arctos_pyrenees_100m.yaml
```

que inclou comprovacions sobre la graella com a part de la validació prèvia a l'execució.

F.5 Execució del *pipeline*

L'execució completa d'una *run* cobreix les tres etapes del *pipeline* (*download*, *clip* i *build*) i genera el *dataset* final:

```
pirineus-raster run \  
  configs/runs/ursus_arctos_pyrenees_100m.yaml
```

En màquines amb memòria limitada, es pot reduir la pressió sobre la RAM reduint el nombre de treballadors paral·lels i el nombre màxim de rasters carregats simultàniament:

```
pirineus-raster run \  
  configs/runs/ursus_arctos_pyrenees_100m.yaml \  
  --num-workers 1 \  
  --max-rasters-in-memory 2
```

Si es vol executar una font concreta de manera independent, per exemple per depurar o regenerar una capa específica, es pot usar:

```
pirineus-raster run-source <source_id> \  
  configs/runs/ursus_arctos_pyrenees_100m.yaml
```

Per consultar les fonts disponibles al catàleg o inspeccionar una font concreta:

```
pirineus-raster list-sources
pirineus-raster catalog
pirineus-raster catalog --source-config \
  configs/sources/copernicus/dem_glo30.yaml
```

F.6 Validació de resultats

Un cop generada una *run*, les sortides es troben dins de `data_processed/datasets/`, en una carpeta pròpia de l'execució (per al cas principal, `ursus_arctos_pyrenees_100m`). El paquet inclou: la carpeta `rasters/` amb els GeoTIFF finals i els seus fitxers JSON de metadades laterals; `metadata/manifest.json` com a índex del *dataset*; `metadata/run_summary.json` amb el resum de l'execució; i `config/` amb còpies de les configuracions utilitzades.

Per obtenir un resum del *dataset* generat:

```
pirineus-raster inspect \
  data_processed/datasets/ursus_arctos_pyrenees_100m
```

Per verificar que tots els rasters finals s'alineen correctament amb la graella de referència i que les metadades són coherents:

```
pirineus-raster validate-dataset \
  data_processed/datasets/ursus_arctos_pyrenees_100m
```

Per a una comprovació estricta que també verifica la presència de tots els camps de metadades estandarditzats:

```
pirineus-raster validate-dataset \
  data_processed/datasets/ursus_arctos_pyrenees_100m \
  --strict-metadata
```

La validació comprova CRS, resolució, *transform affine*, dimensions, valor NoData i rang estadístic per a cada capa, i escriu un informe a `metadata/validation_report.json`.

F.7 Interfície visual de configuració

El *workbench* visual permet explorar el catàleg de fonts, construir configuracions de *run* de manera assistida i validar-les sense editar YAML manualment. Per iniciar l'API de configuració i la interfície conjuntament:

```
pirineus-raster serve-ui
```

Alternativament, es poden iniciar per separat en dos terminals:

```
pirineus-raster serve-config-api --host 127.0.0.1 --port 8765
```

```
cd ui  
npm run dev
```

La interfície queda disponible a `http://127.0.0.1:5173`. Cal tenir l'API de configuració activa perquè la UI pugui consultar el catàleg de fonts i processar les peticions de validació i renderització.

F.8 Execució en HPC/SLURM

Per a execucions que requereixen més memòria o temps de còmput del que ofereix un equip local, el repositori inclou *scripts* SLURM a `jobs/`. Els principals són `run_make_grid.sh`, que llança la creació de la graella com a *job* independent, i `run_raster_features.sh`, que executa la *run* completa del *dataset* en un entorn HPC. Cada script defineix les peticions de recursos (memòria, nombre de nuclis, temps màxim) i redirigeix la sortida estàndard i els errors a fitxers de log.

El flux recomanat en HPC és: primer validar la configuració i crear la graella localment, i després llançar el *build* en el clúster. Això evita ocupar temps de cua per a tasques lleugeres i garanteix que la graella de referència existeix abans que el *job* principal intenti accedir-hi. Els scripts estan preparats per al clúster CSL de la UPC, però s'adapten fàcilment a altres entorns SLURM canviant les directives de recursos i els paths de l'entorn conda.